TESI DI LAUREA IN METODI PER IL RITROVAMENTO DELL'INFORMAZIONE

Analisi Strutturale e Music Captioning a livello di segmento: un approccio ibrido DSP + LLM

Corso di Laurea in Informatica

RELATORE

Prof. Pasquale Lops

RELATORE

Prof. Cataldo Musto

LAUREANDO

Paolo Lamanna

A.A. 2025/2026

Obiettivo del sistema

INPUT

Un brano audio

Nessun addestramento sul compito



sistema

OUTPUT · PER OGNI SEZIONE DEL BRANO

INTERVALLO	**1:05 – 1:27**
NOME	**Big Room Drop 1**
DIDASCALIA	*“A massive, distorted Big Room kick and aggressive synth lead detonate with overwhelming force.”*
MOTIVAZIONE	*“Token 11 marks the explosive peak of the track’s kinetic energy (MSF peaks at 13.75).”*

OBIETTIVO **Segmentare il brano e descrivere ogni sezione, spiegando ogni scelta con misure del segnale**

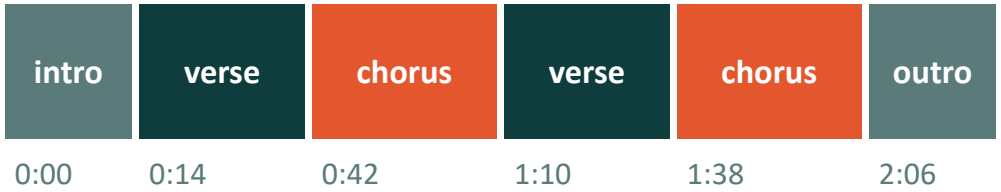
Il problema

I SISTEMI ESISTENTI

Struttura e descrizione restano separate

- **Modelli supervisionati di analisi della struttura musicale (MSA)** → alta precisione strutturale, ma solo un'etichetta funzionale
- **Modelli audio-linguaggio (LALM)** → descrizioni ricche, ma operano su rappresentazioni latenti, difficili da controllare

OUTPUT DI UN MODELLO MSA · ESEMPIO ILLUSTRATIVO



Solo intervalli ed etichette funzionali

OUTPUT DI UN MODELLO LALM · ESEMPIO ILLUSTRATIVO

"Un brano elettronico con synth aggressivi e voce femminile, che alterna momenti più calmi a passaggi molto energici."

Testo libero, senza confini né legame con misure

L’approccio proposto

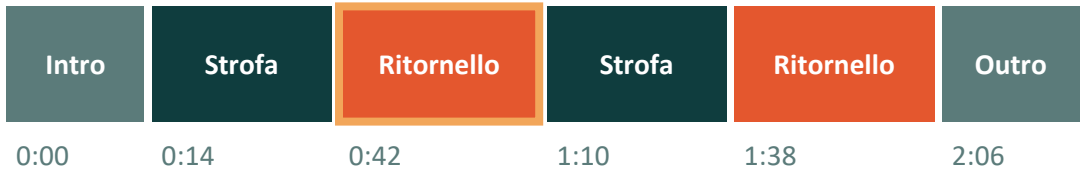
IL NOSTRO SISTEMA

Struttura e descrizione, in modo interpretabile

Il DSP misura, l’LLM interpreta

1. **DSP** → misura il segnale: battiti, energia, voce e testo
2. **LLM** → interpreta le misure, senza mai ascoltare l’audio
3. **Output** → sezioni con intervallo, didascalia e motivazione

OUTPUT: SEZIONI, DIDASCALIA, MOTIVAZIONE · ILLUSTRATIVO

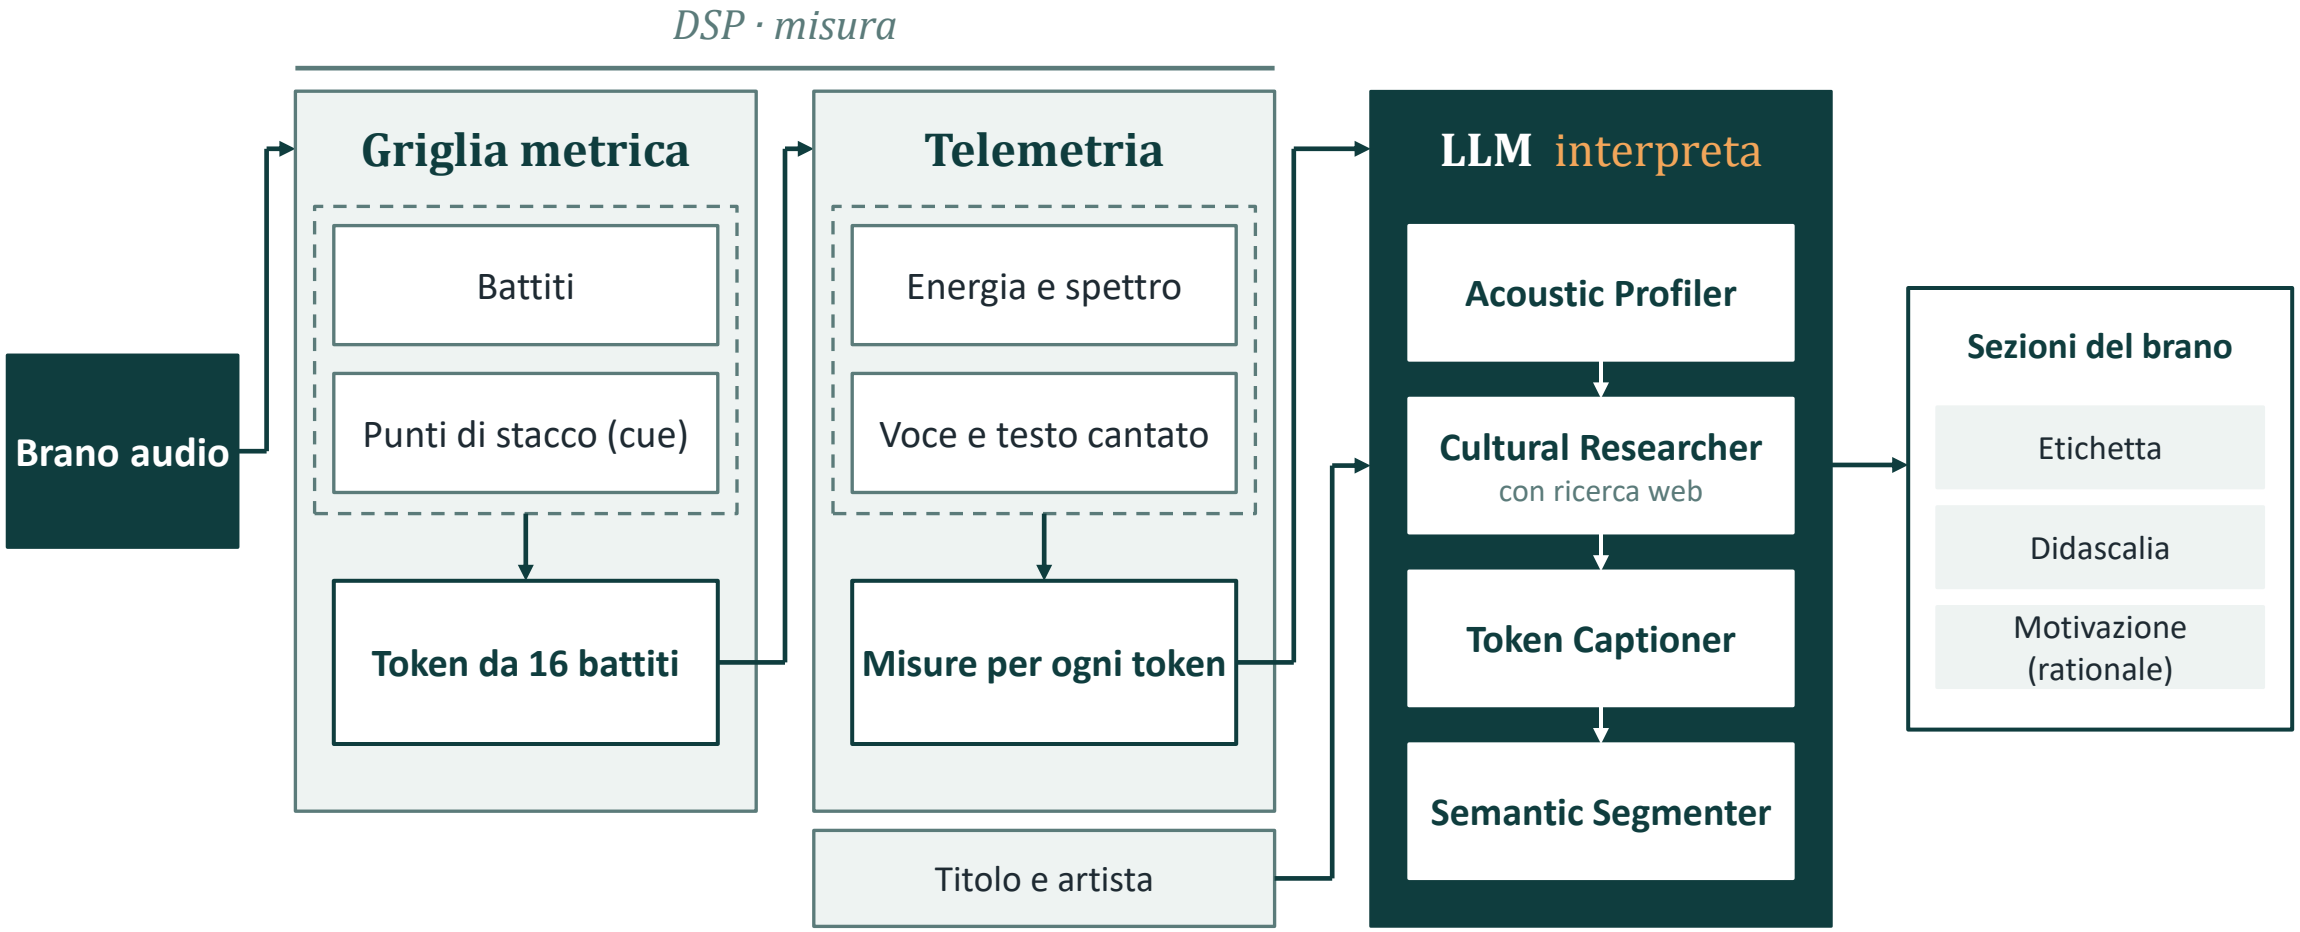


Ritornello · 0:42–1:10

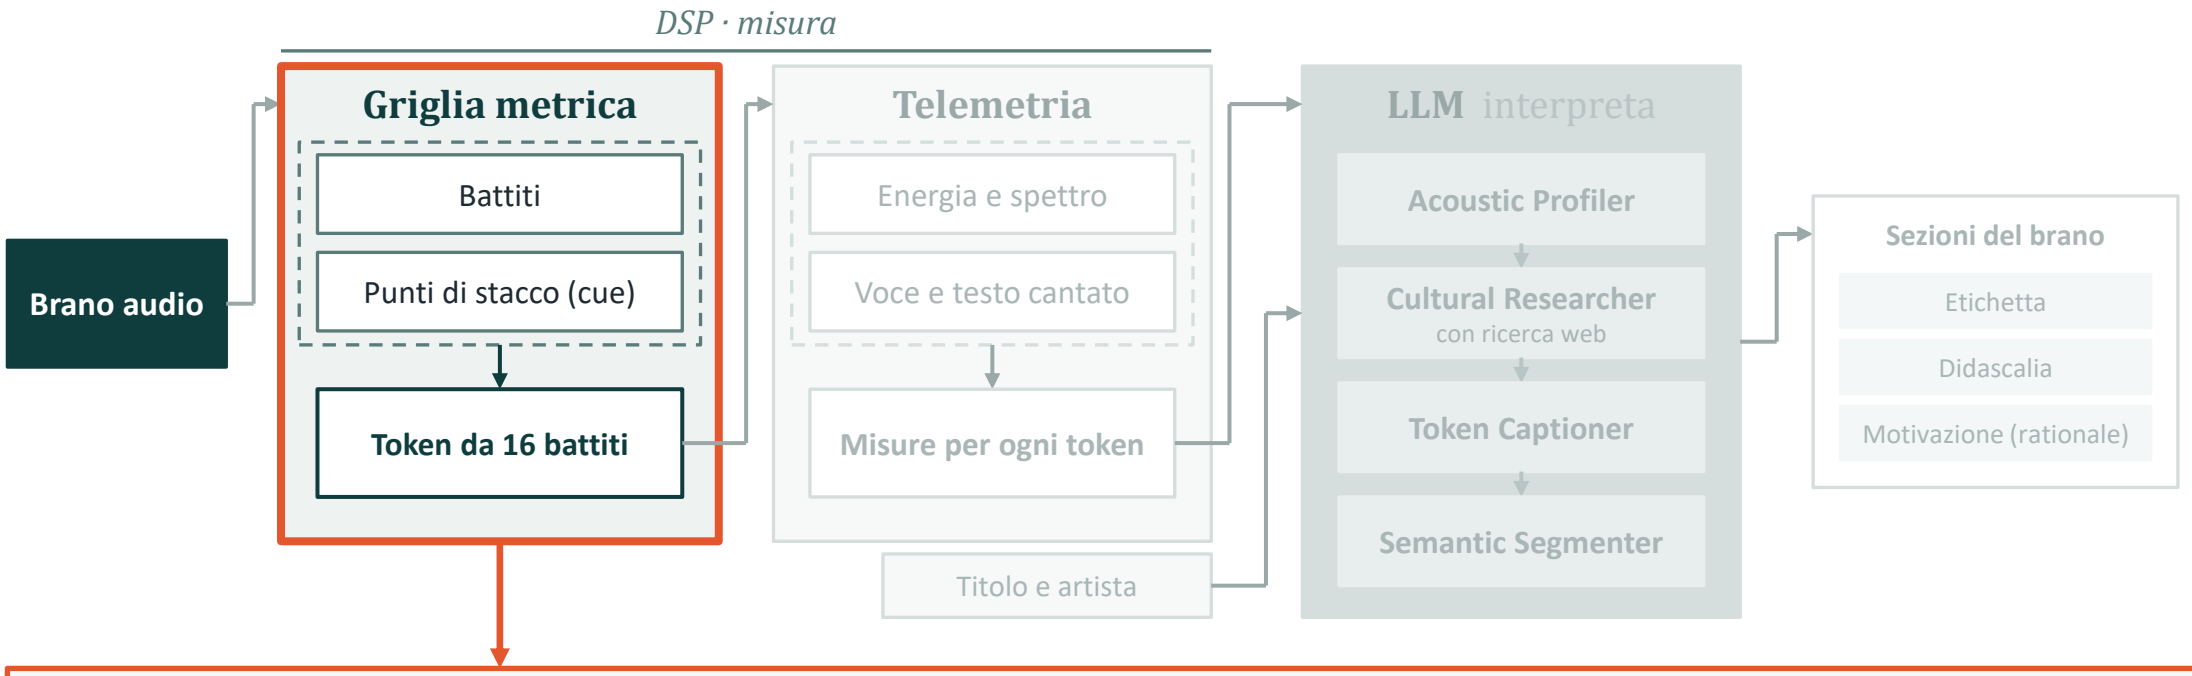
Didascalia Sezione energica e compatta: la voce è piena e l’intensità sale rispetto alla strofa.

Motivazione Energia e flusso spettrale in aumento, attività vocale alta e continua.

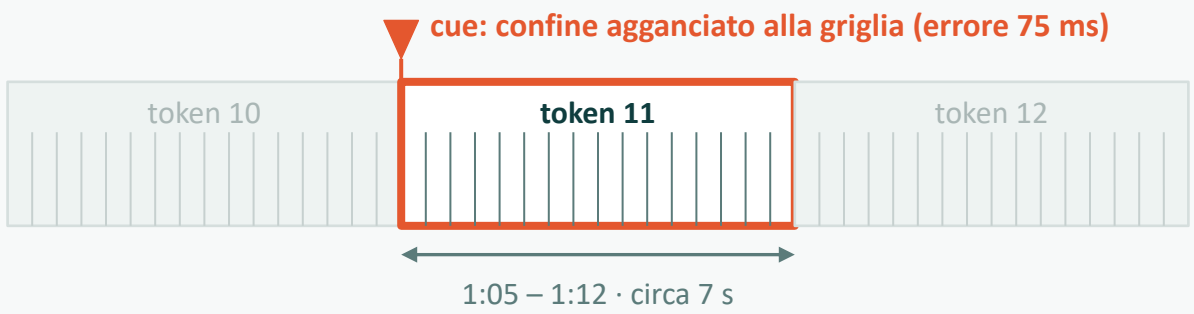
Architettura del sistema



Architettura del sistema



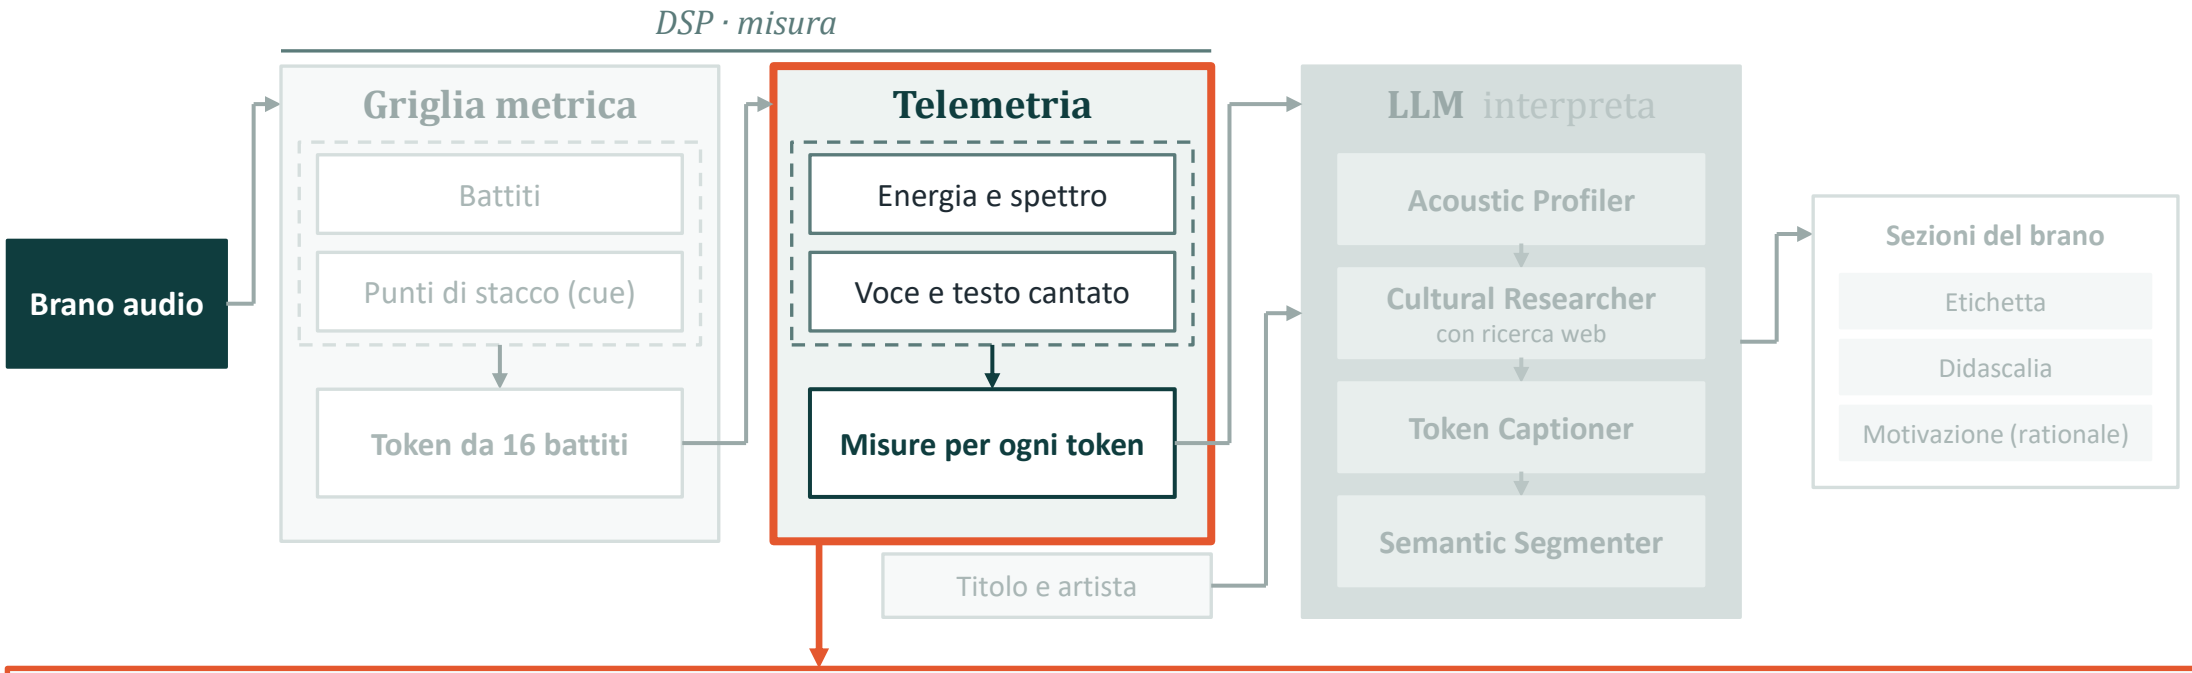
Il brano diventa una griglia di token da 16 battiti



Output effettivo · token 11 · confini sulla griglia


```
{
  "token_size_beats": 16,
  "index": 11,
  "start_time": "1:05", "end_time": "1:12",
  "start_cue": {
    "raw_cue_point": {
      "time_ms": 65085,
      "confidence_score": 0.929 },
    "snapped_time_ms": 65160,
    "displacement_error_ms": 75
  }
}
```

Architettura del sistema



Per ogni token, misure del segnale (token 11)

Energia ritmica (ROE)	0,81
Rapporto dei bassi (BTR)	0,86
Confidenza della voce	0,36
Densità della voce	0,24

valori da 0 a 1

BPM 128,7

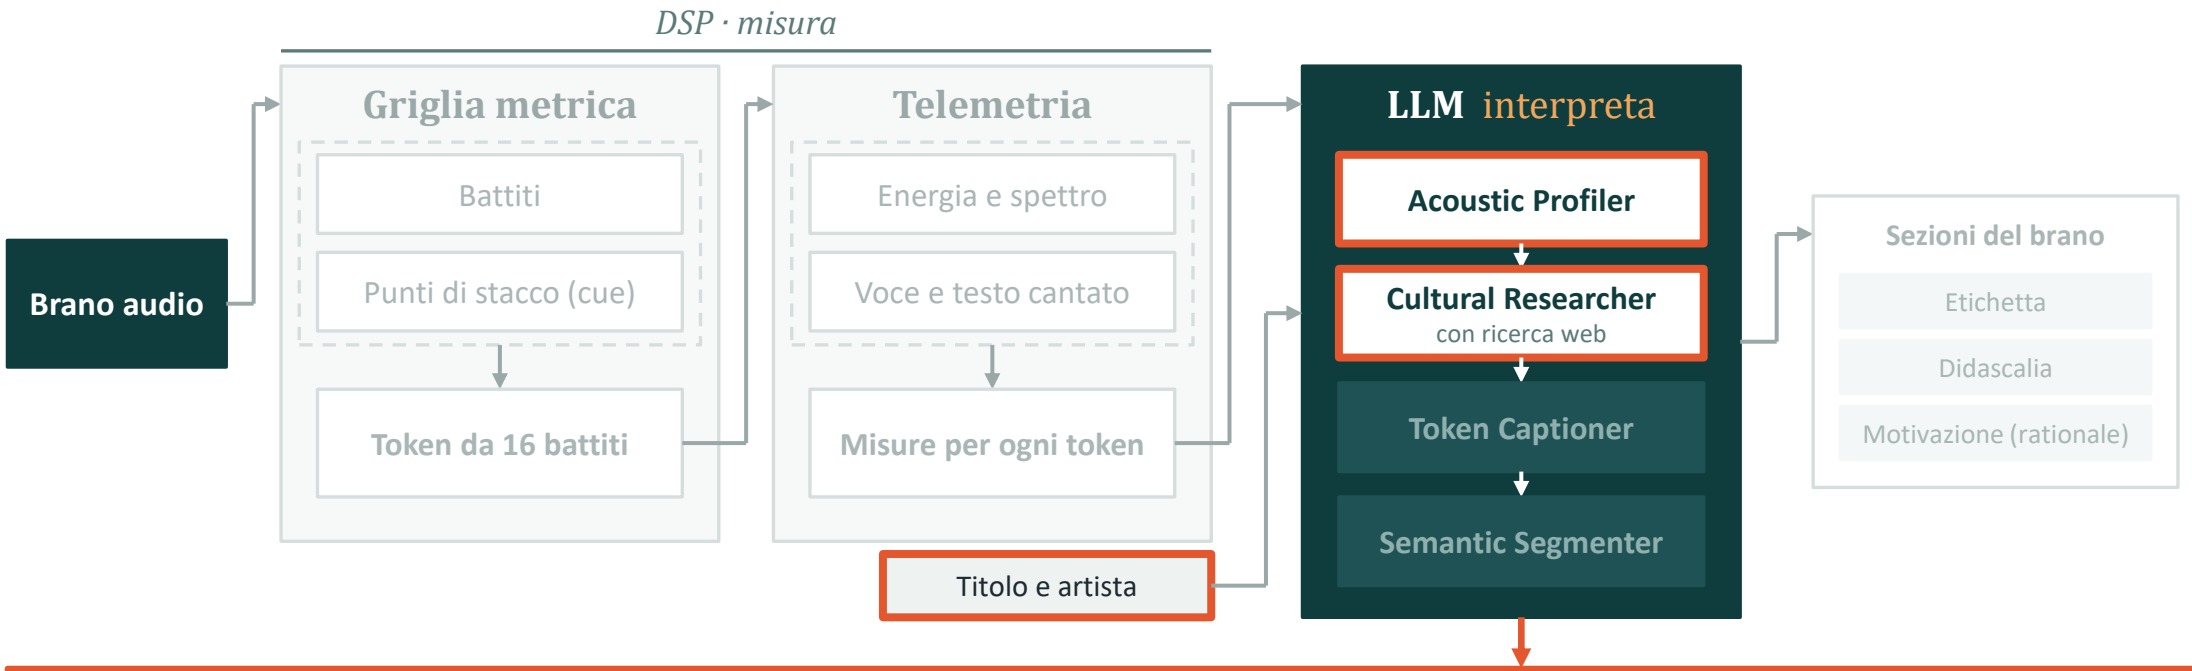
MSF 13,75

picco di energia spettrale

Output effettivo · token 11 · telemetria


```
{
  "index": 11,
  "start_time": "1:05", "end_time": "1:12",
  "dsp_features": {
    "BPM": 128.7, "ROE": 0.81,
    "BTR": 0.86, "MSF": 13.75,
    "SC": 0.18, "HER": 0.62, "OCN": 47,
    "vocal_features": {
      "intensity": -0.12, "confidence": 0.36,
      "density": 0.24 }
  }
}
```

Architettura del sistema



Profilo del brano e contesto culturale

Generi — **Electro House** · **Big Room EDM**

Energia — **Extreme**

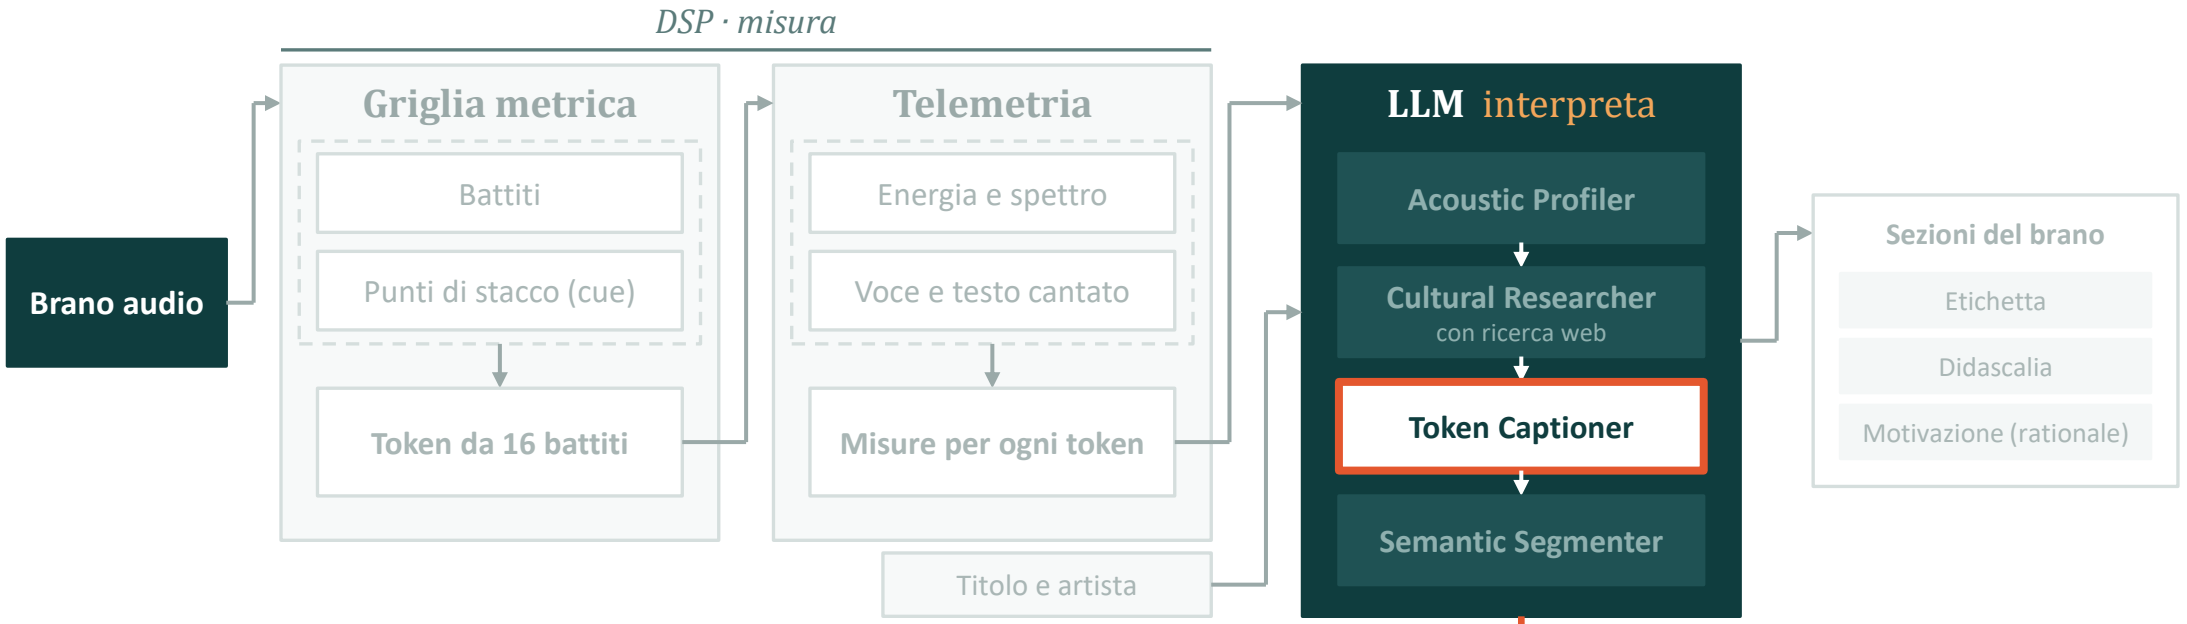
Brano — **David Guetta feat. Skylar Grey**

Generi ed energia: dalla telemetria. Brano: da titolo, artista e ricerca web.

Output effettivo · profilo e contesto culturale

```
{
  "macro_profile": {
    "inferred_genres": [
      "Electro House", "Big Room EDM"],
    "energy_tier": "Extreme"
  },
  "source_identity": {
    "identified_original_artist":
      "Cher (Original) / David Guetta
       feat. Skylar Grey"
  }
}
```

Architettura del sistema



Una didascalia per ogni token

token 11

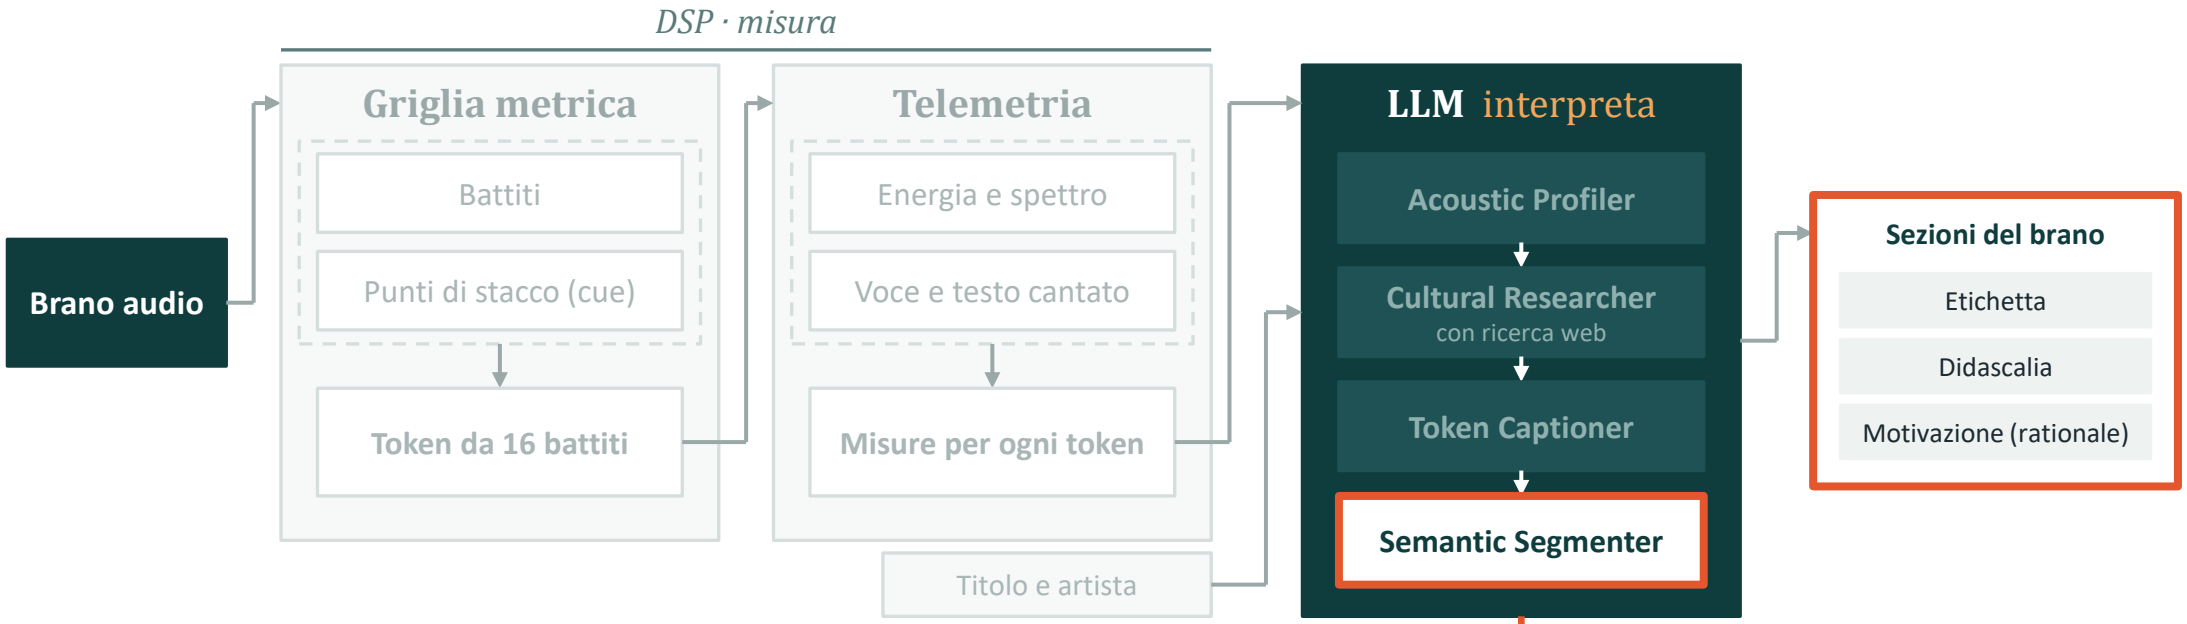
"A massive, distorted Big Room kick and aggressive synth lead detonate with overwhelming force."

MSF 13,75 **ROE 0,81** *misure citate nella motivazione*

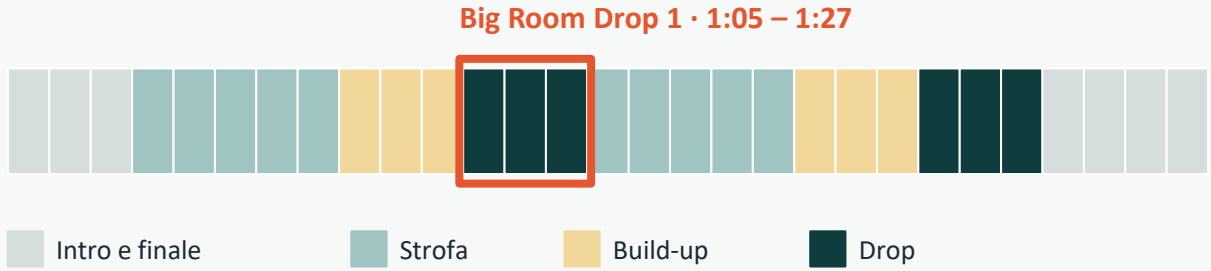
Output effettivo · token 11 · didascalia

```
{
  "index": 11,
  "captioning_data": {
    "caption": "A massive, distorted Big Room
      kick and aggressive synth lead detonate
      with overwhelming force.",
    "rationale": "The global peak in MSF (13.75)
      and extreme ROE (0.81) align perfectly
      with Guetta's signature …"
  }
}
```

Architettura del sistema



29 token raggruppati in 8 sezioni

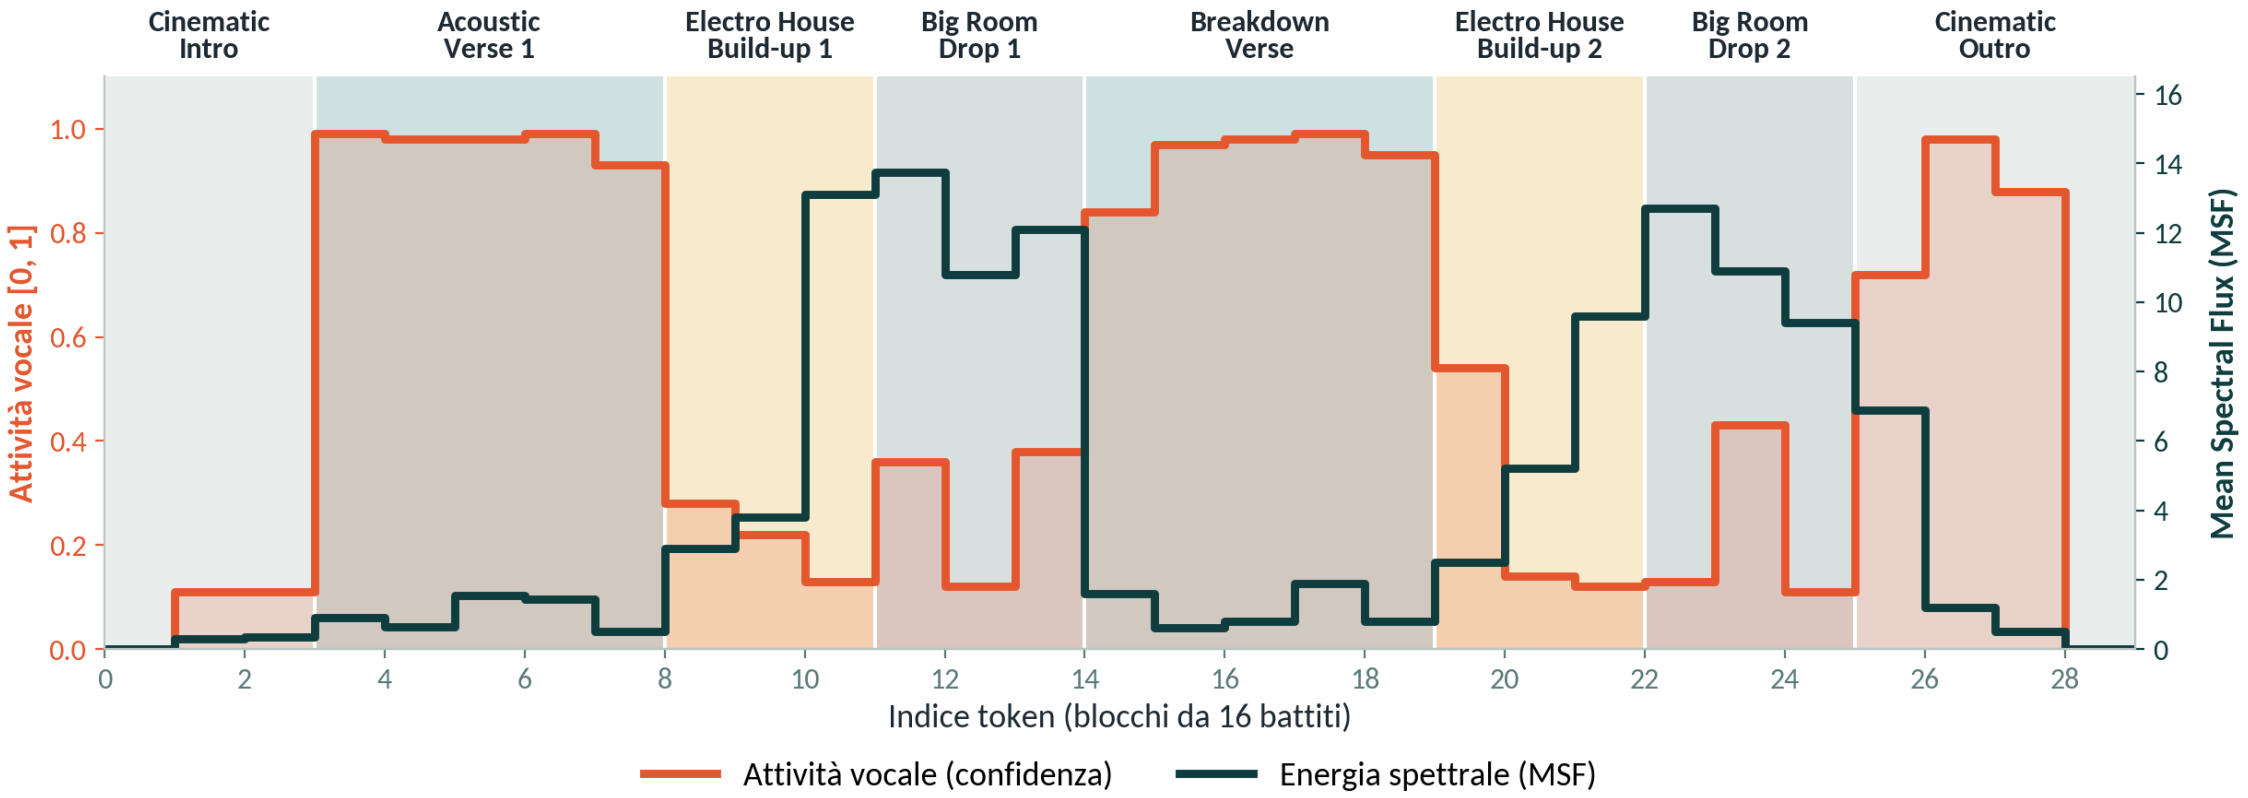


Output effettivo · segmento 3 · sezione

```
{
  "index": 3,
  "name": "Big Room Drop 1",
  "start_time": "1:05",
  "end_time": "1:27",
  "macro_caption": "A massive, distorted Big Room
    kick and aggressive synth lead detonate
    with overwhelming force. …",
  "rationale": "Token 11 marks the explosive peak of
    the track's kinetic energy
    (MSF peaks at 13.75). …"
}
```

Esempio qualitativo

Shot Me Down (David Guetta feat. Skylar Grey): strofe acustiche cantate alternate a drop elettronici



Domande di ricerca

RQ1 · STRUTTURA

Quanto ci avviciniamo a un modello supervisionato?

- **Accuratezza strutturale** → quanto bene il sistema divide il brano in sezioni e le etichetta, senza alcun addestramento sul compito
- **Confronto** → con altri modelli e con lo stesso modello senza DSP, che ascolta l'audio diretto

RQ2 · SEMANTICA

Le didascalie sono legate all'audio della loro sezione?

- **Ancoraggio semantico** → la didascalia descrive davvero quel pezzo di musica, non un brano qualunque

Baseline e Dataset

RQ1

ACCURATEZZA STRUTTURALE

SongFormer *

- Stato dell'arte supervisionato per la segmentazione
- Restituisce solo un'etichetta funzionale per sezione

RQ2

ANCORAGGIO SEMANTICO

FUTGA *

- Segmenti e didascalia per ogni segmento
- Non nasce per la segmentazione: confini come percentuali nel testo
- Unica baseline con pesi aperti confrontabile

DATASET

SongFormBench-HS *

- 50 brani di generi diversi
- Struttura annotata da esperti
- Nessun testo di riferimento per le didascalie dei segmenti

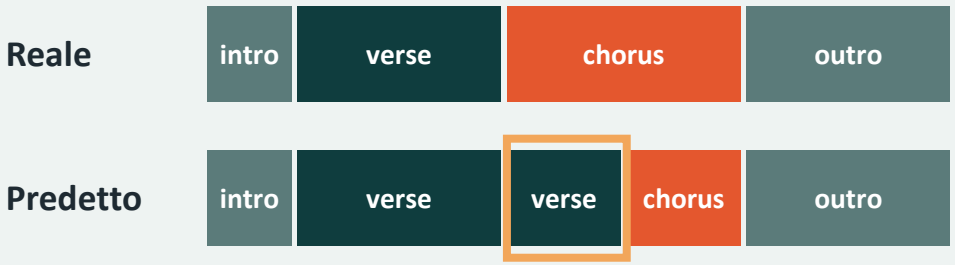
* SongFormer: Hao et al., 2026 · FUTGA: Wu et al., 2024 · SongFormBench-HS: Hao et al., 2026

RQ1 Metriche strutturali

ACC · ETICHETTE

Quanto sono giuste le etichette?

- **Frame per frame**: percentuale di istanti (circa 0,12 s) con l'etichetta funzionale corretta, su 7 categorie standard

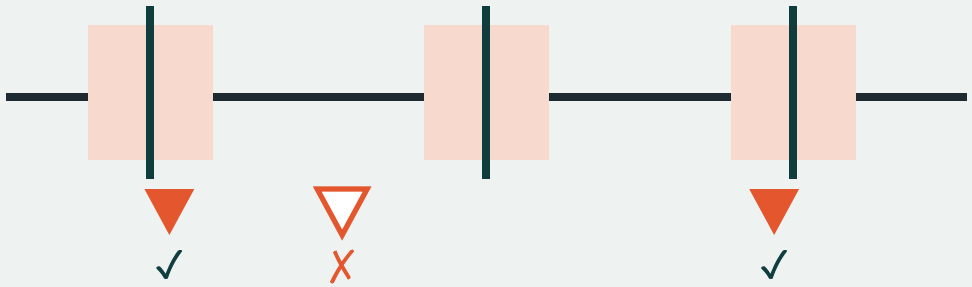


In arancione: frame con etichetta sbagliata

HR3F · HR.5F · CONFINI

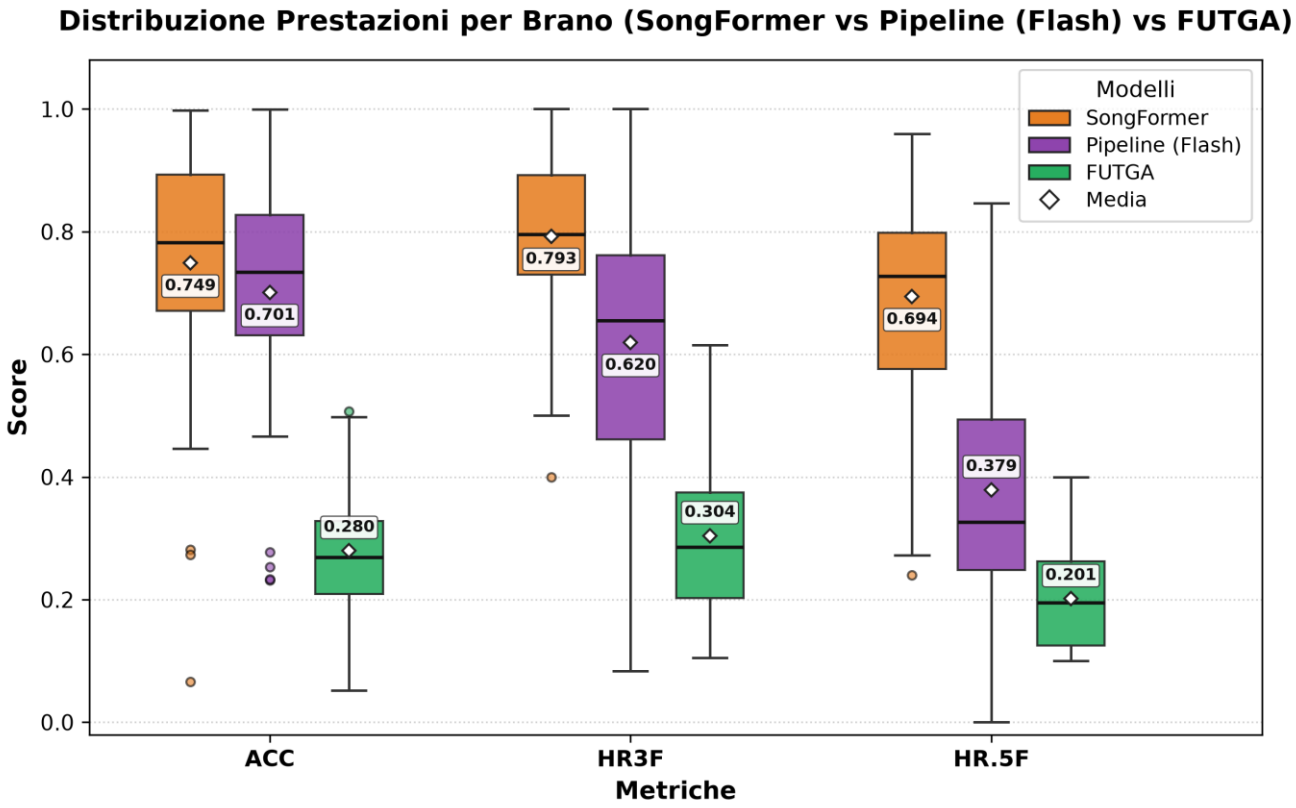
Quanto sono precisi i confini?

- **Hit rate**: un confine predetto è corretto se cade entro una tolleranza da uno reale; si riporta la F-measure (precision e recall insieme)
- **HR.5F** ±0,5 s, severa · **HR3F** ±3 s, tollerante



Linee scure: confini reali con tolleranza · triangoli: predetti

RQ1 Accuratezza strutturale



ACC: % del brano con etichetta corretta.
HR3F / HR.5F: % di confini individuati entro 3 s / 0,5 s da quelli corretti.

ACCURACY

- −4,8 punti da SongFormer, senza addestramento
- Le scatole dei due sistemi si sovrappongono
- Media abbassata da pochi brani, in entrambi
- In 17 brani su 50 la pipeline vince

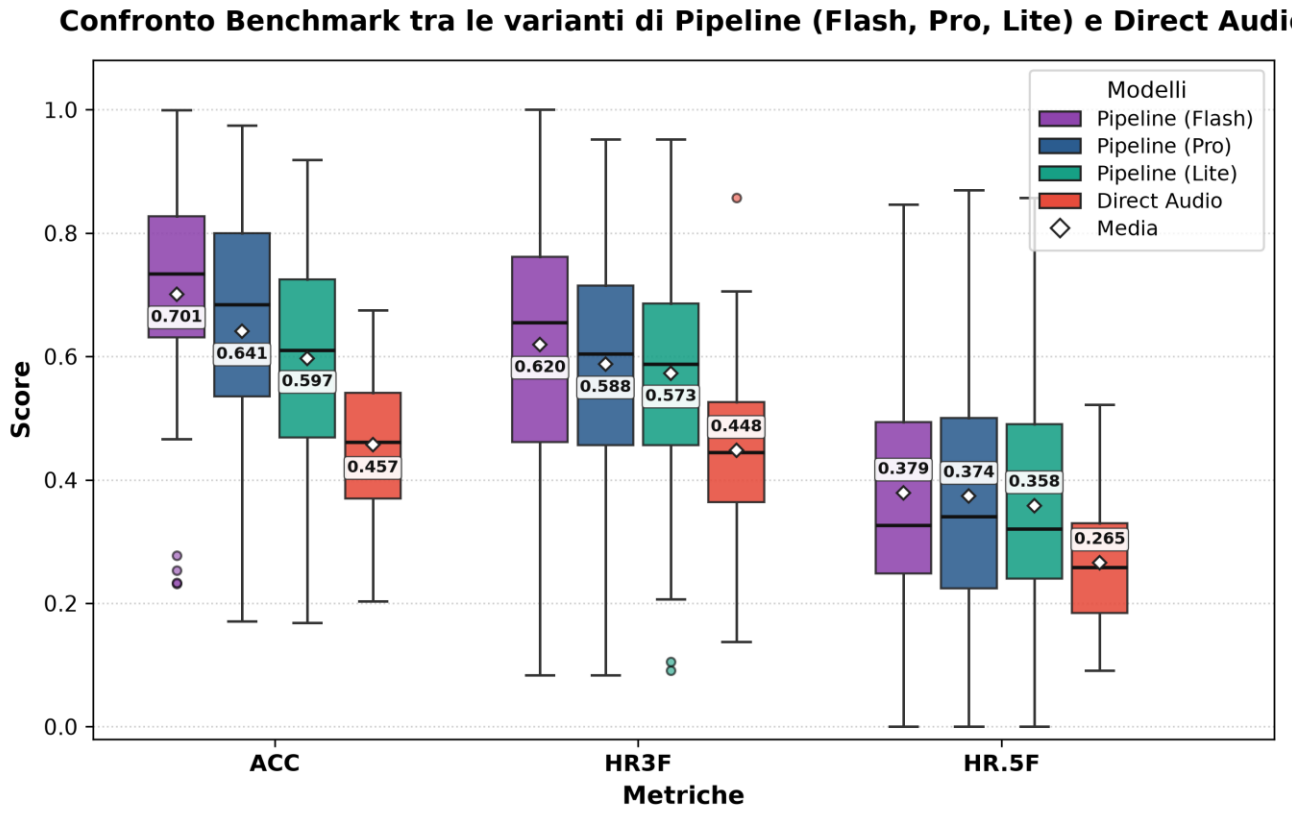
HIT RATE F-MEASURES

- Divario più marcato, soprattutto a ±0,5 s
- Limite della griglia a 16 battiti, non del LLM

FUTGA

- Sottosegmenta: 3 segmenti per brano contro 11 reali

RQ1 Varianti del modello e audio diretto



Flash: Gemini 3.8 Flash · Pro: Gemini 3.1 Pro · Lite: Gemini 3.5 Flash Lite

MODELLO LINGUISTICO

- Flash supera Pro: +6,0 punti di ACC
- Lite, gratuito, è a 4,7 punti da Flash sull'HR3F

CONFINI A ±0,5 s

- Bassi e quasi uguali con tutti i modelli

AUDIO DIRETTO, STESSO MODELLO (LITE)

- ACC da 0,597 a 0,457 senza il DSP
- Tempi incoerenti in 21 brani su 50

RQ2 Approccio alla valutazione semantica

PROBLEMA

Nessun testo di riferimento

- Nessuna didascalia annotata da esperti per le sezioni
- Si misura quindi la coerenza con l'audio

STRUMENTO

CLAP *

- Modello che porta audio e testo nello stesso spazio
- Si confrontano con la similarità del coseno
- Per ogni segmento audio le didascalie si ordinano dalla più vicina alla meno vicina

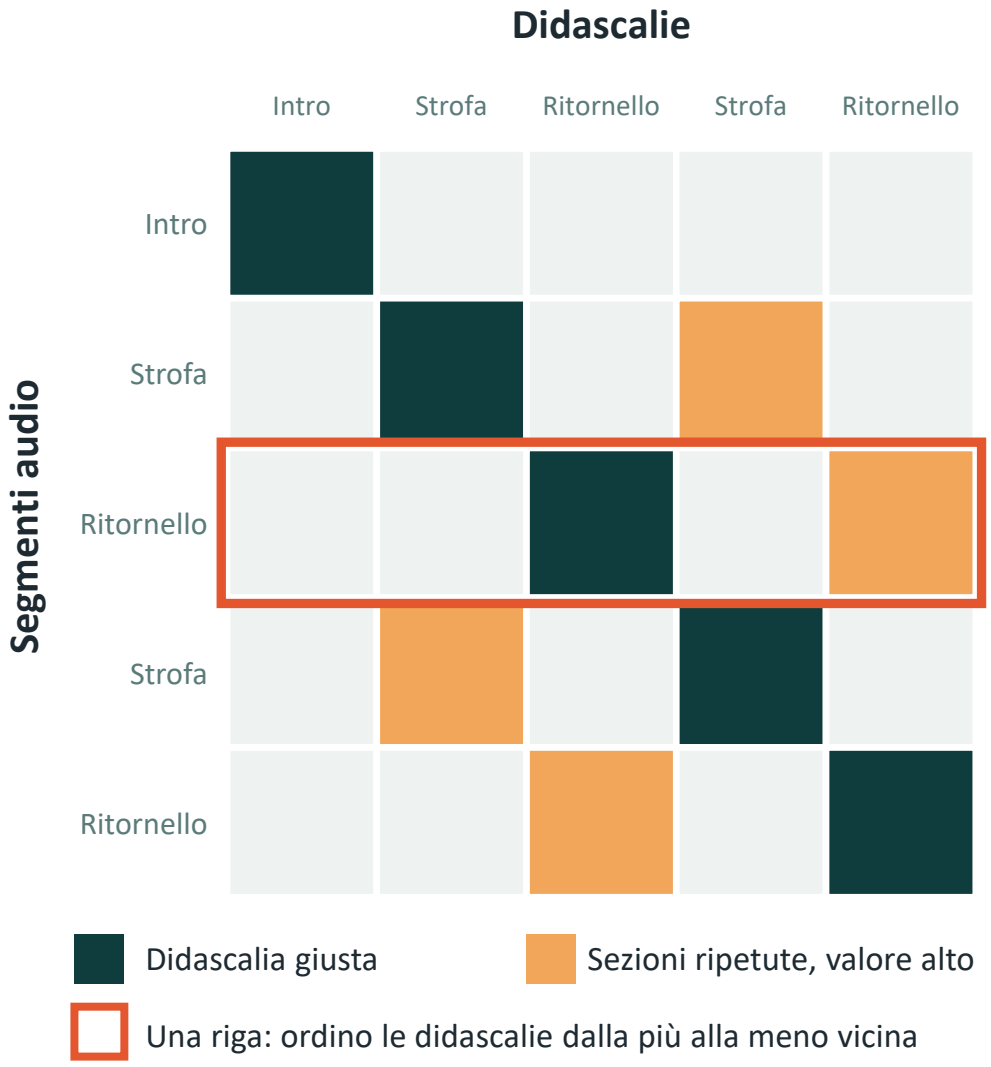
LE METRICHE

Top-1 e MRR

- **Top-1**: la didascalia giusta è la prima della classifica
- **MRR**: premia anche le posizioni vicine, ma meno
- Contano i guadagni rispetto al caso

* CLAP: Wu et al., 2023

RQ2 Coerenza semantica interna



IL TEST

- Coseno tra audio di ogni segmento e ogni didascalia
- Diagonale: la didascalia giusta per quel segmento

RISULTATO (MEDIE SUI 50 BRANI)

- MRR sopra il caso: +31% (+0,085); FUTGA +4% (+0,022)
- Top-1 sopra il caso: +82% (+0,075); FUTGA +10% (+0,033)
- In assoluto il Top-1 resta basso: 16,6% (caso 9,1%)

LIMITE

- La musica si ripete: sezioni uguali si assomigliano
- CLAP ha un vocabolario piatto

Conclusioni

RQ1 · STRUTTURA

Vicini sull'etichetta, lontani sui confini

- ACC a 4,8 punti da SongFormer, senza addestramento
- Sui confini stretti il divario resta ampio

RQ2 · ANCORAGGIO

Modesto, ma osservabile

- Sopra il caso, in modo significativo
- Sopra FUTGA su MRR e Top-1

CONTRIBUTO

Tra i due approcci

- Vicini al supervisionato sulle etichette, senza addestramento
- Sopra la baseline generativa sull'ancoraggio semantico
- Interpretabile: ogni scelta ha una motivazione

Limiti e sviluppi futuri

LIMITE	SVILUPPO
Confini imprecisi Token da circa 7 s, non dipende dal modello	→ **Griglia più fine o altri *beat tracker***
Sordità al timbro La telemetria non misura gli strumenti	→ **Modulo di *tagging* acustico per timbro e strumenti**
Mancanza di annotazioni a livello di segmento	→ **Creazione di un dataset annotato a livello di segmento e valutazione delle didascalie con umani**

GRAZIE PER L’ATTENZIONE

Domande

Analisi strutturale e music captioning a livello di segmento

Tesi e repository

github.com/ApuMbett