

UNIVERSITÀ
DEGLI STUDI DI BARI
ALDO MORO

DIPARTIMENTO DI INFORMATICA

CORSO DI LAUREA IN INFORMATICA

TESI DI LAUREA
IN
METODI PER IL RITROVAMENTO DELL'INFORMAZIONE

Analisi Strutturale e Music Captioning a Livello di Segmento: un approccio ibrido DSP + LLM

RELATORI:
Prof. Pasquale Lops
Prof. Cataldo Musto

LAUREANDO:
Paolo Lamanna

ANNO ACCADEMICO 2025 - 2026

"Che esista un altro mondo,
io non ne dubito.
Basta credere agli occhi,
credere agli occhi,
anche quando si chiudono"
— Lucio Corsi, Un Altro Mondo

Dedico questo lavoro a me stesso,

a chi c'è, a chi c'è stato e a chi non c'è più.

Indice

1 Introduzione 1
- 1.1 Contesto e Motivazione: Music Information Retrieval e Comprensione Semantica . . . 1
- 1.2 Posizionamento . . . 3
- 1.3 Il Sistema Proposto e l'Approccio Interpretabile . . . 4
- 1.4 Domande di Ricerca e Contributi . . . 6
- 1.5 Struttura dell'Elaborato . . . 7

2 Quadro Teorico e Stato dell'Arte 9
- 2.1 Le Tecniche di Estrazione Telemetrica . . . 9
  - 2.1.1 Beat Tracking e Stima del Tempo . . . 9
  - 2.1.2 Individuazione dei Cue Point . . . 10
  - 2.1.3 Onset Detection e Descrittori Spettrali Classici . . . 11
  - 2.1.4 Separazione delle Sorgenti . . . 11
  - 2.1.5 Stima della Tonalità . . . 12
  - 2.1.6 Trascrizione del Testo Cantato . . . 12
- 2.2 Stato dell'Arte della Segmentazione Strutturale Supervisionata . . . 14
- 2.3 Lo Stato dell'Arte: I Modelli End-to-End e i loro Limiti . . . 15
  - 2.3.1 Rappresentazioni Contrastive Audio-Testo: da CLIP a CLAP 16
  - 2.3.2 Le Origini End-to-End e il Limite del Chunking Rigido . . . 17
  - 2.3.3 La Sfida Long-Form e la Cecità Temporale . . . 19
  - 2.3.4 Ragionamento Complesso e Allucinazioni a Cascata . . . 20
  - 2.3.5 L'Approccio Disaccoppiato a Due Stadi . . . 21
- 2.4 Paradigma Ibrido DSP+LLM vs LALM End-to-End . . . 22
  - 2.4.1 Precisione Temporale . . . 22
  - 2.4.2 Cecità alle Feature Acustiche di Basso Livello . . . 23
  - 2.4.3 Interpretabilità e Dipendenza dal Testo . . . 24

3 Sviluppo dell'architettura 25
- 3.1 Beat Grid e Cue Point . . . 26
  - 3.1.1 Rappresentazione a Token del Segnale Audio . . . 27

3.1.2 Allineamento dei *cue points* alla *beat grid* 28
3.2 Estrazione della Telemetria tramite DSP 30
3.2.1 Feature DSP estratte 31
3.2.2 Estrazione e Mappatura del Testo 34
3.2.3 Estrazione delle Feature Vocali (Custom *VAD*) 38
3.3 Architettura Multi-Agente 46
3.3.1 Acoustic Profiler 47
3.3.2 Cultural Researcher 48
3.3.3 Token Captioner 49
3.3.4 Semantic Segmenter 50
3.3.5 Sintesi Comparativa della Modellazione Telemetrica 51
3.3.6 Sintesi Deterministica 53
3.4 Limiti e Sviluppi Futuri 54

4 Valutazione Sperimentale 57
4.1 Dataset e Partizionamento dei Dati 58
4.1.1 Dataset di Riferimento: SongFormBench-HS 58
4.1.2 Partizionamento e Stratificazione per Domini 58
4.2 Baselines di Riferimento 59
4.2.1 Impostazione del Confronto 59
4.2.2 Baseline per l'Accuratezza Strutturale 60
4.2.3 Baseline per l'Accuratezza Semantica e il Music Captioning . 60
4.2.4 Sistemi non Confrontati 61
4.2.5 Esecuzione delle Baseline 61
4.3 Generazione dei Dati di Inferenza 61
4.3.1 Esecuzione di SongFormer 62
4.3.2 Esecuzione di FUTGA 62
4.3.3 Esecuzione della Pipeline Proposta e dei Modelli nei Test . . 64
4.4 Valutazione dell'Accuratezza Strutturale (RQ1) 65
4.4.1 Setup Sperimentale e Baseline 65
4.4.2 Metriche di Valutazione 66
4.4.3 Confronto Globale con lo Stato dell'Arte 68
4.4.4 Risoluzione Temporale e Costo della Griglia a 16 Battiti . . 69
4.4.5 Confronto tra le Varianti della Pipeline 70
4.4.6 Pipeline contro Input Audio Diretto 72
4.4.7 Resilienza al *Domain Shift* 74
4.4.8 Diagnostica per Classe Funzionale 76
4.4.9 Struttura contro Etichetta: Casi Limite 77
4.4.10 Conclusioni sulla Valutazione Strutturale 79
4.5 Valutazione dell'Accuratezza Semantica 80
4.5.1 Coerenza Interna e Risoluzione Semantica 80
4.5.2 *Mode Collapse* e *Repetition Penalty* 82

4.5.3 Matrice di Similarità e Metriche 83
4.5.4 Coerenza Intra-Brano 87
4.5.5 Recupero *Many-to-Many* tra Brani 87
4.5.6 *Semantic Class Agreement* 90
4.5.7 Conclusioni sulla Valutazione Semantica 91
4.6 Limiti e Discussione 92
4.6.1 Limiti dei Moduli DSP 92
4.6.2 Limiti di Protocollo e di Dati 93
4.6.3 Dipendenza da Modelli Linguistici Proprietari 93
4.7 Sviluppi Futuri della Valutazione 94

5 Conclusioni 95

Bibliografia 97

Capitolo 1

Introduzione

1.1 Contesto e Motivazione: Music Information Retrieval e Comprensione Semantica

Il *Music Information Retrieval* (MIR) è l'area di ricerca che si occupa dell'analisi computazionale, dell'estrazione di informazioni e dell'organizzazione automatica di dati musicali e segnali audio complessi [1]. Fin dalle sue origini, la disciplina ha affrontato sia compiti percettivi puntuali sia l'analisi dell'evoluzione temporale del segnale, sviluppando metodologie fondate sul *Digital Signal Processing* (DSP) e sull'apprendimento automatico. Tra i compiti classici rientrano la stima del tempo metronomico, il tracciamento dei battiti e dei movimenti della battuta (*beat and downbeat tracking*), il riconoscimento degli accordi, la stima delle altezze e l'individuazione di punti di svolta tramite funzioni di novità spettrale [2], fino alla modellazione della struttura formale dei brani. Sebbene questi metodi abbiano definito le basi analitiche per l'elaborazione del segnale sonoro, l'output rimane tradizionalmente limitato all'assegnazione di etichette discrete o valori numerici predefiniti, senza produrre alcuna articolazione descrittiva in linguaggio naturale.

In questo quadro si colloca la *Music Structure Analysis* (MSA), uno dei compiti analitici più consolidati della disciplina [3]. L'obiettivo della MSA è decomporre una traccia audio continua in sezioni strutturali mutuamente esclusive e temporalmente coerenti, corrispondenti alle parti canoniche della forma musicale quali introduzione, strofa, ritornello, ponte o coda. L'identificazione dei confini temporali e la classificazione funzionale permettono di formalizzare l'architettura del brano, riducendo la complessità del flusso sonoro a una sequenza ordinata di blocchi omogenei. Tuttavia, i metodi tradizionali di MSA categorizzano i segmenti all'interno di tassonomie simboliche chiuse, senza catturare le variazioni timbriche,

l'evoluzione della densità energetica, il contenuto testuale o i tratti stilistici che distinguono un passaggio musicale da un altro.

Negli ultimi anni, la crescente convergenza tra MIR ed elaborazione del linguaggio naturale (NLP) ha favorito la nascita del *Music Captioning* [4, 5]. Questo paradigma supera la rigidità delle etichette predeterminate per generare descrizioni in linguaggio naturale incentrate sull'orchestrazione, la dinamica energetica e l'atmosfera lungo lo sviluppo temporale della traccia [6]. L'obiettivo non è più una classificazione rigida, ma la produzione di sintesi semantiche dense e direttamente fruibili dall'utente, capaci di esprimere la complessità acustica del brano.

L'unione tra segmentazione strutturale e descrizione semantica risponde a molteplici requisiti applicativi. Nel campo del recupero cross-modale (*Cross-Modal Music Retrieval*) [7], l'accesso a descrizioni dettagliate consente di superare la tradizionale ricerca per metadati globali, aprendo la strada all'indicizzazione e al recupero mirato a livello di singolo segmento formale (*Segment-level Retrieval*) per compiti di sonorizzazione o sincronizzazione video. Inoltre, l'analisi congiunta di parametri fisici e semantici offre una solida base per la catalogazione scalabile di archivi sonori e per applicazioni di mixaggio assistito (*DJ mixing*). In questo contesto, disporre di sezioni descritte per energia acustica e profilo timbrico permette di pianificare transizioni musicalmente coerenti, superando i limiti del semplice allineamento ritmico (*beat-matching*) tipico dei software convenzionali.

Tuttavia, l'applicazione di modelli linguistici al dominio musicale deve confrontarsi con il cosiddetto *semantic gap*, ovvero il profondo divario tra le caratteristiche fisiche di basso livello estratte dal segnale acustico e le rappresentazioni concettuali di alto livello espresse dal linguaggio umano [8]. Mentre il testo è composto da sequenze di simboli discreti e ordinati, una traccia audio è un segnale continuo e polifonico in cui strumenti, frequenze e dinamiche si sovrappongono nello stesso momento.

Descrivere un brano non equivale quindi a una semplice traduzione diretta da segnale a testo. Per consentire a un modello linguistico di interpretare la musica riducendo il rischio di allucinazioni, occorre prima suddividere la traccia in blocchi temporali coerenti e vincolare la generazione a parametri fisici estratti in modo oggettivo dal segnale. Questo ancoraggio permette di produrre descrizioni verificabili e saldamente collegate all'evoluzione acustica del brano. Su queste premesse si sviluppa l'architettura proposta nel presente lavoro.

1.2 Posizionamento

L'obiettivo metodologico del presente elaborato è definire un approccio all'analisi strutturale della musica che sia spiegabile e vincolato ai dati fisici del segnale. Il sistema proposto affronta i limiti di due diverse famiglie di approcci presenti in letteratura. I modelli supervisionati specializzati nell'analisi della struttura musicale, come SongFormer [9], individuano i confini temporali con precisione sub-secondo, ma si limitano a poche etichette funzionali prefissate, senza fornire spiegazioni causali o descrizioni testuali dei segmenti. All'estremo opposto, i modelli generativi audio-linguaggio producono descrizioni narrative articolate. Tra questi, FUTGA [6] costituisce l'unico sistema aperto e direttamente comparabile presente in letteratura, essendo progettato per fornire congiuntamente partizioni temporali e didascalie per ciascun segmento. Tale modello è stato addestrato tramite concatenazioni sintetiche di brevi frammenti da dieci secondi, per poi essere raffinato su registrazioni reali del dataset HarmonixSet corredate da didascalie validate da annotatori umani. Tuttavia, l'analisi empirica condotta in questo lavoro evidenzia come FUTGA produca una segmentazione eccessivamente grossolana, limitandosi in media a 3.04 segmenti per brano a fronte degli 11.40 delle annotazioni di riferimento nel corpus di valutazione, senza catturare le articolazioni interne della forma canzone.

A questo proposito, una prima alternativa potrebbe consistere nell'unire i due sistemi in cascata, demandando a SongFormer l'estrazione dei confini e a un modello generativo la produzione delle didascalie. Tuttavia, i due moduli opererebbero in modo disgiunto, con la conseguenza che la didascalia non avrebbe un legame verificabile con le caratteristiche fisiche che hanno determinato il taglio temporale, rendendo difficile controllare la presenza di allucinazioni nel testo.

Una seconda questione riguarda la possibilità di affidare l'intero processo a un modello multimodale generalista che riceve direttamente l'audio grezzo. A questo riguardo emergono due problemi principali. Il primo riguarda la verificabilità e la tracciabilità delle decisioni, poiché una descrizione generata direttamente dalla forma d'onda da un modello a scatola chiusa non può essere controllata senza riascoltare l'intero brano. Nell'approccio proposto, invece, ogni passaggio logico è giustificato da misure fisiche quali tempo metronomico, variazioni di energia, salti timbrici e attività vocale, a cui si affianca, per il solo inquadramento stilistico e culturale del brano, l'informazione esterna ricavata da titolo e artista. Il secondo riguarda la robustezza temporale. Negli esperimenti condotti in questo lavoro con un modello generalista alimentato ad audio grezzo, sono emerse frequenti anomalie nella gestione della linea temporale, tra cui derive cumulative di durata, intervalli con estremi invertiti e cambi di notazione temporale a metà traccia. Difficoltà nella precisione temporale su audio di lunga durata sono del resto documentate anche in letteratura per i *Large Audio-Language Models* in generale [10]. Esistono architetture audio-linguaggio addestrate specificamente sul dominio musicale,

ma le più recenti (FUTGA-MIR, Bukey et al.) non ne rendono pubblici i pesi. Music Flamingo [11], i cui pesi sono stati resi disponibili successivamente all'avvio di questo lavoro, non produce nativamente una segmentazione con didascalia per sezione e non è quindi direttamente comparabile sul compito di questa tesi. I riferimenti praticabili per un confronto riproducibile restano quindi FUTGA e i modelli generalisti di frontiera. Al contrario, operare su *token* discreti allineati ai battiti musicali garantisce per costruzione la contiguità temporale, la copertura completa del brano e, nei brani a metro regolare, il rispetto della fraseologia musicale.

1.3 Il Sistema Proposto e l'Approccio Interpretabile

Per affrontare il divario tra segnale acustico continuo e rappresentazione strutturata senza ricorrere a modelli a scatola chiusa, l'architettura proposta adotta una *pipeline* modulare basata su un approccio interpretabile. La premessa fondamentale consiste nel separare l'estrazione delle proprietà acustiche dalla generazione delle descrizioni semantiche. Il modello linguistico non elabora l'onda sonora, ma riceve una rappresentazione intermedia formata da parametri fisici calcolati dal segnale, partizioni allineate alla metrica e testo cantato.

A livello metodologico, il sistema riprende il paradigma *Audio-to-Metadata-to-Caption* formulato da Bukey et al. [12], sviluppandolo in chiave *zero-shot*. Anziché addestrare una rete neurale per stimare i metadati, un motore DSP calcola direttamente grandezze fisiche quali tempo metronomico, profilo energetico RMS, centroidi spettrali e attività vocale, appoggiandosi, dove necessario, a componenti pre-addestrati di uso generale (ad esempio per il tracciamento dei battiti e la separazione delle sorgenti) impiegati senza alcun addestramento sul compito. Questa scelta limita il rischio di allucinazioni sulle caratteristiche fisiche del brano, pur implicando che eventuali errori di misura del DSP si propaghino alle fasi successive. La discretizzazione temporale si basa su token da sedici battiti, pari a quattro battute in un metro standard in quattro quarti. A differenza delle finestre temporali rigide a durata fissa usate in modelli come SonicVerse [13], i token risultano sincronizzati con la scansione metrica. A tali descrittori acustici si affianca la trascrizione temporizzata del testo cantato ottenuta tramite WhisperX [14].

Le informazioni estratte per ciascun token vengono elaborate da una sequenza di quattro agenti linguistici specializzati, illustrata nello schema di Figura 1.1. L'Acoustic Profiler e il Cultural Researcher, quest'ultimo guidato dai metadati esterni di titolo e artista, definiscono il profilo stilistico e il contesto culturale della traccia. Il Token Captioner genera una descrizione per ciascun token, mentre il Semantic Segmenter raggruppa i blocchi contigui nelle sezioni strutturali del brano, assegnando a ciascuna un'etichetta funzionale e una didascalia complessiva.

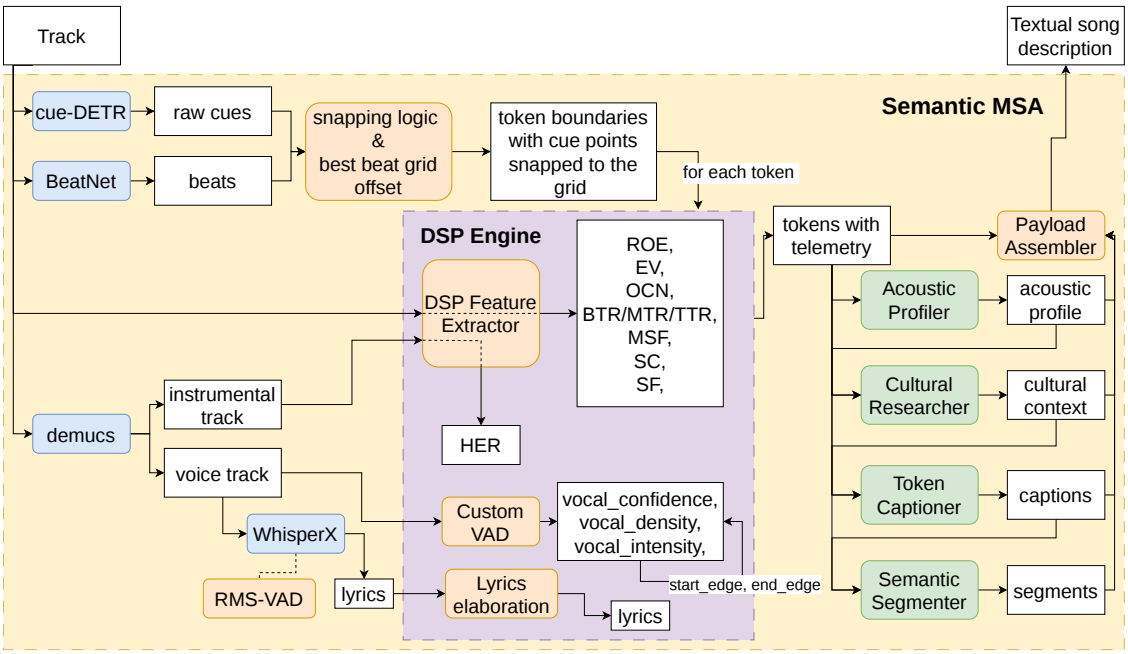


Figura 1.1: Diagramma generale dell'architettura proposta

Un elemento cardine del sistema è l'obbligo per ciascun agente di produrre un *Rationale*, ossia una giustificazione esplicita che ancora le scelte lessicali e strutturali ai valori telemetrici o alle righe del testo cantato. Questo meccanismo rende le decisioni tracciabili e verificabili. L'assunzione di un metro in quattro quarti costituisce un limite strutturale per brani con metriche irregolari. Rispetto ai modelli supervisionati dedicati che operano con precisione temporale sub-secondo, il sistema proposto privilegia la stabilità formale e la spiegabilità del partizionamento, affidando la scelta dei confini al Semantic Segmenter sulla griglia determinata dal DSP.

1.4 Domande di Ricerca e Contributi

Sulla base delle considerazioni teoriche e metodologiche illustrate, vengono definite due domande di ricerca che guidano la valutazione sperimentale dell'elaborato.

La prima domanda (RQ1, inerente all'accuratezza strutturale) indaga in che misura l'approccio proposto riesca ad avvicinarsi alle prestazioni di modelli supervisionati dedicati nel partizionamento e nell'etichettatura senza un addestramento specifico sul task, confrontandosi al contempo con i modelli generativi ad audio grezzo.

La seconda domanda (RQ2, incentrata su ancoraggio e risoluzione semantica) esamina se le didascalie generate a livello di singolo segmento siano effettivamente legate al contenuto audio locale anziché costituire testi generici, e come si confrontino con quelle di un modello generativo di riferimento, analizzandone la coerenza nello spazio latente multimodale e nel recupero cross-modale.

A fronte di tali quesiti, i contributi principali del presente lavoro si articolano in tre aspetti fondamentali.

In primo luogo, si definisce un'architettura modulare fondata su token da sedici battiti, telemetria DSP deterministica e trascrizione del testo, organizzata in una pipeline multi-agente in cui ogni passaggio decisionale è vincolato a una spiegazione esplicita basata sui dati fisici, sul testo cantato e, per il solo contesto culturale, sull'informazione esterna di titolo e artista. La discretizzazione metrica garantisce per costruzione una copertura contigua e completa del brano, rendendo ogni scelta di partizione e di etichettatura pienamente tracciabile e verificabile.

In secondo luogo, viene presentata una validazione sperimentale comparativa con i riferimenti della letteratura. Senza alcun addestramento specifico sul task, la pipeline raggiunge un'accuratezza di etichettatura globale vicina a quella del modello supervisionato SongFormer (ACC pari a 0.701 contro 0.749), con uno scarto di 4.8 punti, contenuto ma statisticamente significativo ($p = 0.009$), e nettamente superiore a quella della baseline generativa FUTGA (ACC pari a 0.280). Nella collocazione temporale dei confini (HR3F e HR.5F) il divario con SongFormer è molto più ampio, a causa della risoluzione della griglia discreta a 16 battiti adottata dal sistema. Sul piano semantico, il vantaggio rispetto al modello generativo di riferimento risiede nel guadagno rispetto al livello di caso (MRR di +0.085 contro +0.022), anziché nei valori assoluti, condizionati dal diverso numero di segmenti; i risultati evidenziano un ancoraggio reale ma moderato del testo generato al rispettivo segmento acustico.

In terzo luogo, un'analisi empirica delle varianti della pipeline e uno studio di ablazione con audio diretto. Il confronto tra le configurazioni (Flash, Pro e Lite) mostra che l'aumento della scala del modello non comporta necessariamente un miglioramento delle prestazioni, infatti, la variante Flash ottiene l'accuratezza più elevata

(ACC pari a 0.701 contro 0.641 di Pro), mentre la precisione sui confini stretti (HR.5F) rimane pressoché costante tra le varianti, confermando che il limite temporale risiede nella discretizzazione metrica a monte e non nell'agente linguistico. Contestualmente, il confronto a parità di modello (Lite) evidenzia la superiorità della pipeline rispetto all'elaborazione diretta dell'audio grezzo (ACC pari a 0.597 contro 0.457), la quale manifesta anomalie temporali nel 42% dei casi e una spiccata tendenza alla sottosegmentazione.

1.5 Struttura dell'Elaborato

Il lavoro è articolato in cinque capitoli.

Il Capitolo 2 traccia il quadro teorico e lo stato dell'arte, passando in rassegna le tecniche tradizionali di Music Information Retrieval, i metodi consolidati di Music Structure Analysis e la recente convergenza con i modelli audio-linguaggio e il music captioning.

Il Capitolo 3 illustra la metodologia e l'architettura del sistema, quindi descrive la discretizzazione della traccia in token da sedici battiti sincronizzati con la metrica musicale, l'estrazione deterministica dei parametri DSP, l'integrazione del testo cantato e il coordinamento della pipeline multi-agente, discutendo infine i limiti teorici dell'approccio e le relative prospettive di sviluppo.

Il Capitolo 4 riporta la valutazione sperimentale. Dopo aver introdotto il corpus di test, le baseline di confronto e il protocollo di generazione dei dati di inferenza, il capitolo approfondisce l'analisi dell'accuratezza strutturale (RQ1), arricchita dal confronto tra le varianti della pipeline e dal test con modello alimentato ad audio diretto, per poi esaminare la coerenza semantica interna (RQ2). Si conclude con l'analisi dei limiti metodologici e con gli sviluppi futuri della sperimentazione.

Il Capitolo 5 riassume le conclusioni generali dell'elaborato, tracciando un bilancio dei risultati raggiunti alla luce degli obiettivi di partenza e delineando le direzioni di ricerca a lungo termine.

Capitolo 2

Quadro Teorico e Stato dell'Arte

2.1 Le Tecniche di Estrazione Telemetrica

Nel dominio del *Music Information Retrieval* (MIR), l'estrazione di parametri fisici dal segnale acustico costituisce il fondamento metodologico per la comprensione computazionale della musica. A differenza dei modelli linguistici, che operano su sequenze discrete di simboli, il segnale sonoro si presenta come un flusso polifonico continuo in cui informazioni ritmiche, armoniche, timbriche e vocali convivono simultaneamente. Per rendere tale complessità trattabile da un'architettura decisionale, producendo grandezze interpretabili anziché rappresentazioni latenti, la letteratura scientifica ha sviluppato metodologie fondate sul *Digital Signal Processing* (DSP) e sull'apprendimento automatico specializzato. Tali tecniche consentono di isolare grandezze oggettive e riproducibili, fornendo una telemetria strutturata che descrive l'evoluzione temporale della traccia. Le sottosezioni seguenti illustrano i principi teorici dei moduli adottati per l'estrazione di queste dimensioni fisiche.

2.1.1 Beat Tracking e Stima del Tempo

L'analisi ritmica di un brano richiede l'individuazione dei battiti (*beat tracking*) e del primo battito di ciascuna misura musicale (*downbeat tracking*), elementi indispensabili per ricostruire la gerarchia metrica del segnale. Un riferimento consolidato è la libreria *madmom* [15], impiegata ad esempio in sistemi per il DJing automatico [16], che implementa un approccio basato su reti neurali ricorrenti (RNN) per stimare le probabilità di battito e di inizio misura, affidando a un modello di inferenza probabilistica (una *Dynamic Bayesian Network*) la scelta della sequenza più probabile di battiti e inizi misura [17].

In alternativa, BeatNet [18] è uno stimatore di battiti, downbeat e metro pensato per l'uso online, che combina reti convoluzionali e ricorrenti (CRNN) con filtri a

particelle (*particle filtering*). La letteratura ha successivamente proposto ulteriori modelli, tra cui SpecTNT-TCN [19] e Beat Transformer [20], e Beat This! [21], che rinuncia alla post-elaborazione con DBN.

La stima del tempo metronomico, espresso in battiti per minuto (BPM), presenta criticità specifiche nel dominio della musica dance ed elettronica (EDM). Gli stimatori di tempo sono soggetti a errori di ottava ritmica, restituendo il doppio o la metà del tempo effettivo, al punto che le valutazioni sui dataset EDM considerano corrette anche tali multipli e i software per DJ richiedono di vincolare l'intervallo di BPM ammesso [22]. Nella musica espressiva, il tempo locale è stato modellato tramite la mediana degli intervalli tra battiti su finestre temporali brevi [23]. Un approccio alternativo consiste nell'accumulare le ipotesi di tempo prodotte localmente nel corso del brano, raggrupparle in classi e selezionare la classe che raccoglie il maggior consenso [24]. Nei brani EDM che alternano sezioni a tempo pieno, raddoppiato (*double-time*) o dimezzato (*half-time*), una media globale rischia di falsare il risultato. L'architettura proposta adotta quindi una logica a consenso calcolata sui singoli *token*, descritta in dettaglio nel Capitolo 3.

2.1.2 Individuazione dei Cue Point

Nel contesto del mixaggio musicale, i *cue point* sono posizioni temporali che un DJ usa per segnalare punti salienti di un brano e confini adatti alla transizione tra due brani [25]. Nel presente lavoro questa idea è adottata come euristica, poiché è plausibile che un punto saliente coincida con l'inizio di una frase musicale, e dunque possa segnalare un cambio strutturale. L'estrazione automatica di questi marcatori è stata tradizionalmente affrontata mediante algoritmi DSP puri, volti a rilevare improvvise variazioni di energia o discontinuità spettrali [16]. Il vantaggio intrinseco dell'approccio analitico risiede nel naturale allineamento dei punti di transizione alla griglia ritmica sottostante, poiché le funzioni di novità (*novelty function*) operano direttamente sui multipli dei battiti calcolati.

Un significativo avanzamento è stato tuttavia introdotto da Cue-DETR [25], un modello che riformula l'individuazione dei cue point come un problema di rilevamento di oggetti in ambito di *Computer Vision*. Basato sull'architettura *Transformer* DETR e alimentato da segmenti di spettrogramma in scala Mel (*mel-spectrogram*), Cue-DETR non richiede analisi musicali di basso livello e supera i metodi precedenti, incluso l'approccio a regole di Zehren et al., in termini di *precision*, *recall* e F1, mostrando aderenza al fraseggio musicale tipico della musica elettronica.

Tale scelta però comporta un compromesso. L'impiego di un modello visivo che opera su finestre temporali continue incrementa l'accuratezza semantica nel posizionamento dei cue point, ma disaccoppia le coordinate temporali stimate dalla

griglia ritmica discreta dei battiti, rendendo necessarie strategie di riconciliazione e quantizzazione temporale, tema approfondito nell'architettura proposta nel Capitolo 3.

2.1.3 Onset Detection e Descrittori Spettrali Classici

Il rilevamento degli istanti di attacco dei singoli eventi sonori (*onset detection*) consente di quantificare la densità e la percussività del segnale. Nel lavoro di rassegna di Bello et al. [26] l'identificazione degli *onset* viene formalizzata tramite funzioni di novità calcolate su deviazioni di fase, differenze spettrali o salti di energia alle alte frequenze, così da intercettare i transienti associati a colpi percussivi o cambi di nota.

Per l'analisi quantitativa del timbro, la letteratura fa riferimento ai descrittori spettrali standardizzati da Peeters [27]. Tra i parametri utilizzati figurano il flusso spettrale (*spectral flux*), che quantifica il tasso di variazione della forma spettrale tra *frame* consecutivi ed è utile a rilevare transizioni, il centroide spettrale (*spectral centroid*), che individua il baricentro delle frequenze ed è strettamente correlato alla brillantezza timbrica percepita, e la piattezza spettrale (*spectral flatness*), utile per discriminare componenti rumorose da strutture armoniche. A questi si affiancano grandezze energetiche come la ripartizione dell'energia in bande di frequenza dedicate e la varianza dell'energia calcolata sul valore quadratico medio (RMS).

Questi descrittori costituiscono la base analitica della telemetria calcolata dal sistema per ciascun *token*, tra cui ROE, OCN, MSF, SC, SF ed EV. La loro formulazione matematica e il loro significato sono approfonditi nel Capitolo 3.

2.1.4 Separazione delle Sorgenti

La natura polifonica della registrazione musicale comporta la sovrapposizione di sorgenti strumentali e vocali all'interno della stessa traccia. L'isolamento di tali componenti, noto come *Music Source Separation* (MSS), è stato storicamente limitato da fenomeni di mascheramento spettrale, ma ha conosciuto un salto prestazionale con l'avvento di modelli di *deep learning* dedicati. Tra questi, Demucs e le sue varianti ibride [28, 29] costituiscono architetture di riferimento per la separazione vocale e strumentale, combinando l'elaborazione nel dominio del tempo e in quello tempo-frequenza tramite reti convoluzionali e meccanismi di attenzione. Più recentemente, la ricerca ha sviluppato architetture basate su Transformer, tra cui BS-RoFormer introdotto da Lu et al. [30].

Accanto alla separazione neurale delle sorgenti vocali, la letteratura fa ricorso alla separazione armonico-percussiva (*Harmonic-Percussive Source Separation*, HPSS).

L'algoritmo formulato da FitzGerald [31] sfrutta la diversa geometria con cui i suoni compaiono nello spettrogramma, dove i suoni armonici stabili si sviluppano in orizzontale lungo il tempo, mentre i colpi percussivi formano linee verticali lungo le frequenze. Applicando filtri mediani lungo queste due direzioni ortogonali, l'algoritmo scompone il segnale in una componente armonica e una percussiva. Tale principio teorico consente di isolare il contributo tonale dell'accompagnamento strumentale, costituendo la base per quantificare il rapporto di energia armonica del brano.

2.1.5 Stima della Tonalità

La determinazione della tonalità musicale (*key estimation*) riveste un ruolo centrale per l'analisi dell'organizzazione armonica e per le applicazioni di mixaggio armonico, in cui la compatibilità tra brani consecutivi è vincolata alle relazioni di consonanza tra le rispettive scale musicali. Il primo passaggio consiste nella trasformazione del segnale sonoro in un cromagramma (*Pitch Class Profile*), introdotto originariamente negli studi di Fujishima [32] per proiettare l'energia delle frequenze udibili sulle dodici note della scala cromatica. A livello spettrale, tale mappatura beneficia dell'impiego della *Constant-Q Transform* (CQT) [33], i cui *bin* di frequenza hanno spaziatura geometrica, coerente con la progressione logaritmica dei semitoni musicali.

A partire dal cromagramma medio, la stima della tonica e del modo (maggiore o minore) si ottiene applicando l'algoritmo di Krumhansl e Schmuckler [34], che confronta il brano con i profili tonali di riferimento. Tali profili sono misurati sperimentalmente (*probe-tone ratings*) nei quali agli ascoltatori viene chiesto di valutare quanto ciascuna delle dodici note si adatti a un contesto tonale dato [35]. Il sistema calcola il coefficiente di correlazione tra il cromagramma medio del brano e i ventiquattro profili ottenuti traslando ciclicamente i due vettori canonici (maggiore e minore) lungo le dodici classi di altezza, e identifica la tonalità che massimizza tale correlazione.

2.1.6 Trascrizione del Testo Cantato

Nel contesto dei brani vocali, la comprensione semantica della traccia richiede l'analisi congiunta di parametri acustici e testo cantato. L'adattamento dei sistemi di riconoscimento vocale automatico (*Automatic Speech Recognition* ASR) al canto risente infatti del mascheramento della base strumentale, delle vocali prolungate e delle variazioni d'intonazione imposte dalla melodia. L'architettura WhisperX [14], sviluppata per la trascrizione di parlato di lunga durata, combina il modello Whisper con una pre-segmentazione basata su rilevamento dell'attività vocale (*Voice Activity Detection* VAD), ossia un algoritmo che individua i tratti del segnale in

cui è presente la voce distinguendoli da silenzio e sola base strumentale, e con una fase di allineamento fonetico forzato basata su modelli wav2vec 2.0 [36], ottenendo *timestamp* a livello della singola parola.

L'effetto della separazione delle sorgenti sulla trascrizione con Whisper non è immediato. Nel lavoro di Syed et al. [37], fornire a Whisper le voci separate con l'algoritmo di segmentazione nativo produce miglioramenti modesti o dipendenti dal dataset. Il beneficio consistente si ottiene invece utilizzando la voce separata come rilevatore di attività vocale basato sull'ampiezza RMS (*RMS-VAD* [37]), per derivare i confini di segmento (di durata massima pari a 30 secondi), e trascrivendo poi entro tali confini. La separazione delle sorgenti si è inoltre rivelata utile in compiti affini di rilevamento della voce cantata [38]. Syed et al. osservano inoltre che Whisper cancella sistematicamente vocalizzi non lessicali e cori, indipendentemente dalla qualità della separazione [37].

A queste difficoltà si aggiunge la tendenza di Whisper a generare allucinazioni, ovvero a produrre testo non correlato all'audio o sequenze ripetute [37]. Tale fenomeno, documentato anche su audio non vocale [39], viene definito nel seguito come *Ghost Vocals*.

I metodi passati in rassegna forniscono la base telemetrica (Figura 1.1) utilizzata dagli agenti linguistici per l'analisi del brano (Capitolo 3). Prima di illustrare tale approccio, la sezione successiva esamina lo stato dell'arte dei modelli supervisionati di segmentazione strutturale, a partire dalla rassegna di Paulus et al. [3] fino a SongFormer [9].

2.2 Stato dell'Arte della Segmentazione Strutturale Supervisionata

La *Music Structure Analysis* (MSA) è uno dei compiti consolidati del MIR, e la sua rassegna di riferimento è quella di Paulus et al. [3]. Gli autori definiscono l'obiettivo generale come la suddivisione di una registrazione in segmenti temporali corrispondenti a parti musicali e il raggruppamento di tali segmenti in categorie musicalmente significative, con particolare attenzione alla musica popolare occidentale. I metodi sono ripartiti in tre famiglie, fondate su ripetizione, novità e omogeneità, e la rassegna segnala che alcuni di essi tentano di assegnare ai gruppi individuati etichette come strofa o ritornello. La rassegna riferisce inoltre che il primo confronto sistematico tra metodi ebbe luogo nel task di segmentazione strutturale di MIREX 2009. Nella pratica, come osservano gli autori di SongFormer, il problema è spesso formulato come etichettatura di sequenze nel tempo [9].

Il task Music Structure Analysis di MIREX[1] richiede di segmentare l'audio e di assegnare a ciascun segmento una tra sette classi funzionali (*intro*, *verse*, *chorus*, *bridge*, *inst*, *outro* e *silence*), le stesse sette categorie adottate da Wang et al. [40].

La valutazione combina l'accuratezza a livello di frame (ACC) per le etichette con la F-measure dei confini entro ± 0.5 secondi (HR.5F) e ± 3 secondi (HR3F), secondo il protocollo richiamato nella Sezione 4.4. La pagina del task indica All-In-One [41] come riferimento di base, affiancato nell'edizione 2026 da SongFormer.

All-In-One rientra tra le *pipeline* che, secondo gli autori di SongFormer, si appoggiano a pre-elaborazioni onerose come il beat tracking e la separazione delle sorgenti, con un aggravio di complessità che ostacola la scalabilità [9]. Il sistema illustrato nel presente lavoro condivide questa dipendenza, ma la assume come scelta di progetto, infatti, il beat tracking fornisce la griglia ritmica su cui poggia la tokenizzazione e la separazione vocale alimenta la trascrizione del testo, per cui tali elaborazioni non sono un costo accessorio della segmentazione ma il presupposto della telemetria e dell'approccio bottom-up descritti nel Capitolo 3.

SongFormer [9] estrae rappresentazioni auto-supervisionate (*self-supervised learning*, SSL) dai modelli MuQ e MusicFM su due scale, finestre locali da 30 secondi e una finestra globale da 420 secondi, e le fonde lungo la dimensione delle feature. Le rappresentazioni, campionate a 25 Hz, vengono sottocampionate di un fattore tre fino a circa 8.33 Hz e arricchite da un *data source embedding* appreso, che indica l'origine di ciascun campione di addestramento e che in inferenza viene fissato a quello di HarmonixSet. La sequenza è elaborata da un Transformer a quattro strati con codifica posizionale RoPE, e due teste distinte producono la probabilità

[1] `https://music-ir.org/mirex/wiki/2026:Music_Structure_Analysis`

di confine per ogni frame e la classe funzionale, assegnata a ciascun segmento come la classe a massima probabilità media. L'output è una sequenza ordinata di coppie (istante di inizio, etichetta). In valutazione le etichette sono ricondotte alle sette categorie, con *pre-chorus* assimilato a *verse*.

La supervisione è eterogenea, infatti all'insieme di addestramento di HarmonixSet si affiancano annotazioni ricavate dai testi, annotazioni parziali e annotazioni generate con Gemini 2.5 Pro. Gli autori le descrivono come etichette parziali, rumorose o con schemi discordanti, e l'embedding di sorgente serve a mitigarne l'effetto. Il corpus risultante, SongFormDB, supera i 10.000 brani, mentre la valutazione avviene su SongFormBench, composto da 300 brani verificati da esperti.

Sul sottoinsieme SongFormBench-HarmonixSet, indicato nel seguito come SongFormBench-HS, la configurazione addestrata su tutti i corpora raggiunge un'ACC di 0.807, contro lo 0.740 di All-In-One, mentre quella addestrata sul solo HarmonixSet ottiene HR.5F pari a 0.703 (All-In-One: 0.596) e HR3F pari a 0.784 (All-In-One: 0.730). Gemini 2.5 Pro, valutato dagli stessi autori, presenta un HR3F leggermente superiore (0.813) ma un HR.5F di 0.423, e gli autori ne concludono che l'annotazione basata su modelli linguistici privilegia un allineamento grossolano dei confini. Il primato dichiarato riguarda quindi ACC e HR.5F su SongFormBench, e non la tolleranza ampia.

Su SongFormBench, dunque, SongFormer offre la precisione temporale più elevata tra i sistemi confrontati dagli autori sotto tolleranza stretta, ma il suo spazio di uscita resta una tassonomia chiusa di etichette funzionali. Il sistema stabilisce dove cade una sezione e a quale delle sette classi appartiene, senza produrre alcuna descrizione in linguaggio naturale dei tratti timbrici, energetici o testuali che la distinguono dalle altre. Si tratta della polarità già anticipata nella Sezione 1.2. Il paradigma opposto, quello dei modelli *end-to-end* audio-linguaggio, descrive il contenuto ma, come si vedrà nella Sezione 2.3, non offre la stessa precisione temporale.

2.3 Lo Stato dell'Arte: I Modelli End-to-End e i loro Limiti

Negli ultimi anni, la ricerca nel dominio del Music Information Retrieval e del Natural Language Processing ha cercato di colmare il divario strutturale tra la natura continua del segnale acustico e la discretezza del linguaggio, attraverso lo sviluppo di architetture neurali end-to-end e di *Large Audio-Language Models* (LALM), quali Music Flamingo [11] e le recenti evoluzioni della serie Audio Flamingo [42]. Tali sistemi tentano di mappare direttamente l'audio grezzo o le sue proiezioni latenti in descrizioni testuali libere, senza l'intermediazione di rappresentazioni simboliche strutturate, estendendo al dominio musicale paradigmi multimodali consolidati

nel NLP. Nonostante i traguardi generativi raggiunti, un'analisi comparativa di modelli quali LP-MusicCaps [5], BLAP [43], SonicVerse [13], FUTGA [6] e Music Flamingo [11] evidenzia limiti metodologici e vincoli architetturali riconducibili a tre macro-criticità: la cecità strutturale indotta da partizioni arbitrarie, la cecità temporale nell'allineamento degli eventi e la propagazione di errori latenti.

2.3.1 Rappresentazioni Contrastive Audio-Testo: da CLIP a CLAP

Oltre ai modelli generativi, un ruolo centrale nell'intersezione tra audio e linguaggio è svolto dall'apprendimento contrastivo multimodale. Tale paradigma è stato formalizzato originariamente nel dominio visivo da Radford et al. con il modello CLIP (*Contrastive Language-Image Pretraining*) [44], la cui intuizione principale consiste nel proiettare immagini e descrizioni testuali all'interno di uno spazio vettoriale congiunto, ottimizzato in modo che elementi semanticamente affini risultino vicini secondo la metrica di similarità del coseno.

Questo principio è stato successivamente trasposto al dominio sonoro attraverso lo sviluppo di CLAP (*Contrastive Language-Audio Pretraining*), formulato per la prima volta da Elizalde et al. [7]. In tale architettura, un *encoder* acustico specializzato e un encoder testuale vengono addestrati congiuntamente per allineare rappresentazioni di clip sonore e descrizioni linguistiche. Il paradigma ha trovato ulteriore consolidamento e scalabilità con LAION-CLAP, introdotto da Wu et al. [45], che ha esteso l'addestramento su dataset di dimensioni sensibilmente maggiori, divenendo uno dei punti di riferimento primari per il recupero cross-modale e la caratterizzazione semantica della musica.

Dal punto di vista matematico, l'addestramento di questi modelli si fonda sull'ottimizzazione della *loss function* InfoNCE. Dato un *batch* composto da N coppie accoppiate di audio e testo, il sistema calcola la matrice quadrata di similarità cross-modale $M \in \mathbb{R}^{N \times N}$, in cui ciascuna cella $M[i, j]$ rappresenta la similarità del coseno tra l'embedding acustico della clip i e l'embedding linguistico della descrizione j:

$$M[i, j] = \frac{\mathbf{e}_i^{\text{audio}} \cdot \mathbf{e}_j^{\text{text}}}{\|\mathbf{e}_i^{\text{audio}}\| \, \|\mathbf{e}_j^{\text{text}}\|}. \tag{2.1}$$

L'obiettivo di apprendimento viene formalizzato come una perdita di entropia incrociata simmetrica, calcolata lungo le righe e lungo le colonne della matrice. Tale formulazione massimizza i valori della diagonale principale ($i = j$), corrispondenti alle associazioni audio-testo corrette, e penalizza le attivazioni extra-diagonali ($i \neq j$), associate a coppie scorrelate. La tendenza alla diagonale dominanza riflette dunque la natura geometrica intrinseca dello spazio contrastivo, in cui la massima affinità vettoriale viene forzata in corrispondenza del corretto accoppiamento cross-modale. Nell'ambito del *music captioning* basato su modelli linguistici,

l'uso di modelli contrastivi permette di esaminare due limiti noti nella generazione delle descrizioni.

Il primo riguarda la riduzione della diversità espressiva indotta dalle fasi di allineamento post-addestramento (*post-training alignment*) tramite apprendimento per rinforzo basato su preferenze umane (RLHF). Come evidenziato da Zhang et al. [46], tale procedura favorisce il fenomeno noto come *mode collapse*, in cui il modello converge su un ristretto sottoinsieme di risposte prototipiche, a causa della preferenza degli annotatori per testi più familiari. In compiti di descrizione strutturata della musica, un modello linguistico privo di vincoli deterministici rischia pertanto di produrre didascalie generiche o intercambiabili per sezioni diverse della medesima traccia, vanificando la differenziazione semantica pur in presenza di confini temporali corretti.

Specularmente, un secondo limite deriva dall'adozione di strategie correttive durante la fase di decodifica, quali la *repetition penalty* [47]. Introdotta per mitigare la ripetizione monotona di parole mediante la penalizzazione esplicita dei logit associati a token precedentemente emessi, questa tecnica introduce una forza artificiale che scoraggia la ridondanza lessicale. In un contesto musicale, qualora una medesima sezione acustica si ripeta in modo identico lungo il brano, tale penalizzazione potrebbe indurre il modello a generare variazioni stilistiche superflue o ingiustificate dal segnale sonoro. Sebbene si tratti di una conseguenza logica del campionamento penalizzato, l'impatto effettivo di questo fenomeno nel dominio musicale non è ancora documentato in letteratura con la stessa ampiezza del mode collapse.

Sfruttando la struttura di questo spazio condiviso, il presente lavoro impiega le rappresentazioni di CLAP per definire metriche di ancoraggio semantico e temporale intra-traccia, verificando nella valutazione sperimentale (Capitolo 4) che le didascalie siano realmente legate al segmento audio e non degenerate in testi generici.

2.3.2 Le Origini End-to-End e il Limite del Chunking Rigido

La prima generazione di sistemi dedicati al music captioning ha affrontato la generazione di descrizioni testuali operando su frammenti sonori isolati di breve durata. Tra i lavori di riferimento di questo filone, LP-MusicCaps [5] ha affrontato la scarsità di dati annotati mediante una pipeline di generazione sintetica dove un modello linguistico è stato impiegato per tradurre elenchi di tag acustici preesistenti in descrizioni discorsive fluide, attraverso *prompt* strutturati volti ad arricchire il lessico ed evitare formule ripetitive [5]. Tale procedura è servita unicamente a creare un corpus sintetico supervisionato, impiegato poi per addestrare il modello *end-to-end* audio-testo. Questo approccio si differenzia dal paradigma a due stadi

Audio-to-Metadata-to-Caption proposto da Bukey et al. [12], in cui l'LLM interviene a tempo d'inferenza condizionato da metadati espliciti. Poiché le didascalie sintetiche derivano da tag preesistenti senza un ascolto diretto del segnale sonoro da parte del modello linguistico, la qualità finale dipende strettamente dalla copertura e dall'accuratezza dei vocabolari di annotazione originari [5]. Inoltre, l'architettura encoder-*decoder* finale viene addestrata su coppie testo-audio limitate a finestre temporali fisse di dieci secondi, producendo descrizioni locali prive di qualsiasi modellazione della struttura macroscopica del brano.

Un'evoluzione di questo filone è rappresentata da BLAP [43], che adatta l'architettura BLIP-2 al dominio musicale collegando un encoder acustico CLAP a un modello linguistico (Flan-T5) tramite un modulo Q-Former (*Querying Transformer*). Tale allineamento consente di ridurre di un fattore sei i dati di addestramento necessari mantenendo un'elevata qualità descrittiva sui singoli estratti sonori. Tuttavia, operando anch'esso unicamente su brevi clip isolate, BLAP condivide con LP-MusicCaps l'incapacità di modellare l'evoluzione temporale della composizione e delle transizioni dell'intero brano.

Un tentativo di integrare l'analisi del segnale e la sintesi testuale in un'unica architettura multi-task è rappresentato da SonicVerse [13]. Il sistema adotta un encoder acustico pre-addestrato e introduce un *multi-task projector* formato da un *music content projector*, che converte le proprietà qualitative globali (*soft features*) in token linguistici, e da un *music feature projector*, dotato di teste di classificazione ausiliarie addestrate a predire attributi musicali discreti (*hard features*, quali tonalità, strumentazione e tempo) [13]. A livello metodologico, SonicVerse impiega strumenti di estrazione MIR esterni (la libreria MIRFLEX) unicamente durante la fase di addestramento per generare pseudo-etichette con cui supervisionare le teste ausiliarie, consentendo alle proiezioni neurali di predire tali attributi a tempo d'inferenza senza eseguire moduli esterni. Nonostante SonicVerse incorpori elementi di teoria musicale, per gestire brani estesi adotta un partizionamento in finestre da dieci secondi, aggregando successivamente le descrizioni dei singoli blocchi mediante un modello linguistico. Il presente lavoro si ispira proprio a questo approccio *bottom-up*, delegando agli agenti la sintesi progressiva a partire da unità locali, in questo caso i *token* sincronizzati alla griglia metrica (Capitolo 3), ma se ne differenzia per due scelte di fondo. Innanzitutto, non affida l'estrazione delle grandezze fisiche a reti neurali ausiliarie, impiegando moduli DSP deterministici a tempo d'inferenza per preservare l'oggettività della telemetria. Inoltre, sostituisce il taglio a tempo fisso con *token* sincronizzati alla griglia metrica, evitando che una segmentazione arbitraria spezzi battute o frasi musicali e ne comprometta la coerenza strutturale.

2.3.3 La Sfida Long-Form e la Cecità Temporale

Per superare la frammentazione in clip da dieci secondi e consentire l'analisi di intere composizioni musicali, uno dei primi modelli a proporre un'architettura di *long-form captioning* time-aware è FUTGA [6]. In assenza di dataset su larga scala contenenti brani estesi corredati da annotazioni allineate nel tempo, gli autori hanno introdotto una strategia di aumento generativo dei dati che consiste nell'estrarre sequenze di tre o cinque clip da MusicCaps e concatenarle sulla base della similarità del coseno tra gli embedding semantici delle rispettive descrizioni, simulando lo sviluppo narrativo di una traccia reale [6]. Per rappresentare la progressione temporale superando i tagli rigidi, i limiti temporali delle singole sezioni vengono codificati come percentuali relative rispetto alla durata complessiva del brano (da 0 a 100%) inserite direttamente nel testo. Un modello linguistico viene quindi impiegato per parafrasare le descrizioni parziali in una didascalia unificata che delinea la macro-struttura e le relative variazioni dinamiche, fungendo da riferimento per il *fine-tuning* del *backbone* multimodale. Poiché la supervisione sintetica non riproduce la struttura di brani reali, il modello viene inoltre addestrato su HarmonixSet, con didascalie riviste da annotatori umani [6].

La successiva evoluzione del framework, denominata FUTGA-MIR [48], integra informazioni estratte con strumenti MIR (tra cui tempo, melodia, strumentazione e ritmo), che condizionano il campionamento dei clip sintetici e vengono fornite in ingresso al modello, con ulteriore verifica umana delle didascalie. L'obiettivo è ridurre il divario tra composizioni sintetiche e registrazioni reali. Per valutare la capacità del modello di ancorare le descrizioni all'audio lungo l'intera traccia, FUTGA [6] formalizza un protocollo di recupero cross-modale molti-a-molti (*Audio Clip Retrieval*) a livello di brano, ripreso in FUTGA-MIR [48]. Data una traccia di interrogazione descritta da un insieme di didascalie c_i e un insieme di tracce candidate composte da frammenti acustici a_j, ciascuna coppia viene proiettata nello spazio condiviso di CLAP. La similarità globale tra la query A e la traccia candidata B viene definita come la media delle similarità del coseno pesata per la sovrapposizione temporale (*Intersection over Union*, IoU) tra l'intervallo temporale della didascalia e quello del frammento sonoro:

$$\text{score}(A, B) = \frac{\sum_{i,j} \text{IoU}(c_i, a_j) \cdot \cos\left(\mathbf{e}_{c_i}^{\text{text}}, \mathbf{e}_{a_j}^{\text{audio}}\right)}{\sum_{i,j} \text{IoU}(c_i, a_j)}. \tag{2.2}$$

Le coppie prive di sovrapposizione temporale ricevono peso nullo. La graduatoria risultante consente di calcolare metriche standard di recupero a livello di brano, tra cui Recall@K (con $K \in \{1, 5, 10\}$) e il rango mediano (MedR) [6, 48]. Il presente lavoro si ispira a tale impostazione, adottandone una versione semplificata di tipo molti-a-molti, con pool piatto e bidirezionale e senza pesatura IoU, approfondita nei capitoli successivi (Capitolo 4).

Nonostante i progressi nella generazione di descrizioni articolate per sezione, la scansione temporale in FUTGA e FUTGA-MIR dipende unicamente dalle percentuali stimate nel testo. L'assenza di un ancoraggio deterministico al brano espone a imprecisioni temporali che possono accumularsi lungo la traccia, rendendo tali stime inadatte ad applicazioni in contesti ad alta precisione.

2.3.4 Ragionamento Complesso e Allucinazioni a Cascata

In risposta ai limiti di profondità descrittiva dei modelli precedenti, un avanzamento di rilievo è rappresentato da Music Flamingo [11], un modello multimodale sviluppato per estendere la comprensione musicale a livello professionale su registrazioni di lunga durata. Gli autori contestano l'eccessiva brevità delle didascalie generate dai modelli precedenti, argomentando che descrizioni compresse impediscano l'inclusione di nozioni armoniche, timbriche e stilistiche essenziali. Per sostenere compiti di ragionamento avanzato, il framework introduce dataset annotati su larga scala ed estende la finestra di contesto acustico dell'architettura. Sotto il profilo temporale, Music Flamingo introduce i *Rotary Time Embeddings* (RoTE), che codificano i riferimenti temporali direttamente all'interno delle rappresentazioni estratte dall'encoder acustico [11]. Il post-addestramento prevede una fase iniziale su dati teorico-musicali per istruire il modello a produrre passaggi logici intermedi entro tag dedicati prima di emettere la didascalia finale, seguita da un'ottimizzazione tramite apprendimento per rinforzo guidata da ricompense personalizzate [11].

Tuttavia, operando interamente all'interno di uno spazio latente privo di vincoli deterministici espliciti, tale approccio rimane esposto a una specifica vulnerabilità, la propagazione degli errori (o allucinazione a cascata). Qualora il modello linguistico incorra in un'errata interpretazione iniziale del contesto sonoro, l'errore può propagarsi lungo i passaggi successivi di generazione. In assenza di un riscontro fisico stabile sul segnale, la contaminazione del contesto testuale può indurre l'architettura ad allucinare sviluppi formali, attributi di arrangiamento o componenti strumentali non riscontrabili nell'audio reale, riducendo l'affidabilità del testo prodotto. Questo comportamento evidenzia la difficoltà di garantire un'interpretazione oggettiva e verificabile della struttura musicale basandosi unicamente su rappresentazioni latenti non vincolate.

In una recente evoluzione di questa famiglia di modelli, Audio Flamingo Next [42] propone un paradigma di *Temporal Audio Chain-of-Thought*, che ancora i passaggi intermedi del ragionamento a riferimenti temporali espliciti (timestamp) su audio fino a trenta minuti. Anche in questo caso, tuttavia, l'ancoraggio temporale è appreso dal modello e non deriva da una griglia metrica deterministica calcolata a monte sul segnale.

Music Flamingo e i modelli derivati costituiscono dunque architetture complesse,

il cui adattamento richiede impegnativi processi di fine-tuning e risorse di calcolo dedicate. Al contrario, la pipeline proposta nel presente elaborato non richiede addestramento aggiuntivo del modello linguistico, in quanto l'estrazione deterministica via DSP calcolata a monte separa la misurazione fisica dalla sintesi semantica, rendendo il sistema facilmente riconfigurabile e ispezionabile lungo l'intera catena decisionale.

2.3.5 L'Approccio Disaccoppiato a Due Stadi

I limiti delle architetture dei modelli *end-to-end* hanno spinto la ricerca verso un paradigma alternativo alla mappatura diretta da segnale a testo (*Audio-to-Caption*). Nel recente lavoro di Bukey et al. (Adobe Research, 2026) [12], gli autori mostrano come forzare un'architettura multimodale ad apprendere una mappatura immediata dalla forma d'onda a un testo discorsivo imponga una stilizzazione linguistica rigida. Tale dipendenza rischia di incorporare nei pesi del modello le specificità sintattiche del corpus di addestramento e induce un fenomeno di *entanglement* rappresentazionale, in cui l'informazione fattuale sul brano rimane intrecciata con lo stile linguistico, aumentando il rischio di imprecisioni descrittive [12].

Per superare questa criticità, Bukey et al. propongono un paradigma disaccoppiato a due stadi denominato Audio-to-Metadata-to-Caption [12]. Nella prima fase, un modello autoregressivo leggero viene addestrato a stimare esclusivamente metadati strutturati in formato JSON, comprendenti campi quali genere, atmosfera, parole chiave, tempo, tonalità, livello di energia e strumentazione [12]. Nella seconda fase, tali metadati vengono elaborati a tempo d'inferenza da un modello linguistico congelato, che genera la descrizione discorsiva finale mediante tecniche di prompt design e apprendimento nel contesto (*in-context learning*) [12].

Questa articolazione offre un duplice vantaggio. Oltre a raggiungere prestazioni comparabili a quelle delle *baseline* dirette con circa il 46% delle ore di calcolo su GPU per l'addestramento, introduce un'elevata flessibilità nella modulazione stilistica post-hoc, permettendo di variare registro o dettaglio con l'inclusione di un singolo esempio nel prompt (*metadata 1-shot*) senza alcun ri-addestramento dei pesi [12]. Il disaccoppiamento abilita inoltre operazioni di imputazione dei metadati (*metadata imputation*), in cui informazioni parzialmente note possono essere fornite in ingresso per guidare la stima delle grandezze residue.

L'approccio illustrato nel presente lavoro condivide il principio di disaccoppiare la quantificazione delle caratteristiche del brano dalla loro articolazione semantica. Tuttavia, mentre Bukey et al. affidano la predizione dei metadati a un modello neurale addestrato a tale scopo, la pipeline qui proposta delega tale estrazione a un motore DSP che non richiede alcun addestramento sul compito, sostituendo la stima

statistica con grandezze fisiche calcolate direttamente dal segnale e vincolando la segmentazione a una griglia metrica anziché a un singolo blocco globale.

2.4 Paradigma Ibrido DSP+LLM vs LALM End-to-End

Il contrasto tra l'accuratezza temporale dei modelli di segmentazione (Sezione 2.2) e la flessibilità espressiva delle architetture *end-to-end*, fino al recente paradigma disaccoppiato di Bukey et al. [12] (Sezione 2.3), motiva l'approccio ibrido adottato in questa tesi, esaminato nei paragrafi successivi.

Si potrebbe obiettare che un LALM di frontiera, essendo in grado di descrivere in linguaggio naturale il contenuto di una traccia musicale, renda superflua una pipeline deterministica di estrazione delle feature. Tuttavia, se questi modelli sembrano affidabili nella comprensione globale della traccia (genere, atmosfera o descrizioni discorsive), diverse evidenze sperimentali ne evidenziano i limiti su compiti percettivi a grana fine, tra cui la localizzazione temporale [9, 10, 49] e la stima di proprietà acustiche come la tonalità [11]. Tali limiti motivano la scelta di calcolare a monte le grandezze fisiche e di affidare al modello linguistico la sola interpretazione semantica. A questa scelta si aggiunge un vantaggio di interpretabilità. Ogni descrizione prodotta si appoggia a misure esplicite, come il tempo metronomico, l'energia e l'attività vocale, che possono essere ispezionate e verificate, mentre con un modello che riceve l'audio grezzo non è possibile ricostruire su quali elementi del segnale si fondi la descrizione. Ciò non implica che il sistema proposto superi i modelli di segmentazione dedicati sulle metriche di confine, aspetto discusso nella valutazione sperimentale (Capitolo 4).

2.4.1 Precisione Temporale

Pur analizzando l'audio in generale e non la struttura musicale, Shi et al. [49] individuano due cause della scarsa precisione temporale dei LALM su compiti di localizzazione di eventi sonori ossia l'assenza di riferimenti temporali fisici espliciti nell'input audio e un obiettivo di addestramento supervisionato basato sull'entropia incrociata che penalizza le previsioni temporalmente vicine a quella corretta. Come rimedio propongono TimePro-RL, che intervalla *timestamp embedding* nella sequenza di feature audio (*Audio-Side Time Prompt*) e vi affianca un'ottimizzazione per rinforzo con GRPO, valutata su compiti di *audio grounding*, *sound event detection* e *dense audio captioning*.

Difficoltà analoghe su audio di lunga durata sono riportate da Shao et al. [10], secondo cui l'allineamento temporale diventa progressivamente meno accurato all'aumentare della durata della registrazione, fenomeno riscontrato anche durante

la valutazione sperimentale (Capitolo 4). Nel dominio musicale, sul sottoinsieme SongFormBench-HS (Sezione 2.2) un modello specializzato raggiunge un HR.5F di 0.703, contro 0.423 di un LALM generalista di frontiera (Gemini 2.5 Pro) [9], a riprova di un limite strutturale legato all'architettura e all'addestramento. Il sistema proposto condivide con TimePro-RL il principio di fornire al modello coordinate temporali esplicite, ma le ricava da una griglia ritmica calcolata a monte dal DSP anziché apprenderle con un post-addestramento del modello linguistico.

2.4.2 Cecità alle Feature Acustiche di Basso Livello

Un secondo limite riguarda la percezione di proprietà armoniche come la tonalità. Nell'analisi di *linear probing* riportata da Ghosh et al. [11], l'encoder audio basato su Whisper raggiunge il 91.37% di accuratezza nella classificazione del genere (GTZAN) contro il 40.56% nella classificazione della tonalità. Gli autori ipotizzano che il divario dipenda dal fatto che, con obiettivi di addestramento basati su didascalie, è molto più probabile che il genere di un brano compaia nel testo rispetto alla tonalità. Pur trattandosi di un'ipotesi interpretativa e non di una relazione causale verificata, questa evidenza motiva la scelta di stimare la tonalità con moduli di analisi del segnale dedicati (Sezione 2.1) anziché delegarla a un encoder generalista.

Queste difficoltà percettive trovano riscontro anche in MMAU-Pro [50], benchmark di 5305 istanze su 49 competenze che include audio di durata fino a dieci minuti, mentre nei benchmark precedenti MMAU e MMAR i clip durano in media circa 10 e 19 secondi (e per tale motivo non considerati in questa analisi). Su MMAU-Pro modelli come Gemini 2.5 Flash e Audio Flamingo 3 raggiungono soltanto il 59.2% e il 51.7% di accuratezza, con risultati particolarmente bassi nel ragionamento su audio spaziale, pur trattandosi di una valutazione generale distribuita tra parlato, suoni ambientali e musica, e non di una misura specifica per il dominio musicale.

Nel contesto dell'*audio captioning*, MMAC [51] valuta copertura e precisione delle didascalie su audio generico (parlato, scene acustiche ed eventi sonori). Applicando vincoli di lunghezza a Gemini 2.5 Pro, gli autori osservano che descrizioni più estese coprono più informazione ma con precisione decrescente. Pur non riguardando direttamente la musica, il risultato segnala un compromesso tra completezza e affidabilità, rilevante per un'architettura mirata alla produzione di didascalie dense.

2.4.3 Interpretabilità e Dipendenza dal Testo

Nella pipeline proposta il componente linguistico non riceve mai l'audio grezzo, ma opera su rappresentazioni testuali, ovvero la telemetria strutturata estratta a monte, i metadati forniti dall'utente e il testo trascritto. Ogni affermazione sulle caratteristiche acustiche contenuta nelle didascalie può quindi essere ricondotta a una misura esplicita, come il tempo metronomico, il profilo energetico o l'attività vocale, e verificata senza riascoltare il brano.

Nei modelli che ricevono l'audio grezzo questa tracciabilità manca, e un'analisi dei benchmark di audio-linguaggio suggerisce un ulteriore motivo di cautela. Foo et al. [52] mostrano che i modelli mantengono il 60-72% del punteggio pieno anche senza audio in ingresso (fino all'81.2% per Audio Flamingo 3 su MMAU) e che solo il 3.0-4.2% degli item richiede l'intera clip. Ne segue che le prestazioni su tali benchmark possono riflettere ragionamento testuale più che percezione acustica. Si tratta di risultati su benchmark di domanda-risposta e non sulla generazione di didascalie, ma indicano che l'aderenza di una descrizione al segnale non può essere data per scontata quando il modello non rende conto delle evidenze su cui si basa.

La propagazione degli errori è un limite di questa impostazione. Senza accesso al segnale grezzo, il componente linguistico non ha modo di compensare le imprecisioni del DSP, che si trasferiscono direttamente nel testo finale. La natura esplicita delle misure permette però di individuare l'errore, isolando il parametro quantitativo che lo ha generato.

Le evidenze discusse riguardano compiti specifici e non la comprensione musicale in senso generale, per cui sarebbe una generalizzazione eccessiva sostenere che i LALM "non capiscono la musica". I LALM end-to-end sembrano più affidabili nella comprensione semantica globale di un brano, pertanto il sistema proposto non intende sostituirli su quel terreno. Piuttosto, l'architettura ibrida adottata in questa tesi sfrutta la capacità dei modelli linguistici di produrre testo semanticamente ricco, vincolandola a misure esplicite e verificabili, da cui le caratteristiche acustiche descritte restano tracciabili.

Capitolo 3

Sviluppo dell'architettura

Il presente lavoro si propone di sviluppare un sistema per l'analisi fisica delle tracce musicali che, a partire dall'estrazione di dati telemetrici [1, 14, 18, 25, 27, 29, 31], consenta a un Large Language Model (LLM) di generare descrizioni testuali [12] e di operare una segmentazione semantica del brano.

A tale scopo, è stato adottato un approccio bottom-up [13]: la traccia audio viene suddivisa in unità musicali atomiche definite token, per ciascuna delle quali viene raccolta e aggregata la relativa telemetria fisica.
Poiché il sistema è ottimizzato per il dominio della musica elettronica, si assume un'impostazione metrica standard in 4/4. Di conseguenza, la dimensione di ciascun token è stata fissata empiricamente a una lunghezza di 16 battiti musicali.

Oltre a supportare la segmentazione semantica e la generazione delle didascalie, la rappresentazione discreta e telemetrica del brano è concepita per abilitare compiti decisionali di livello superiore come la generazione autonoma di un mix musicale. In questa prospettiva, le descrizioni qualitative e i parametri fisici di ciascun *token* forniscono a un eventuale agente decisionale le informazioni necessarie per allineare e combinare i segmenti audio in base alle loro proprietà acustiche e strutturali. L'implementazione di tale agente non rientra negli obiettivi del presente lavoro e viene discussa tra gli sviluppi futuri (Sezione 3.4).

Architettura

L'organizzazione complessiva dell'architettura proposta è stata schematizzata nel Capitolo 1 (si veda la Figura 1.1). Nelle sezioni seguenti vengono descritti in dettaglio i singoli componenti della pipeline, a partire dall'estrazione della griglia ritmica e dei punti di transizione fino all'orchestrazione degli agenti per la segmentazione e la generazione delle didascalie.

3.1 Beat Grid e Cue Point

Il sistema deve individuare due componenti temporali della traccia audio: la *beat grid* (la griglia ritmica che scandisce i battiti e i movimenti della battuta) e i *cue point*. Questi ultimi, nati nella pratica dei DJ come marcatori dei punti salienti di un brano [25], sono adottati qui come euristica per localizzare i cambi strutturali, come l'ingresso di una strofa, di un *drop* o di un'outro, secondo quanto discusso nel Capitolo 2.

L'estrazione della *beat grid* risulta strettamente necessaria per la costruzione dei *token*. Essendo questi ultimi definiti nell'architettura come frammenti audio della durata fissa di 16 battiti, essi risultano intrinsecamente sincronizzati a livello metrico. Parallelamente, l'individuazione dei *cue point* fornisce al sistema una mappatura logica della struttura musicale, identificando le coordinate temporali in cui è plausibile che avvenga un cambio strutturale.

Poiché i *token* sono definiti sulla griglia ritmica, è necessario che le due dimensioni temporali risultino allineate. Nella pratica manuale dei DJ l'allineamento tra marker strutturali e griglia ritmica non rappresenta sempre un vincolo matematico stringente [25]. Nel presente lavoro si è scelto invece di introdurre un vincolo architetturale: i *cue point* estratti devono essere allineati alla *beat grid* sottostante, così da coincidere con i margini temporali dei *token*. La scelta è coerente con l'euristica adottata, secondo cui un punto saliente coincide con l'inizio di una frase musicale, e semplifica la gestione temporale del sistema.

In una prima fase di progettazione del sistema, l'estrazione della griglia ritmica e dei cue point si basava su un approccio puramente analitico tramite Digital Signal Processing (DSP). Il vantaggio principale di tale metodologia risiedeva nel naturale e perfetto allineamento dei punti di transizione alla griglia ritmica sottostante [16].

Tuttavia, a seguito di un'analisi prestazionale condotta sulla letteratura recente, si è optato per l'integrazione di un modello basato su Computer Vision applicata a spettrogrammi per l'individuazione dei cue point, il quale ha dimostrato un'accuratezza significativamente superiore rispetto all'approccio DSP tradizionale [25].

L'adozione di questo nuovo paradigma ha conseguentemente disaccoppiato l'estrazione dei cue point da quella dei battiti, rendendo necessario l'impiego di un modello indipendente per la generazione della griglia ritmica.

A tal fine, la scelta è ricaduta su BeatNet [18], selezionato nella fase iniziale di progettazione, in cui il sistema era pensato anche per un uso nel mixaggio automatico, oggi tra gli sviluppi futuri (Sezione 3.4). Il componente è stato mantenuto, in quanto non oggetto della valutazione sperimentale. Modelli più recenti per il tracciamento offline (si veda il Capitolo 2) non sono stati confrontati

ma data la struttura modulare della pipeline, lo stimatore è sostituibile senza modificare il resto del sistema.

3.1.1 Rappresentazione a Token del Segnale Audio

A differenza dei tradizionali sistemi di elaborazione del linguaggio naturale, in cui il *token* rappresenta la minima unità semantica testuale, nell'architettura proposta il termine *token* è stato ridefinito per il dominio musicale. Nello specifico, il segnale audio continuo viene discretizzato in una sequenza temporale di *token* di lunghezza fissa, ciascuno corrispondente a esattamente 16 battiti (*beat*), fatta eccezione per i *token* parziali all'inizio e alla fine della traccia, descritti più avanti.

La scelta di questa specifica cardinalità non è casuale, ma risponde a una precisa euristica musicale: nei generi moderni (come Pop ed Electronic Dance Music), le macro-sezioni strutturali e i giri armonici si sviluppano tipicamente su frasi musicali di 4 battute (dove una battuta in 4/4 equivale a 4 battiti, per un totale di 16).
Di conseguenza, il token da 16 battiti rappresenta l'unità atomica ideale: abbastanza breve da catturare variazioni locali nelle feature acustiche, ma sufficientemente lungo da contenere un senso compiuto a livello ritmico e strutturale. All'interno del sistema, ogni *token* non trasporta solo il frammento audio grezzo, ma funge da contenitore (payload) per tutta la telemetria estratta dal motore DSP e dai modelli di trascrizione.

Costruzione dei Token e Sincronizzazione di Fase

La corretta suddivisione del brano musicale in *token* richiede che i frammenti audio non vengano generati in modo arbitrario a partire dall'inizio fisico della traccia, bensì che siano allineati in fase con la struttura metrica del brano. A tal fine, la logica di costruzione dei confini temporali non si limita a raggruppare sequenzialmente i battiti estratti, ma individua un punto di ancoraggio strategico da cui partire con la costruzione della griglia.

Nello specifico, l'algoritmo analizza la sequenza ritmica e identifica tutti i *downbeat*, ovvero i battiti che corrispondono al primo movimento di una battuta musicale (identificati dal valore di posizione metrico pari a 1). Il sistema seleziona il primo *downbeat* utile (con la possibilità di applicare un offset iniziale, espresso in battute intere e scelto in modo da massimizzare il punteggio medio di affidabilità dei *cue point* agganciati alla griglia, concetto che verrà formalizzato nella Sezione 3.1.2)

A partire da questo indice di riferimento, la griglia dei battiti viene campionata con un passo costante pari alla dimensione del *token* (16 battiti). Questo vincolo garantisce che ogni segmento audio generato inizi sempre esattamente sul primo movimento di una battuta e contenga al suo interno quattro battute complete in 4/4.

Tale coerenza strutturale è un prerequisito per l'allineamento dei *cue point* alla griglia e per la regolarità della sequenza di *token* su cui operano gli agenti. Questo vincolo costruttivo garantisce che i frammenti audio risultino intrinsecamente sincronizzati a livello metrico, evitando fenomeni di disallineamento ritmico tra *token* adiacenti.

Come conseguenza diretta di questo allineamento metrico, le porzioni di traccia collocate prima dell'ancoraggio iniziale e dopo l'ultimo blocco completo non vengono scartate, ma vanno a costituire dei segmenti marginali di lunghezza variabile, tipicamente inferiori ai 16 battiti. Questi frammenti, che corrispondono fisiologicamente all'introduzione del brano (es. silenzio, rumore di fondo o tappeti sonori precedenti al primo *downbeat* effettivo) e alla sua naturale conclusione (*fade-out* o coda di riverbero), vengono elaborati dal sistema come *token* parziali. Tale approccio garantisce la copertura e l'analisi dell'intero segnale audio continuo, preservando al contempo l'incorruttibilità strutturale (esattamente 4 battute in 4/4) di tutti i *token* centrali su cui operano gli agenti della *pipeline*.

3.1.2 Allineamento dei *cue points* alla *beat grid*

Siccome i *cue point* vengono estratti da un modello di computer vision (Cue-DETR [25]), i relativi timestamps non sono intrinsecamente allineati alla griglia ritmica del brano. Per risolvere questo disallineamento è stata implementata una logica di snapping, che àncora ciascun cue point al confine temporale del token più vicino.

Scoring dei *cue points* e *Quantization Error Ratio (QER)*

Poiché l'operazione di *snapping* descritta in precedenza introduce uno scostamento temporale rispetto alla posizione originale del *cue point* stimata dal modello Cue-DETR, è necessaria l'introduzione di una metrica in grado di quantificare tale imprecisione, il *Quantization Error Ratio (QER)*. Tale metrica è pensata per fornire a un eventuale agente futuro di mix (Sezione 3.4) una misura dell'affidabilità di ciascun punto di transizione. Nella pipeline attuale contribuisce alla scelta della fase della griglia (Sezione 3.1.2).

Il QER è definito come il rapporto tra lo scostamento temporale del *cue point* (rispetto al margine del *token* più vicino) e l'errore massimo tollerabile, calcolato in funzione dei BPM locali della traccia. Scalando l'errore in relazione alla durata effettiva del battito, questa metrica risulta intrinsecamente indipendente dalla velocità di riproduzione (*BPM-agnostic*); in questo modo è garantita una base coerente sia per la calibrazione del punteggio di affidabilità, sia per la comparazione di tracce caratterizzate da ritmi eterogenei.

A livello implementativo, la durata effettiva del battito non viene stimata globalmente, ma è calcolata dinamicamente estraendo i margini temporali del *token* specifico all'interno del quale ricade il *cue point* in esame. Tale accortezza algoritmica, unita a logiche di fallback per la gestione dei *cue point* posizionati in sezioni esterne alla griglia strutturale (ovvero i *token* parziali definiti in precedenza), garantisce precisione anche nell'elaborazione di brani caratterizzati da fluttuazioni di tempo o cambi di BPM in corso d'opera [23, 24], contribuendo alla definizione *BPM-agnostic* della metrica.

La formulazione matematica del QER implementa una normalizzazione *min-max* definita tra una soglia di tolleranza minima (*threshold_ms*) e un errore massimo tollerabile (*max_error*) ed è espressa come segue:

$$\text{QER} = \max\left(0, \min\left(1, \frac{\text{error} - \text{threshold_ms}}{\text{max_error} - \text{threshold_ms}}\right)\right) \tag{3.1}$$

In questo contesto, il parametro *threshold_ms* (empiricamente impostato a 50 ms) definisce la *deadzone* iniziale: entro tale soglia, lo scostamento è considerato impercettibile e non genera penalità ($QER = 0$). Il *max_error* rappresenta invece il limite superiore di tolleranza, empiricamente fissato a metà della durata di un singolo battito.

Mentre la letteratura scientifica suggerisce che la soglia di percettibilità della latenza si attesti nell'ordine delle decine di millisecondi [53], il *max_error* viene qui adottato come limite estremo di accettabilità (pari, ad esempio, a 250 ms a 120 BPM): superata tale soglia, lo scostamento risulta macroscopico e il *cue point* non può più essere considerato allineato alla griglia, oltre a essere inaccettabile ai fini di un eventuale mix fluido. Grazie alla struttura della formula, il valore del QER satura a 1 non appena lo scostamento eguaglia o supera questo limite.

Infine, per ottenere una misura complessiva di affidabilità, il valore della penalità calcolata tramite il QER viene combinato con il punteggio di *confidence* originario fornito da Cue-DETR. Nello specifico, il punteggio finale di affidabilità (S) viene ottenuto applicando al valore originale della *confidence* (C) una penalità moltiplicativa modulata da un iperparametro α:

$$S = C \cdot (1 - \alpha \cdot \text{QER}) \tag{3.2}$$

L'introduzione di questo parametro permette di regolare la severità della penalità temporale. Ad esempio, impostando $\alpha \approx 1$ si penalizzano fortemente gli scostamenti elevati, rendendo il punteggio più selettivo, e un eventuale agente di mix potrebbe così scartare i *token* associati a *cue point* inaffidabili. Nella pipeline attuale α è fissato a 0.5 e il punteggio non filtra alcun *cue point*.

Ottimizzazione fasica della *beat grid*

L'analisi ha evidenziato una ricorrenza di errori sistematici di scostamento legati alla fase della griglia. Per compensarli, il sistema esegue uno scorrimento iterativo della *beat grid*, testando i possibili *offset* del *downbeat* di partenza, in multipli di una battuta intera, ossia un quarto della lunghezza del *token*. Per ciascuna permutazione, l'algoritmo ricalcola lo *snapping* e valuta la *confidence* media globale ($\bar{S}$). La griglia viene infine ancorata alla configurazione che massimizza tale punteggio, favorendo così la riduzione del *QER* medio e un migliore allineamento dei *cue point* ai margini dei *token*.

Al termine dell'allineamento, i *cue point* agganciati alla griglia vengono associati ai *token* come marcatori categorici (`START`, `END` o `BOTH`), a seconda che coincidano con l'inizio, con la fine o con entrambi i margini del *token*. Gli agenti ricevono soltanto questo marcatore, senza timestamp né punteggi, e il *Semantic Segmenter* lo impiega come riferimento per collocare i confini tra le sezioni (Sezione 3.3.4). I *cue point* che ricadono nei *token* parziali iniziale e finale vengono agganciati rispettivamente al primo e all'ultimo ancoraggio della griglia.

3.2 Estrazione della Telemetria tramite DSP

Al fine di analizzare le proprietà fisiche del brano e generare la telemetria necessaria per le logiche decisionali, la traccia audio originale viene preliminarmente sottoposta a un processo di *source separation* tramite l'architettura Demucs [28], isolando la componente puramente strumentale da quella vocale.

L'obiettivo di tale scomposizione è l'estrazione di una rappresentazione quantitativa granulare del timbro e della dinamica energetica per ciascun *token* musicale. Parallelamente, per arricchire il livello di comprensione del contesto semantico e culturale, il sistema provvede all'estrazione e alla trascrizione del testo. Infine, al fine di mitigare il fenomeno del *vocal clash*, ovvero il rischio di decisioni di mixaggio distruttive in presenza di attività vocale, il sistema calcola un set di metriche acustiche dedicate, progettate per valutare l'intensità e la dominanza della voce all'interno di ogni *token*.

È possibile visualizzare concettualmente la collocazione di questo modulo facendo riferimento alla Figura 1.1 (riquadro viola etichettato come "DSP Engine").

3.2.1 Feature DSP estratte

Per ciascun *token* il motore DSP calcola un insieme ristretto di feature deterministiche, scelte tra i descrittori classici della letteratura MIR discussi nel Capitolo 2. Le feature per *token* descrivono la dinamica ritmica ed energetica (ROE, OCN, EV), la distribuzione dell'energia in frequenza (BTR, MTR, TTR), il timbro e la variazione spettrale (MSF, SC, SF) e il contenuto armonico (HER). A queste si affiancano il tempo metronomico (BPM), calcolato sia per *token* sia sull'intero brano, e la tonalità, stimata soltanto a livello globale. Una sintesi è riportata nella Tabella 3.1.

Metrica	Significato Matematico	Sintesi Funzionale
BPM [22–24]	Beats Per Minute	Tempo metronomico, stimato per *token* e, per consenso, sull'intero brano.
Key [32, 34]	Chiave Armonica	Ottenuta via CQT e profili cognitivi. Descrittore armonico globale del brano.
ROE [26]	Rhythmic Onset Energy	Media dell'inviluppo dei transienti. Definisce l'aggressività ritmica.
EV [27]	Energy Variance	Varianza dell'energia RMS. Rileva forti fluttuazioni dinamiche.
OCN [26]	Onset Count Number	Conteggio assoluto dei transienti. Quantifica la densità ritmica.
B/M/TTR	Band Energy Ratios	Quota relativa del livello RMS nelle bande basse, medie e alte.
MSF [26]	Mean Spectral Flux	Tasso di variazione spettrale. Rileva transizioni strutturali.
SC [27]	Spectral Centroid	Centro di massa dello spettro. Definisce la brillantezza tonale.
SF [27]	Spectral Flatness	Distingue suoni puramente tonali da rumore a banda larga.
HER [31]	Harmonic Energy Ratio	Estratto via HPSS. Rapporto tra livello RMS armonico e livello RMS totale.

Tabella 3.1: Panoramica delle feature DSP estratte. L'HER impiega la componente armonica della traccia strumentale isolata.

Descrittori calcolati per *token*

Tutte le feature di questo gruppo, ad eccezione dell'HER che impiega solo la traccia strumentale, sono calcolate sulla traccia originale. Nel seguito $S_t(f)$ indica lo spettro di ampiezza (modulo della *Short-Time Fourier Transform*) della t-esima finestra di analisi del *token*, con $t = 1, \ldots, T$ e $f \in F$, e r_t il corrispondente valore RMS.

La ROE (*Rhythmic Onset Energy*) è la media, nel *token*, della funzione di rilevamento degli *onset* [26] e misura l'intensità media degli attacchi, mentre la OCN (*Onset Count Number*) conta gli *onset* rilevati e ne quantifica la densità. L'EV (*Energy Variance*) è la varianza dei valori r_t, ossia la statistica di varianza che Peeters propone per descrivere nel tempo i descrittori istantanei, qui applicata all'energia [27]. L'SC (*Spectral Centroid*) è il baricentro dello spettro [27], mediato sulle finestre del *token* e normalizzato in [0,1] dividendolo per la frequenza di Nyquist, mentre l'SF (*Spectral Flatness*) è il rapporto tra la media geometrica e la media aritmetica dello spettro [27], mediato allo stesso modo, con valori prossimi a 0 per i suoni tonali e a 1 per le componenti rumorose.

Per la distribuzione dell'energia in frequenza si usano tre rapporti di banda, il BTR (*Bass-to-Total Ratio*), l'MTR (*Mid-to-Total Ratio*) e il TTR (*Treble-to-Total Ratio*), riferiti rispettivamente alle frequenze sotto i 250 Hz, tra 250 Hz e 4 kHz e oltre i 4 kHz. Per ciascuna banda b si calcola il livello RMS dello spettro in ogni finestra, mediando i quadrati dei *bin* che la compongono, e lo si media poi sul *token*. Il rapporto è la quota di tale livello sul totale delle tre bande:

$$\rho_b = \frac{1}{T} \sum_{t=1}^{T} \sqrt{\frac{1}{|B_b|} \sum_{f \in B_b} S_t(f)^2}, \qquad R_b = \frac{\rho_b}{\rho_{\mathrm{BTR}} + \rho_{\mathrm{MTR}} + \rho_{\mathrm{TTR}}} \tag{3.3}$$

dove B_b è l'insieme dei *bin* della banda b e $b \in \{\mathrm{BTR}, \mathrm{MTR}, \mathrm{TTR}\}$, così che i tre valori sommino a uno.

L'MSF (*Mean Spectral Flux*) misura l'entità media degli aumenti di energia spettrale tra finestre consecutive. Si basa sulla differenza rettificata tra spettri successivi, che conta solo le frequenze in cui l'energia cresce [26], nella variante con scarti elevati al quadrato e mediati su frequenze e finestre. È distinta dalla variazione spettrale di Peeters, basata invece sulla correlazione normalizzata tra spettri consecutivi [27]:

$$\mathrm{MSF} = \frac{1}{(T-1)\,|F|} \sum_{t=2}^{T} \sum_{f \in F} \left[\max(0,\ S_t(f) - S_{t-1}(f))\right]^2 \tag{3.4}$$

I picchi di MSF accompagnano i cambi bruschi di timbro e di energia, e forniscono un indizio utile per collocare i confini strutturali.

L'HER (*Harmonic Energy Ratio*) è l'unica feature che impiega la traccia strumentale ottenuta dalla separazione delle sorgenti. Su tale traccia, considerata per intero,

si applica l'HPSS [31], che la scompone in una componente armonica e in una percussiva. L'HER non è una grandezza definita dall'algoritmo di FitzGerald ma una misura introdotta in questo lavoro, cioè, il rapporto tra il livello RMS medio della componente armonica strumentale nel *token* e il livello RMS medio del *token* nella traccia originale,

$$\mathrm{HER} = \frac{\overline{r}_{\mathrm{arm,strum}}}{\overline{r}_{\mathrm{master}}} \tag{3.5}$$

dove $\overline{r}$ indica la media dei valori RMS delle finestre del *token*. Poiché il denominatore comprende anche la voce, a parità di sottofondo la presenza di cantato abbassa il valore.

Oltre ai valori per *token*, per alcune di queste grandezze vengono calcolati anche massimi e medie sull'intero brano, forniti agli agenti come riferimenti globali, come illustrato nelle sezioni dedicate agli agenti 3.3.

Tempo Metronomico (BPM)

Il BPM è stimato sulla traccia *master*, anziché sulla sola base strumentale, a partire dai battiti individuati da BeatNet, e viene riportato a due livelli di granularità: una stima locale per ciascun *token* e un valore globale per l'intero brano.

La doppia granularità risponde a criticità note per questo dominio. Gli stimatori di tempo sono soggetti a errori di ottava [22] e, nei brani EDM che alternano sezioni a tempo pieno, raddoppiato (*double-time*) o dimezzato (*half-time*), una media globale può falsare il risultato. Per il tempo locale nella musica espressiva è stata proposta la mediana degli intervalli tra battiti su segmenti di circa dodici secondi [23], mentre un approccio alternativo consiste nel raggruppare in classi le ipotesi di tempo prodotte localmente e selezionare quella con il maggior consenso [24]. Il sistema si ispira a quest'ultimo, applicandolo ai *token* con classi intere e un semplice conteggio delle stime.

La stima locale sfrutta la lunghezza fissa del *token*. Poiché questo contiene esattamente 16 battiti della griglia di BeatNet, il tempo si ricava direttamente dalla durata del blocco, senza ricontare i battiti intermedi:

$$\mathrm{BPM}_{\mathrm{token}} = \frac{16 \cdot 60000}{t_{\mathrm{fine}} - t_{\mathrm{inizio}}} \tag{3.6}$$

dove gli istanti t_{inizio} e t_{fine} sono espressi in millisecondi. La formula presuppone 16 battiti, pertanto nei *token* parziali di bordo, più corti, il valore ottenuto non corrisponde a un tempo reale.

Il valore globale si ottiene per consenso, in quattro passaggi. Si scartano anzitutto i *token* di bordo di durata inferiore a 3 secondi, frammenti troncati che falserebbero il calcolo, dato che un *token* di 16 battiti a 200 BPM dura almeno 4.8 secondi.

Le stime rimanenti sono arrotondate all'intero più vicino, formando classi di tolleranza (*tolerance bins*), e si individua la classe più frequente. Il valore globale è la media aritmetica dei soli valori originari, non arrotondati, ricadenti in tale classe, così da mantenere la precisione decimale e da non risentire delle sezioni a tempo raddoppiato o dimezzato che occupano una parte minoritaria del brano.

La stima locale viene fornita agli agenti per ciascun *token*, anche quando è anomala, perché le anomalie possono essere informative. Nei test condotti su *Shot Me Down*, ad esempio, il tempo stimato nei primi *token* risultava instabile (intorno ai 160 BPM) per poi stabilizzarsi a 128 BPM. Poiché la formula presuppone una griglia regolare di 16 battiti, un'introduzione non quantizzata, in cui BeatNet non individua una scansione regolare, produce stime incoerenti con il resto del brano, e gli agenti hanno interpretato tali fluttuazioni come l'indizio di un'introduzione non quantizzata anziché come un errore di tracciamento.

Tonalità

A differenza del BPM, la tonalità è stimata una sola volta sull'intero brano e riportata come descrittore globale, senza una stima per singolo *token*, per cui eventuali modulazioni interne non vengono rilevate. La procedura segue la catena classica descritta nel Capitolo 2. Dalla traccia strumentale, quindi priva della voce, viene prima isolata la componente armonica tramite HPSS [31], in modo che le percussioni non alterino la stima. Su tale componente si calcola un cromagramma basato sulla *Constant-Q Transform* [32, 33], la cui somma nel tempo fornisce il profilo delle dodici classi di altezza. Il profilo è confrontato, tramite il coefficiente di correlazione di Pearson, con i ventiquattro profili tonali di Krumhansl e Schmuckler [34], ottenuti traslando i due profili canonici maggiore e minore, e la tonalità stimata è quella che massimizza la correlazione. Il risultato è infine espresso nella notazione della *Camelot Wheel*, che associa a ciascuna tonalità un codice alfanumerico.

3.2.2 Estrazione e Mappatura del Testo

L'estrazione del testo mediante l'utilizzo preventivo di algoritmi di *source separation* è una strategia esplorata in letteratura per la trascrizione automatica dei testi cantati [37]. Per la trascrizione effettiva e l'estrazione dei timestamp a livello di singola parola è stato impiegato il modello WhisperX [14].

Tuttavia, per garantire un'ottimizzazione specifica per il dominio musicale, il modulo di *Voice Activity Detection (VAD)* basato su reti neurali fornito di default da WhisperX, ottimizzato nativamente per il parlato, è stato disabilitato. Al suo posto, è stata adottata la strategia di VAD basata sull'energia *RMS* proposta da Syed et al. [37], che gli autori mostrano ridurre in modo consistente il tasso di errore sulle parole rispetto all'algoritmo di segmentazione nativo di Whisper nella trascrizione

long-form di testi cantati. Il confronto diretto con il VAD di WhisperX non è stato oggetto di valutazione in questo lavoro.

WhisperX restituisce quindi, per ciascuna parola rilevata, il tempo di inizio, il tempo di fine e il relativo livello di *confidence*. Su questa base viene costruita una rappresentazione più compatta, adatta a essere consumata dal resto della pipeline.

Riorganizzazione della Trascrizione a Livello di Token

La rappresentazione grezza prodotta da WhisperX risulterebbe eccessivamente verbosa per un impiego diretto all'interno della finestra di contesto di un *Large Language Model*. Ogni parola porta infatti con sé un insieme di attributi temporali che, se mantenuti senza riorganizzazione, aumenterebbero in modo significativo il costo informativo, senza fornire un guadagno significativo sul piano semantico.

Per questo motivo, le informazioni di trascrizione vengono riorganizzate e aggregate all'interno dei rispettivi *token* temporali, mediante una logica di associazione spaziale basata sui timestamp delle singole parole. L'obiettivo non è conservare la trascrizione testuale in modo puramente sequenziale, ma costruire una rappresentazione sufficientemente densa da mantenere solo le informazioni strutturalmente utili per il sistema cioè la presenza del cantato, la sua collocazione temporale d'inizio e il grado di affidabilità della trascrizione.

Infine, le metriche di *confidence* delle singole parole fornite da WhisperX vengono aggregate, tramite media e mediana, per assegnare a ciascun *token* un livello complessivo di affidabilità della trascrizione testuale (*Reliability*: HIGH, MEDIUM, LOW).

Gestione dei Confini Semantici: Il Problema del *Vocal Chop*

La principale criticità riguarda i casi di confine, nei quali una parola si estende tra due *token* consecutivi. In tali situazioni, una segmentazione troppo rigida produrrebbe il fenomeno del *vocal chop*, ossia la frammentazione innaturale di una porzione cantata tra due segmenti adiacenti.

In altri termini, il problema non è solo di allineamento temporale, ma di coerenza percettiva: il sistema deve evitare che una porzione cantata venga trattata, a livello semantico, come due entità distinte quando, dal punto di vista musicale, costituisce un'unica unità espressiva.

Sono state considerate diverse strategie alternative.

La prima consisteva nel far coincidere i *token* con il parlato, così da eliminare alla radice il problema delle parole spezzate. Questa soluzione è stata scartata perché avrebbe introdotto *token* di dimensione variabile, rendendo più complessa

la gestione temporale dell'architettura e indebolendo la regolarità della struttura su cui si basa il sistema.

Una seconda ipotesi prevedeva invece la costruzione di segmenti vocali paralleli, sovrapposti ai segmenti prodotti dal segmenter (Sezione 3.3.4), a partire dall'output del *RMS-VAD* con logica *cut and merge* [37]. In questo scenario, le sezioni vocali avrebbero potuto essere marcate separatamente rispetto ai segmenti musicali principali, consentendo una descrizione più fine del contenuto della traccia.

Questa soluzione risulta però problematica per tre motivi distinti. Anzitutto, se un segmento vocale ricade all'interno di un segmento semantico prodotto dal segmenter, quest'ultimo non può essere mantenuto invariato, ma deve essere ulteriormente suddiviso per generare una variante esplicitamente marcata come vocale. In secondo luogo, poiché nella pratica i segmenti vocali tendono ad avere durata inferiore (o comunque differente) a quella di un singolo *token*, essi dovrebbero essere artificialmente estesi fino a coprire un'intera unità metrica; tuttavia, questa operazione finirebbe per descrivere in modo impreciso la distribuzione reale delle vocals nel brano, sovrastimandone la presenza. Infine, quando un segmento vocale si colloca sul margine tra due segmenti semantici, l'unica soluzione coerente sarebbe la creazione di un segmento ibrido, che però maschera il confine semantico netto tra le due macro-sezioni e compromette la leggibilità strutturale dell'architettura.

Un esempio di tale situazione è illustrato in Figura 3.1

L'idea è stata quindi abbandonata, ma ha evidenziato la necessità di introdurre metriche specifiche per descrivere la presenza vocale ai bordi dei segmenti, da cui derivano le successive metriche di *vocal density*, *confidence* e *intensity*, la definizione delle quali è riportata nella Sezione 3.2.3

Gestione dei Confini Semantici: Soluzione

L'euristica definitiva adottata per la gestione dei testi assegna l'intera parola al *token* in cui essa ha inizio. Qualora la sua durata ecceda il margine del segmento, viene associato un marcatore semantico, ad esempio `<BLEED 376>`, per quantificare l'esatta entità dello sforamento in millisecondi, altrimenti si assume che la parola sia contenuta interamente all'interno del segmento.

La soluzione adottata privilegia una struttura regolare e semplice, demandando al *Semantic Segmenter* l'eventuale fusione dei *token* nei soli casi in cui la presenza vocale ai bordi suggerisca una reale continuità semantica. Il *token*, quindi, rimane un'unità strutturale fissa e la decisione di unirlo o meno a quello successivo viene rimandata a tale agente, che dispone delle informazioni vocali necessarie per evitare tagli impropri.

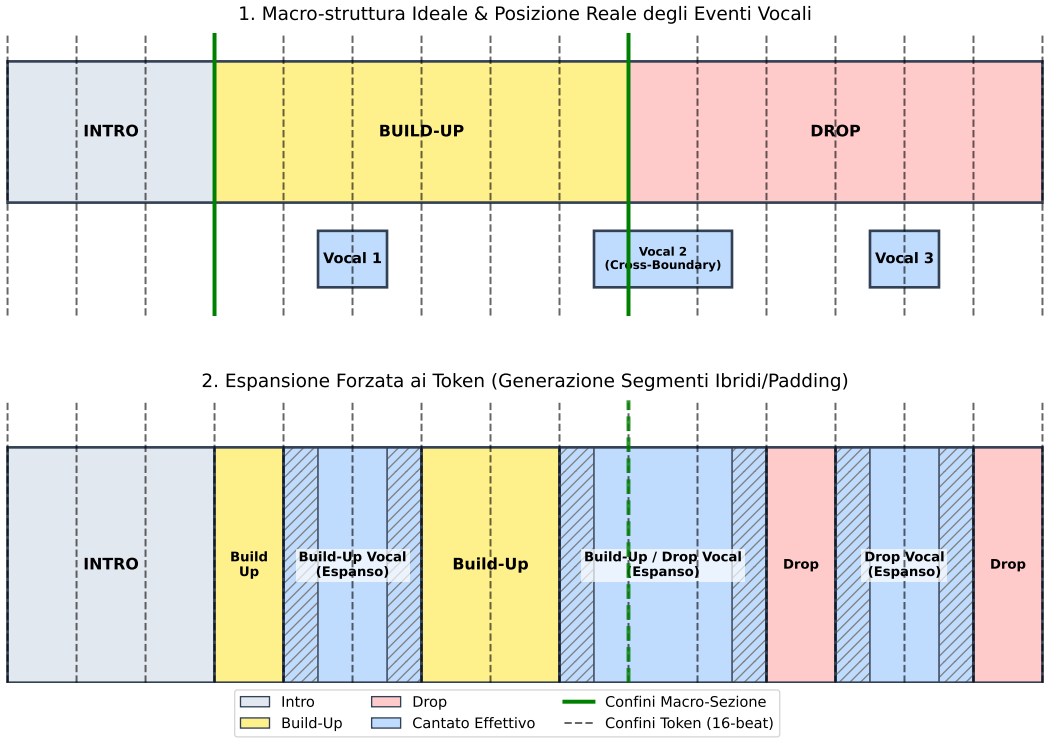


Figura 3.1: Effetto dell'allineamento forzato dei segmenti vocali alla griglia metrica dei token, dove si osserva come questo possa generare "segmenti ibridi" che accorpano e mascherano il confine netto tra due macro-sezioni semanticamente distinte (ad esempio, *Build-Up* e *Drop*) e segmenti grandi quanto un singolo *token* che sono composti solo in parte (anche minima) dal cantato. Tale operazione compromette la logica semantica necessaria per ottenere una corretta descrizione del brano.

Questa scelta è stata preferita anche per preservare la leggibilità dell'architettura complessiva. Segmenti ibridi o eccessivamente articolati avrebbero infatti complicato l'interpretazione da parte degli agenti a valle, mentre una rappresentazione regolare consente di mantenere la segmentazione semplice e consistente.

Ai fini dell'analisi successiva, è sufficiente conservare l'intervallo di inizio e fine della porzione testuale presente nel *token*. L'obiettivo principale non è infatti ricostruire in modo puntuale la distribuzione interna delle parole, bensì fornire al sistema un'indicazione affidabile della presenza di cantato, utile a ridurre il rischio di *vocal chop* nella segmentazione e di *vocal clash* in un eventuale mix futuro, demandando l'analisi più fine della componente vocale alla Sezione 3.2.3.

Un esempio pratico del risultato di tale aggregazione, completo di marcatura di sconfinamento e valutazione di affidabilità, è riportato nel Listato 3.1.

Listing 3.1: Esempio di struttura dati generata dal modulo di mappatura semantica per un singolo *token* del brano *Satisfaction – David Guetta, Benny Benassi*. È visibile l'applicazione dell'euristica di *bleed* (sconfinamento testuale di 376 ms nel *token* successivo) e il mantenimento delle metriche essenziali (*timestamp* e *reliability*) destinate agli agenti della *pipeline*.

```
"lyrics": {
    "text": "Push me, and then just touch me, till I can get
      ↪ my satisfaction. Push <BLEED 376>",
    "start_time_ms": 103170,
    "end_time_ms":   110636,
    "reliability":   "MEDIUM"
}
```

3.2.3 Estrazione delle Feature Vocali (Custom *VAD*)

Come evidenziato in letteratura [37], i modelli di trascrizione neurale come Whisper presentano limiti strutturali nel riconoscimento di voci non lessicali, quali vocalizzi, sospiri e *ad-libs* tipici della musica EDM. Affidarsi unicamente alla trascrizione comporterebbe il rischio di ignorare informazioni vocali spazialmente rilevanti per l'analisi del brano. Per sopperire a questa lacuna e fornire agli agenti un'informazione affidabile sulla presenza vocale, utile anche a prevenire sovrapposizioni vocali indesiderate (*vocal clash*) in un eventuale mix futuro, si è reso necessario lo sviluppo di un modulo di estrazione di feature vocali puramente acustico, indipendente dalla trascrizione e complementare alla mappatura testuale descritta nella sezione precedente.

Il modulo implementato opera come un *Voice Activity Detector* (VAD) acustico, strutturato attorno a un vincolo architetturale fondamentale. Il consumatore finale di questi dati, infatti, non è un sistema algoritmico tradizionale, bensì un *Large Language Model* (LLM). Sebbene un'estrazione classica del segnale (come, ad esempio, l'esportazione matriciale dei *frame* derivati dalla *Short-Time Fourier Transform* o il passaggio di *array* continui calcolati su micro-finestre temporali da 100 ms) offra la massima granularità analitica, il suo inserimento diretto all'interno di un *prompt* testuale comporterebbe un costo computazionale proibitivo in termini di *token* e saturerebbe istantaneamente la *context window* degli agenti.

Si rende quindi necessario individuare un compromesso architetturale ottimale tra l'alta risoluzione fisica del segnale e la sua leggibilità semantica. Pertanto, in questo studio si propone l'introduzione di un set di feature *custom*, ideate appositamente per "comprimere" l'ingombro vocale ad alta frequenza. L'obiettivo è tradurre il dato acustico grezzo in metriche aggregate che siano intrinsecamente *token-efficient* e direttamente interpretabili dall'IA come concetti semantici di alto livello.

Dualismo Cognitivo e Astrazione Architetturale

L'architettura di astrazione proposta si pone l'obiettivo di modellare matematicamente l'apparato uditivo umano, al fine di tradurre il segnale audio in una rappresentazione semantica che l'LLM possa interpretare in modo naturale. Dal punto di vista psicoacustico, la letteratura neuro-cognitiva [54] ha dimostrato che l'udito elabora il suono secondo un preciso dualismo: riceve lo stimolo preservandone i dettagli sfumati e i gradienti fisici continui, ma lo "categorizza" in classi nette (ad esempio, collassando l'ambiguità acustica in "voce presente" o "voce assente" [55]) solo nell'istante in cui il processo cognitivo richiede la formulazione di un'azione o di una scelta esplicita (*forced-choice decision-making*).

Il sistema simula questo esatto comportamento. Da un lato, le metriche di base (*Vocal Energy Dominance* e *Vocal Intensity*) agiscono come l'orecchio umano: preservano il dato fisico continuo per estrarre e trasmettere l'escursione dinamica reale del volume (in perfetta linea con i postulati di McMurray). Dall'altro lato, tale gradiente viene successivamente compresso in uno stato probabilistico fortemente polarizzato, di natura quasi-binaria. Questa compressione avviene tramite l'elevata pendenza di una funzione sigmoide, la cui architettura ricalca matematicamente le curve psicometriche della percezione umana [56], qui specificamente ottimizzata per la *Speech Presence Probability* [57], generando così la *Vocal Confidence* (Figura 3.3).

Questo collasso in metriche discrete si rende architetturalmente indispensabile poiché i moduli a valle (come il *Segmenter* o un eventuale agente futuro di mix) operano in un puro spazio decisionale esecutivo. Dovendo collocare confini strutturali o, nel caso di un mix, innescare transizioni, essi non possono affidarsi a fluttuazioni continue, ma sono costretti a compiere una scelta binaria esclusiva. La categorizzazione forzata fornisce loro i confini operativi inequivocabili necessari per agire, chiudendo in modo elegante il parallelismo con la cognizione umana.

Vocal Energy Dominance

Tutte le metriche derivate si fondano sul calcolo di una grandezza primaria definita *Vocal Energy Dominance* (VED). Tale metrica rappresenta il rapporto energetico locale tra la traccia vocale isolata e l'energia acustica totale del brano (data dalla somma della traccia vocale e di quella strumentale).

Matematicamente, per una data finestra di analisi, la VED è calcolata a partire dal valore medio della *Root Mean Square* (RMS) dei rispettivi segnali:

$$\mathrm{VED} = \frac{\overline{\mathrm{RMS}}_{\mathrm{vocal}}}{\overline{\mathrm{RMS}}_{\mathrm{vocal}} + \overline{\mathrm{RMS}}_{\mathrm{instrumental}} + \epsilon} \tag{3.7}$$

dove ϵ (impostato architetturalmente a 10^{-6}) è un fattore di regolarizzazione introdotto per prevenire instabilità numeriche in presenza di assoluto silenzio digitale.

Questa specifica formulazione matematica garantisce la totale invarianza della metrica rispetto all'escursione dinamica globale del brano (rendendola indipendente dai livelli di *mastering*) e sopprime in modo naturale i micro-artefatti acustici transitori generati dagli algoritmi di *source separation*. Eventuali residui strumentali (*bleed*) presenti nella traccia vocale, avendo un'energia trascurabile rispetto al blocco strumentale principale, collassano matematicamente il rapporto a valori tendenti allo zero, prevenendo falsi positivi pur preservando la fedeltà del dato per la successiva astrazione semantica.

Soglia di attivazione

Per valutare la presenza vocale in modo adattivo su ogni traccia, la soglia di attivazione (T) non è preimpostata, ma viene calcolata dinamicamente tramite un algoritmo di *Bimodal K-Means Clustering*. Più nello specifico, l'intero brano viene preventivamente suddiviso in micro-frammenti temporali da 100 ms (*frame*). Per ciascuno di questi frammenti si calcola il rispettivo valore di VED. L'aggregazione di questi valori genera la distribuzione dell'energia vocale dell'intera traccia su cui opererà l'algoritmo [58]. Come illustrato in Figura 3.2, analizzando questa popolazione di dati, il modello individua due centroidi: quello del rumore di fondo (v_{noise}) e quello del cantato (v_{vocal}).

La soglia T viene posizionata geometricamente con un *bias* del 25% a partire dal rumore di fondo. Questo fattore di scala (0.25) non è una regola fissa imposta dalla letteratura, ma è un iperparametro calibrato empiricamente attraverso test iterativi su diversi brani. Poiché le tracce vocali isolate esibiscono un'altissima varianza dinamica (spaziando da transizioni sussurrate a ritornelli ad alta ampiezza), l'impiego di una soglia geometricamente simmetrica (0.50) comporterebbe un tasso inaccettabile di falsi negativi, scartando i segmenti vocali a bassa dominanza. Al contrario, un posizionamento troppo aderente al centroide del rumore rischierebbe di innescare falsi positivi a causa delle imperfezioni algoritmiche dei modelli di *source separation*. Tali modelli, infatti, possono occasionalmente lasciar trapelare residui strumentali ad alta energia (come i transienti di un colpo di cassa) all'interno della traccia vocale, un fenomeno noto nel dominio dell'ingegneria del suono come *leakage* o *drum bleed*. L'evidenza empirica ha dimostrato che un *bias* al 25% verso il *noise floor* agisce come una zona di tolleranza acustica ottimale cioè è sufficientemente basso da non perdersi i sussurri, ma abbastanza alto da non scambiare un colpo di cassa isolato per una voce umana.

A partire dalla soglia dinamica T, incrociata con i centroidi estratti (v_{noise} e v_{vocal}) e la misurazione continua della VED locale, il sistema analizza la traccia vocale

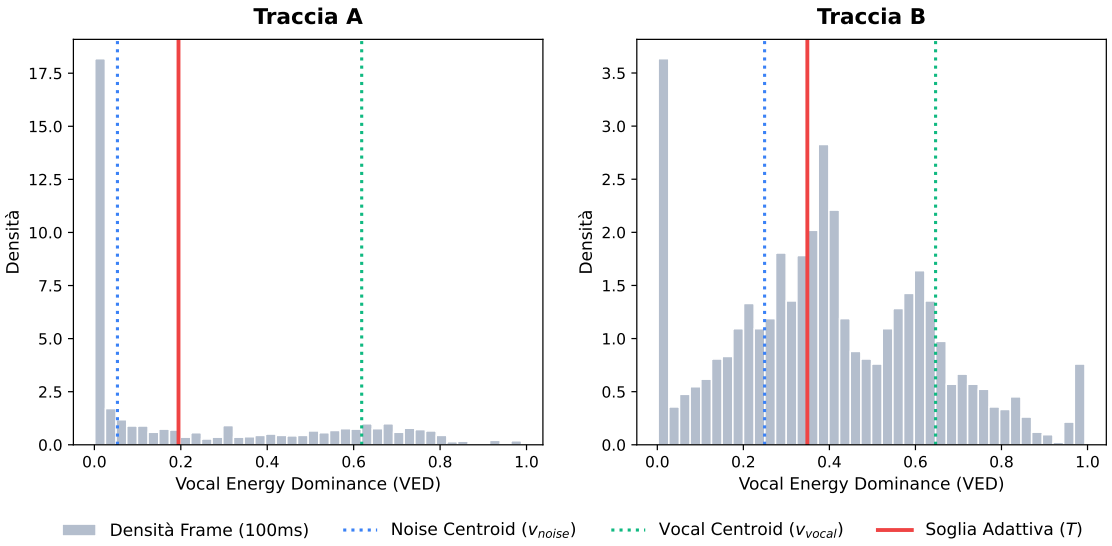


Figura 3.2: Comparazione dell'estrazione adattiva della soglia (T) su brani con escursioni dinamiche differenti. L'asse orizzontale rappresenta il valore di *Vocal Energy Dominance* (VED), mentre l'asse verticale indica la quantità di *frame* (finestre da 100 ms) che registrano tale valore. Le linee tratteggiate identificano i due centroidi (rumore e cantato) rilevati dall'algoritmo, mentre la linea solida rossa traccia la soglia finale calcolata. Nella Traccia A (*Shot Me Down*, caratterizzata da strofe cinematiche puramente acustiche in cui la voce domina su un arpeggio di chitarra isolato) la distanza tra i centroidi è netta e la soglia si posiziona in un'ampia valle energetica. Nella Traccia B (*Vielleicht Vielleicht (Holy Priest Remix)*, un brano EDM fortemente compresso in cui il cantato è presente per quasi tutta la durata, sovrapponendosi ininterrottamente alla strumentale e spalmando così la distribuzione energetica) la distanza tra il centroide del rumore e quello della voce si riduce sensibilmente, rendendo meno netta la separazione tra i due stati; tuttavia, l'applicazione del *bias* geometrico al 25% garantisce il posizionamento di un *gate* vocale sicuro e proporzionalmente ancorato al rumore di fondo reale della traccia.

isolata elaborando per ciascun *token* tre metriche acustiche specializzate. L'impiego di queste metriche si rende necessario per astrarre il dato fisico in formati semanticamente digeribili dagli agenti al livello di astrazione superiore.

Vocal Confidence

La *Vocal Confidence* trasforma il gradiente energetico continuo della VED in un indice di confidenza semantica definito nell'intervallo $[0, 1]$ tramite una funzione logistica sigmoide. Come suggerito dall'approccio di Dam et al. [57], l'impiego di funzioni sigmoidi per approssimare la *Speech Presence Probability* (SPP) rappresenta una strategia computazionalmente efficiente per mappare la transizione tra l'assenza e la presenza di voce:

$$\text{Vocal_Confidence} = \frac{1}{1 + e^{-k(\text{VED}-T)}} \tag{3.8}$$

Come anticipato, la sigmoide funge da modello computazionale per la categorizzazione. Sebbene la letteratura psicoacustica individui nelle curve psicometriche umane una pendenza moderata e pressoché invariante ($k \approx 9.4$ [56]), le sperimentazioni condotte ai fini di questo studio hanno evidenziato come, nel dominio dell'elaborazione di tracce musicali eterogenee, l'impiego di una pendenza statica risulti subottimale. L'osservazione puramente empirica ha infatti suggerito che le variazioni di escursione dinamica, dai mix acustici ariosi alle tracce EDM compresse, richiedano una responsività adattiva per non rendere ambigua l'interpretazione del segnale da parte degli agenti a valle.

Pertanto, applicando il concetto di ottimizzazione dinamica introdotto da Dam et al. [57], il sistema calcola il parametro k in funzione delle specificità acustiche di ciascun brano. A tale scopo, è stata formulata un'euristica sperimentale *ad hoc*, inedita in letteratura, che sfrutta direttamente le coordinate spaziali dei centroidi estratti dal K-Means. Tale euristica empirica impone matematicamente che la confidenza raggiunga la certezza quasi assoluta ($P = 0.99$) esattamente in corrispondenza del volume medio del cantato (v_{vocal}). Risolvendo la funzione logistica per k a partire da questo vincolo arbitrario:

$$0.99 = \frac{1}{1 + e^{-k(v_{vocal}-T)}} \implies k = \frac{\ln(99)}{v_{vocal} - T} \approx \frac{4.595}{v_{vocal} - T} \tag{3.9}$$

Sapendo che la soglia T è stata precedentemente posizionata con un *bias* del 25% tra il rumore e la voce, la distanza tra il centroide vocale e la soglia equivale al 75% della distanza totale tra i due centroidi ($\Delta = 0.75 \cdot (v_{vocal} - v_{noise})$). Sostituendo questo termine al denominatore, si ricava l'equazione adattiva finale:

$$k \approx \frac{4.595}{0.75 \cdot (v_{vocal} - v_{noise})} \approx \frac{6.126}{v_{vocal} - v_{noise}} \tag{3.10}$$

Questa derivazione empirica fa sì che il coefficiente k vari in modo automatico a seconda del contesto. Su brani acustici ad alta dinamica la formula genera una

transizione più morbida (es. $k \approx 20$); viceversa, su tracce EDM compresse, dove la separazione tra i centroidi è minima, il sistema inasprisce automaticamente la pendenza (raggiungendo anche valori $k > 50$). Come visibile nell'evoluzione temporale in Figura 3.3 (linea arancione), questa normalizzazione adattiva garantisce che i moduli a valle ricevano sempre un segnale semantico categorico e inequivocabile, operando in modo identico e affidabile su brani con caratteristiche acustiche o stili di produzione completamente diversi.

Vocal Density

Questa metrica rappresenta la percentuale di occupazione vocale all'interno del *token*. Analogamente a quanto fatto per calcolare la distribuzione globale dell'energia, il frammento audio viene suddiviso in micro-frammenti temporali continui da 100 ms (*frame*). La *Vocal Density* corrisponde al rapporto percentuale tra i *frame* la cui VED locale supera matematicamente la soglia di attivazione dinamica (VED $> T$) (visivamente rappresentati dalle barre blu nella Figura 3.3) e il numero totale di *frame* che compongono il *token*.

Vocal Intensity

Mentre la *Confidence* fornisce una probabilità di presenza e la *Density* un'occupazione spaziale, la *Vocal Intensity* misura il livello di escursione dinamica del cantante. Si ottiene normalizzando la VED locale rispetto alla distanza utile tra la soglia di tolleranza (T) e il volume medio atteso per la voce (v_{vocal}):

$$\text{Vocal_Intensity} = \frac{\text{VED} - T}{v_{vocal} - T} \tag{3.11}$$

La normalizzazione ha come risultato la definizione di un indice relativo in cui i valori assumono significati strutturali precisi. Un'intensità negativa (< 0) certifica matematicamente l'assenza di voce utile; un valore pari a 0 indica un segnale appoggiato esattamente sulla soglia di tolleranza; un valore prossimo a 1 identifica un cantato a volume standard; infine, valori > 1 segnalano i segmenti in cui il cantato risulta significativamente più spinto della media, permettendo all'LLM di intercettare dinamicamente la presenza di acuti e ritornelli ad alta energia. Inoltre, grazie alla natura normalizzata della metrica, gli agenti sono in grado di comparare l'intensità vocale in modo oggettivo tra brani radicalmente diversi, annullando le discrepanze dovute al volume di registrazione originale.

Al fine di fornire ai livelli di astrazione superiore metriche di rischio mirate, le medesime misurazioni vengono estratte anche in modo isolato sui margini del *token* (utilizzando una finestra di analisi calibrata sui BPM locali, pari alla durata temporale di uno o due battiti iniziali e finali). Questa strategia architetturale incarna

il principio della massima resa analitica con il minimo costo computazionale: anziché obbligare i moduli a valle ad analizzare l'intero *token* per identificare l'esatta interruzione vocale, il sistema calcola la probabilità di ingombro esclusivamente nei punti critici di confine tra *token* adiacenti. Ciò fornisce ai moduli a valle i confini esatti per mitigare il rischio di tagli innaturali della voce (*vocal chop*) nella segmentazione semantica e di sovrapposizioni caotiche (*vocal clash*) in un eventuale mix futuro.

Il risultato complessivo del modulo è una rappresentazione semantica compatta che sintetizza, per ciascun *token*, l'intera presenza vocale in tre descrittori aggregati: *Vocal Intensity*, *Vocal Confidence* e *Vocal Density*. Queste grandezze vengono prodotte sia a livello globale del *token* sia in corrispondenza dei margini critici di transizione (`start_edge` e `end_edge`), fornendo ai moduli a valle una mappa di rischio strutturata e direttamente interpretabile. La struttura dati risultante, illustrata nel Listato 3.2, costituisce l'interfaccia di uscita del modulo: una rappresentazione *token-efficient* che traduce la complessità acustica dell'ingombro vocale in un insieme minimo di descrittori semantici, rendendo l'informazione vocale accessibile all'agente LLM senza saturarne la *context window*.

Listing 3.2: Struttura dati delle feature vocali aggregate prodotte dal modulo Custom VAD per lo stesso *token* del brano *Satisfaction – David Guetta, Benny Benassi* illustrato nel Listato 3.1. Per ciascuna delle tre metriche (`intensity`, `confidence`, `density`) vengono esposti sia il valore globale sull'*intero token* sia i valori calcolati in isolamento sui margini critici (`start_edge`, `end_edge`), destinati alla valutazione del rischio di *vocal chop* nella segmentazione e di *vocal clash* in un eventuale mix, ai confini tra *token* adiacenti.

```
"vocal_features": {
    "start_edge": {
        "intensity":   0.93,
        "confidence":  0.99,
        "density":     0.88
    },
    "end_edge": {
        "intensity":   0.31,
        "confidence":  0.81,
        "density":     0.59
    },
    "intensity":   0.84,
    "confidence":  0.98,
    "density":     0.79
}
```

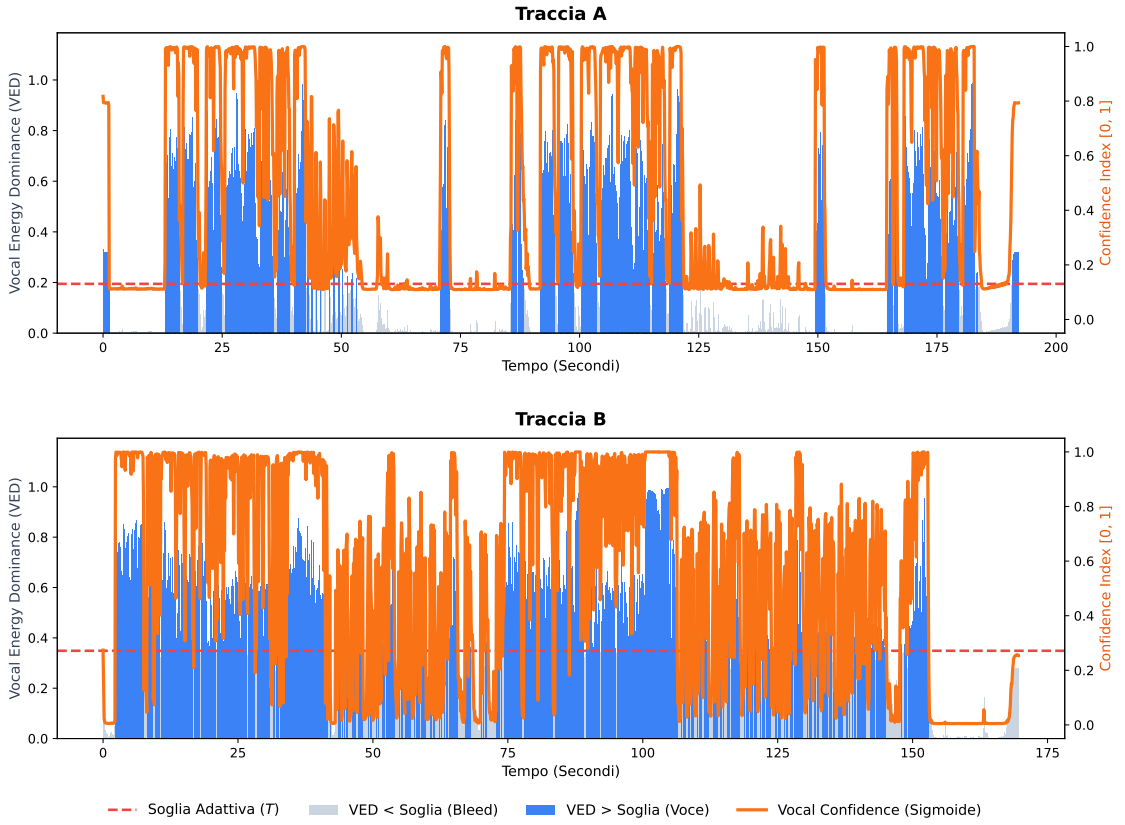


Figura 3.3: Visualizzazione della telemetria DSP di basso livello (risoluzione a 100 ms) utilizzata per il calcolo della *Vocal Density* e della *Vocal Confidence*. Al fine di chiarire le dinamiche estrattive, il grafico mostra i gradienti continui prima dell'aggregazione finale; gli agenti non operano a questa risoluzione microscopica, ma consumano esclusivamente i dati riassuntivi collassati a blocchi di 16 battiti (*token*). Il grafico illustra il passaggio dal dominio fisico a quello semantico: la *Vocal Density* è ottenuta quantificando fisicamente i *frame* la cui VED supera la soglia T (barre blu). Contemporaneamente, il gradiente fisico viene trasformato in probabilità tramite la sigmoide (linea arancione). Si osserva che nella Traccia A (*Shot Me Down*), caratterizzata da un cantato intenso alternato a silenzi acustici, e nella Traccia B (*Vielleicht*), dominata da un cantato costante ma pesantemente compresso sul rumore di fondo, la curva di confidenza esibisce il medesimo comportamento fortemente polarizzato grazie all'euristica adattiva del parametro k. Proprio in virtù di questo schiacciamento probabilistico della *Confidence*, la *Vocal Intensity* diviene una metrica compensativa cruciale: essa recupera e trasmette ai livelli superiori l'escursione dinamica reale del volume vocale, che andrebbe altrimenti irrimediabilmente persa nella categorizzazione sigmoidea.

3.3 Architettura Multi-Agente

A valle dell'estrazione telemetrica e della discretizzazione del segnale sonoro in *token* metrici, l'interpretazione strutturale e semantica della composizione è effettuata da un'architettura multi-agente sequenziale basata su LLM. In contrasto con i modelli *end-to-end* a scatola chiusa esaminati nel Capitolo 2, il sistema sviluppa un paradigma sequenziale in cui le grandezze fisiche a basso livello, calcolate in modo deterministico mediante *Digital Signal Processing* (DSP), vengono progressivamente innalzate di livello semantico attraverso una catena modulare di quattro agenti specializzati, secondo lo schema generale introdotto in Figura 1.1. Ciascun agente riceve una rappresentazione telemetrica specializzata, arricchita dalle deduzioni maturate nei passaggi precedenti, con l'obiettivo di colmare in modo controllabile e trasparente il divario tra segnale acustico e comprensione concettuale (*semantic gap*).

Il sistema si fonda sulla trasparenza e sull'ancoraggio oggettivo di ogni deduzione. Per ridurre le derive cognitive e le allucinazioni tipiche della generazione autoregressiva, a ogni agente viene imposto di elaborare una giustificazione analitica esplicita, definita *rationale*, che precede e motiva ogni decisione descrittiva o strutturale. Attraverso l'applicazione del paradigma *Chain-of-Thought*, il modello linguistico dimostra la coerenza delle proprie conclusioni richiamando i parametri fisici del DSP, le medie o i picchi locali e i riferimenti temporali del testo cantato, garantendo un funzionamento verificabile e controllabile. Inoltre viene modellata la telemetria con l'obiettivo di preservare la finestra di contesto e a prevenire il sovraccarico informativo del modello. Le grandezze estratte dal segnale comprendono infatti molteplici parametri fisici a livello di blocco, stime locali e dettagli ausiliari non tutti necessari per i compiti di ciascun modulo. L'immissione di tali dati nel prompt introdurrebbe rumore, saturando il contesto e degradando l'efficacia dell'inferenza. Il sistema applica quindi una selezione e una compressione deterministica calibrate sui bisogni informativi di ciascun nodo, oscurando le variabili ridondanti e serializzando unicamente le dimensioni acustiche pertinenti al ruolo di ogni agente.

Nelle pagine seguenti vengono esaminati i quattro agenti della sequenza, descrivendo per ciascuno il compito funzionale, le modalità di filtraggio del segnale e le strutture informative prodotte.

3.3.1 Acoustic Profiler

L'Acoustic Profiler rappresenta il nodo di ancoraggio puramente fisico dell'architettura. Agendo come un profilatore cieco (*Blind Profiler*), il modulo ha il compito di inferire il macro-genere musicale, la classe energetica globale, il profilo della presenza vocale e la traiettoria dinamica dell'opera affidandosi esclusivamente alle proprietà acustiche del segnale ed escludendo qualsiasi informazione anagrafica o titolo dell'opera.

Al modulo non vengono passati titolo e autore per evitare che la memoria pregressa del modello linguistico condizioni l'analisi. L'attribuzione del genere resta così vincolata alle sole grandezze del segnale, ad esempio se una traccia registra 174 BPM e un'elevata energia sulle basse frequenze, il sistema la cataloga come *Drum & Bass* anche qualora il testo cantato rimandi a una ballata melodica.

L'analisi vocale è inoltre regolata da un meccanismo di verifica fisica, concepito per raccordare i parametri acustici estratti dal modulo di VAD (Sezione 3.2.3) con il testo trascritto. Basandosi sulla metrica di *Vocal Intensity* (Equazione 3.11), l'agente discrimina l'effettiva emissione canora da allucinazioni o rumori di fondo, infatti, valori di intensità positivi accompagnati da testo coerente identificano la voce principale in primo piano, valori positivi in assenza di testo indicano vocalizzi, cori o frammenti vocali sintetizzati non rilevati dal riconoscimento fonetico, mentre un'intensità debole o negativa in presenza di testo valido segnala voci campionate o collocate sullo sfondo e, infine, valori nulli o negativi associati a frammenti sconnessi permettono di intercettare e scartare le allucinazioni generate sul rumore strumentale.

L'agente elabora inoltre i marcatori di continuità vocale (*bleed*), i quali segnalano che una frase cantata si estende oltre il confine del blocco metrico corrente per un intervallo in millisecondi. Questa informazione viene integrata nella descrizione della traiettoria dinamica come un ponte vocale continuo che unisce i token adiacenti.

Nella rappresentazione telemetrica fornita all'agente i metadati relativi al titolo, all'autore e ai percorsi dei file vengono rimossi in modo sistematico. Per consentire all'agente di contestualizzare le variazioni locali ed evitare il sovraccarico informativo, il sistema aggrega le metriche DSP di ciascun token in una media e nei picchi globali della traccia (escludendo i blocchi di inizio e fine). A livello di singolo blocco metrico, i cue point rilevati vengono sintetizzati in indicatori categorici di inizio, fine o compresenza, le caratteristiche vocali di bordo vengono discretizzate tramite soglie di confidenza, densità e intensità e, infine, il vettore descrittivo include unicamente le dieci grandezze fisiche primarie e il tempo metronomico, scartando i dati grezzi privi di normalizzazione.

L'output del modulo descrive il profilo acustico complessivo con un macro-profilo comprendente generi dedotti, livello energetico e relativa giustificazione, un profilo

vocale che descrive grado di presenza, validità del testo e motivazione, e una traiettoria dinamica che illustra l'evoluzione temporale dell'energia ancorandola agli indici dei blocchi e ai ponti vocali.

3.3.2 Cultural Researcher

Il secondo modulo della catena elaborativa assume la funzione di storico culturale della traccia, con il compito di inquadrarne il contesto artistico e musicale. A differenza del profilatore acustico, qui l'agente riceve titolo e artista e può effettuare ricerche sul web in tempo reale: confrontando queste informazioni con il testo cantato, risale all'opera originaria per chiarire se si tratti di una registrazione originale, di una reinterpretazione, di un campionamento o di un *remix*. Qualora, per esempio, i dati anagrafici indichino un produttore contemporaneo ma il testo coincida con un classico degli anni sessanta, il modulo identifica autore, anno e titolo della composizione originale e nota che l'artista corrente ha reinterpretato un brano del passato.

L'agente confronta inoltre il genere culturale originario con le informazioni ricavate dal profilo acustico in uscita dal precedente agente, rilevando eventuali mutazioni di genere, come nel caso di un brano folk acustico riarrangiato a velocità raddoppiata per il contesto della musica elettronica. Parallelamente, il modulo stima l'impatto culturale del brano, discriminando produzioni di risonanza globale da opere di nicchia, e inquadra il pubblico di riferimento e lo stile predominante. Al Cultural Researcher è tuttavia fatto divieto assoluto di avanzare ipotesi sull'articolazione temporale interna o sulla collocazione dei confini tra sezioni, compito che compete esclusivamente ai moduli successivi.

I dati forniti in ingresso a questo modulo vengono ridotti all'essenziale. Il contesto acustico proveniente dal primo agente viene integrato escludendo il suo rationale, superfluo per un'indagine storiografica. I metadati di titolo e autore vengono inseriti, mentre l'intera sequenza temporale dei blocchi metrici e delle metriche DSP viene omessa, evitando di sovraccaricare il contesto del modello con informazioni non strettamente necessarie. Il modulo riceve unicamente i parametri globali di tonalità, tempo metronomico e durata, unitamente al testo cantato aggregato e al relativo indicatore di affidabilità.

L'output del modulo formalizza l'identità dell'opera di provenienza, la dimensione dell'impatto culturale e la sintesi del contesto storico, la classificazione dell'arrangiamento e le note deduttive del ricercatore (il suo rationale).

3.3.3 Token Captioner

Il Token Captioner opera come tramite semantico tra la modellazione matematica del segnale e il linguaggio naturale a livello locale. Attraverso una singola esecuzione sull'intera sequenza temporale, genera una didascalia per ciascun token.

L'agente integra la telemetria locale con il lessico dedotto dai moduli precedenti, infatti, condizionato dal contesto culturale e dal profilo acustico, impiega una terminologia conforme al genere individuato. Ad esempio, per una produzione di musica techno o elettronica farà ricorso a espressioni musicologiche mirate quali percussioni distorte, transienti incisivi o compressione dinamica pronunciata, tralasciando descrizioni generiche estranee alla prassi produttiva del settore.

Ogni didascalia si concentra sugli eventi sonori compresi nei sedici battiti in esame e all'agente è proibito l'uso di etichette macro-strutturali, quali definire un segmento come strofa o ritornello, demandando l'organizzazione formale al modulo di segmentazione. In presenza di parti cantate, il modello non trascrive i versi, bensì ne caratterizza gli aspetti percettivi ed espressivi, descrivendo timbro, registro, sesso percepito, spazialità ed eventuale presenza di riverbero o manipolazioni elettroniche grazie al contesto dei moduli precedenti. Un limite noto del sistema risiede infatti nella "sordità al timbro", ossia nell'assenza di dati telemetrici che ne consentano un'identificazione deterministica, aspetto che viene approfondito nella sezione dedicata alle limitazioni e agli sviluppi futuri (Sezione 3.4). Per preservare densità e rigore espositivo, ciascuna didascalia è soggetta a un limite di lunghezza configurabile come parametro che è stato fissato a 20 parole come compromesso di default anche analizzando le didascalie generate dai sistemi concorrenti.

La vista telemetrica fornita a questo stadio include i profili acustico e culturale depurati dalle sezioni argomentative intermedie, ripristina titolo e autore per orientare il lessico stilistico e presenta l'array dei blocchi metrici provvisti delle dieci grandezze fisiche primarie, del tempo metronomico, degli indicatori sintetici di cue point e della presenza vocale ai margini.

La struttura informativa prodotta contiene la sequenza ordinata delle didascalie locali, corredate ciascuna dall'indice del blocco e da una sintetica giustificazione che ricollega le scelte descrittive ai valori numerici e alle ancore globali.

3.3.4 Semantic Segmenter

L'ultimo componente della sequenza è il Semantic Segmenter, a cui è affidato il ruolo di architetto macro-strutturale. Il suo compito consiste nel raggruppare la sequenza ordinata di didascalie locali e di descrittori fisici, delineando le partizioni formali della composizione musicale (quali introduzione, strofe, ritornelli, passaggi di transizione, sezioni strumentali e code) e superando la frammentazione imposta dalla griglia metrica di base.

Il modello consente di modulare la risoluzione temporale attraverso un parametro di granularità, la cui impostazione influenza il numero di sezioni identificate in base alla durata del brano. Ad esempio, una risoluzione bassa delimita macro-sezioni ampie, orientativamente tra cinque e sette blocchi, una risoluzione media definisce una partizione canonica adatta a brani commerciali ed elettronici, compresa tra nove e dodici sezioni, infine, una risoluzione alta permette di isolare stacchi veloci, transizioni e passaggi di durata pari a un singolo token. Nel modello di riferimento la granularità è media, scelta ponderata osservando la struttura tipo dei brani in dataset.

Al fine di unire la compatibilità con i protocolli accademici alla precisione descrittiva, il sistema adotta una tassonomia a doppio strato. Il primo livello è vincolato alle sette classi canoniche consolidate nella letteratura del settore e nei protocolli di valutazione MIREX (si veda 2.2):

$$\mathcal{C}_{\text{standard}} = \{\text{intro}, \text{verse}, \text{chorus}, \text{bridge}, \text{inst}, \text{outro}, \text{silence}\}$$

Il secondo livello assegna a ciascuna sezione una denominazione descrittiva aderente allo stile del brano dedotto dal contesto culturale identificato in precedenza (ad esempio la distinzione tra sezioni di accumulo di tensione, rilasci ritmici energici o intermezzi atmosferici per la musica elettronica, oppure assoli strumentali e ritornelli per il rock). Inoltre, vincolare il modello a un numero prefissato di classi aiuta ad ancorarne l'attenzione, riducendo il rischio di allucinazioni.

I segmenti individuati coprono la traccia in modo contiguo, senza vuoti o sovrapposizioni. Per preservare la coerenza musicale, non è possibile collocare un confine strutturale spezzando a metà una frase cantata. Infine, la macro-didascalia di ogni sezione sintetizza l'evoluzione dinamica e strumentale dell'intervallo usando le singole descrizioni dei token come riferimento, anziché limitarsi a concatenarle.

In ingresso, a ciascun token viene associata la didascalia elaborata dal Token Captioner. Inoltre, a differenza dei moduli precedenti che ricevevano un'indicazione vocale semplificata, per la segmentazione vengono forniti i valori continui di confidenza, densità e intensità sui bordi del blocco, offrendo il dettaglio necessario per posizionare i tagli senza troncare il cantato.

L'output del modulo organizza i segmenti identificati riportandone indice, etichetta standard, denominazione descrittiva, intervallo di blocchi coperti, macro-didascalia e un rationale dettagliato che motiva i confini richiamando le discontinuità nel flusso spettrale, i salti nel rapporto di basse frequenze, le variazioni ritmiche e l'assenza di canto sulle giunzioni temporali.

3.3.5 Sintesi Comparativa della Modellazione Telemetrica

Le scelte metodologiche di filtraggio e trasformazione della telemetria mostrano come ciascun agente riceva una proiezione del segnale calibrata sulla specifica finalità operativa. La Tabella 3.2 riassume comparativamente la gestione dei flussi informativi e dei vincoli di ingresso lungo l'intera sequenza. Parallelamente, la Tabella 3.3 sintetizza i parametri di inferenza adottati per ciascun nodo decisionale nella configurazione di riferimento dell'architettura.

Dimensione o flusso	Acoustic Profiler	Cultural Researcher	Token Captioner	Semantic Segmenter
Ruolo funzionale	Profilatore cieco DSP	Storico culturale	Didascalie a 16 battiti	Architetto macro-sezioni
Metadati nominali (titolo, autore)	Oscurati	Inclusi	Inclusi	Inclusi
Sequenza temporale dei blocchi	Inclusa	Rimossa totalmente	Inclusa	Inclusa
Didascalia locale nel blocco	Assente	Assente	Assente	Iniettata dal Captioner
Rappresentazione feature vocali	Categorie sintetiche	Assente	Categorie sintetiche	Ripristino dettagli continui
Marcatori cue point	Categorie sintetiche	Assente	Categorie sintetiche	Categorie sintetiche
Trascrizione del testo cantato	Per blocco con bleed	Globale aggregata	Per blocco con bleed	Per blocco con bleed

Tabella 3.2: Quadro comparativo della modellazione telemetrica e dei flussi informativi per i quattro agenti della sequenza. Come descritto nel diagramma generale dell'architettura (Figura 1.1), il contesto informativo viene propagato lungo la catena in modo sequenziale, omettendo le argomentazioni del *rationale* per preservare la finestra di contesto.

Parametro di inferenza	Acoustic Profiler	Cultural Researcher	Token Captioner	Semantic Segmenter
Modello linguistico	Gemini 3.8 Flash	Gemini 3.8 Flash	Gemini 3.8 Flash	Gemini 3.8 Flash
Temperatura di campionamento (T)	0.1	0.2	0.5	0.7
Strumento di ricerca sul web	Disabilitato	Abilitato	Disabilitato	Disabilitato
Livello di ragionamento interno	Basso	Basso	Basso	Alto

Tabella 3.3: Configurazione dei modelli linguistici e parametri di inferenza per i quattro agenti nella configurazione di riferimento. L'impiego uniforme di Gemini 3.8 Flash riflette l'assetto che ha conseguito le migliori prestazioni empiriche; varianti con modelli a differente scala sono esaminate nel capitolo di valutazione sperimentale.

Logica di Configurazione dei Parametri di Inferenza

La scelta dei parametri di generazione riportati in Tabella 3.3 risponde a una precisa progressione ingegneristica: l'architettura muove dal determinismo matematico a bassa latenza dei nodi iniziali di analisi fisica per culminare nel ragionamento deduttivo profondo e nell'espressività narrativa del modulo di sintesi globale.

Acoustic Profiler ($T = 0.1$, reasoning basso). Operando come analizzatore cieco privo di metadati esterni, il modulo deve limitarsi a proiettare le grandezze acustiche estratte dal segnale nelle rispettive categorie stilistiche e vocali. Una temperatura quasi deterministica (0.1) impedisce deviazioni tassonomiche o l'invenzione di generi non supportati dalle soglie fisiche. Il basso livello di ragionamento interno è coerente con un'elaborazione basata su regole condizionali dirette (quali il gating vocale fondato su intensità ed energia dei transienti), azzerando la latenza senza richiedere pianificazioni multi-passo.

Cultural Researcher ($T = 0.2$, reasoning basso). Il compito del modulo consiste nell'identificare l'opera e disambiguare eventuali versioni alternative, bootleg o remix tramite interrogazione web. Il valore $T = 0.2$ offre la minima flessibilità lessicale per formulare query di ricerca efficaci e riconciliare discrepanze anagrafiche, bloccando le allucinazioni su date, cataloghi o sull'effettivo impatto storico del brano (evitando di attribuire risonanza sproporzionata a tracce di nicchia). Anche in questo caso il ragionamento interno è mantenuto basso dato che l'agente deve unicamente inoltrare le query alle API di ricerca ed estrarre i riscontri oggettivi.

Token Captioner ($T = 0.5$, reasoning basso). L'adozione di un livello di ragionamento basso è necessaria per evitare l'esplosione dei tempi di inferenza e dei costi di contesto, inoltre, il modulo deve descrivere unicamente gli eventi racchiusi nell'intervallo corrente, demandando la visione globale al modulo successivo. La temperatura a 0.5 rappresenta il compromesso ideale, infatti una temperatura troppo rigida ($T \leq 0.2$) provocherebbe un appiattimento espressivo con descrizioni monotone e ripetitive, mentre valori elevati ($T \geq 0.7$) causerebbero lo sforamento del vincolo di brevità (fissato a 20 parole) o l'introduzione di elementi non supportati dalla telemetria.

Semantic Segmenter ($T = 0.7$, reasoning alto). Rappresentando il punto di sintesi strutturale dell'intera catena, il Segmenter affronta il problema cognitivo più complesso cioè conciliare la granularità richiesta con i salti dei gradienti acustici (ad esempio i cali repentini di flusso spettrale ed energia ritmica), verificare la continuità dei bordi vocali per prevenire tagli innaturali del cantato e formulare una catena di ragionamento che motivi i confini temporali assegnati. Tale ottimizzazione multivincolo giustifica l'allocazione dell'intero budget di ragionamento interno (*high*). Parallelamente, la temperatura a 0.7 consente di produrre una macro-didascalia dalla prosa fluida e coesa, superando la semplice concatenazione meccanica delle didascalie locali.

3.3.6 Sintesi Deterministica

Terminata l'inferenza del Semantic Segmenter, una procedura deterministica assembla tutti i dati in un unico JSON strutturato, senza ulteriori chiamate ai modelli linguistici. Il processo unisce i metadati globali al profilo acustico e culturale, converte i riferimenti temporali di token e cue point in secondi associandovi le relative didascalie, e raggruppa infine i blocchi all'interno delle macro-sezioni.

Il documento finale fornisce una rappresentazione integrata del brano, spendibile sia nell'indicizzazione semantica (*Cross-Modal Music Retrieval*, Sezione 4.5.5) sia nel mixaggio automatico (Sezione 3.4). Come mostrato in Figura 3.4 per *Shot Me Down*, la segmentazione ottenuta si allinea qualitativamente alle variazioni fisiche del segnale.

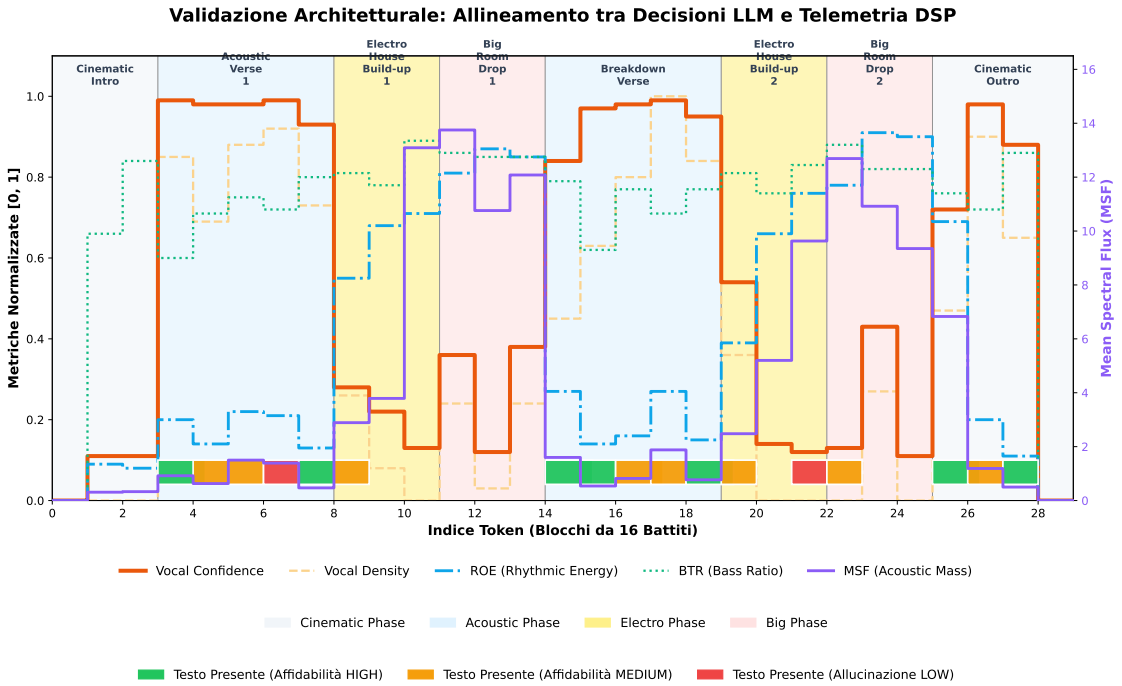


Figura 3.4: Il grafico illustra la correlazione temporale tra i descrittori acustici estratti e la segmentazione strutturale dedotta dal sistema, prendendo in esame il brano *Shot Me Down*. Questa traccia è particolarmente indicata poiché alterna fasi cantate e totalmente acustiche a sezioni caratterizzate da intensi *drop* EDM. Come emerge chiaramente dalla figura, la segmentazione operata dal sistema va di pari passo con l'evoluzione dei valori telemetrici. L'asse delle ascisse riporta l'indice token, misurato in blocchi da 16 battiti. L'asse delle ordinate principale (a sinistra) espone le metriche normalizzate nell'intervallo [0, 1], includendo *Vocal Confidence*, *Vocal Density*, *ROE (Rhythmic Energy)* e *BTR (Bass Ratio)*. L'asse secondario (a destra) traccia i valori della *Mean Spectral Flux (MSF)*, indicativa della massa acustica. Le bande verticali identificano i segmenti strutturali del brano rilevati dal sistema. Alla base del grafico, appositi indicatori cromatici qualificano l'affidabilità della trascrizione testuale, categorizzandola come *Testo Presente* con affidabilità *HIGH*, *MEDIUM* o segnalando un rischio di allucinazione *LOW*.

3.4 Limiti e Sviluppi Futuri

Nonostante l'architettura proposta offra un approccio robusto alla segmentazione e alla descrizione musicale, il sistema presenta alcune limitazioni architetturali intrinseche che ne definiscono il perimetro di applicabilità.

In primo luogo, il *Cultural Researcher* si basa sui metadati in ingresso (titolo e autore) per stabilire il posizionamento storico e stilistico del brano. In scenari in cui tali metadati siano assenti o del tutto generici, l'agente rischia di dedurre un *Cultural Prior* inesatto; a causa della natura sequenziale della *pipeline*, questa

allucinazione si propagherebbe a cascata sui moduli successivi, compromettendo la coerenza del vocabolario adottato dal *Token Captioner*. A questo si aggiunge il fatto che attualmente la telemetria DSP estrae metriche legate all'energia, al ritmo e alla presenza vocale, ma risulta "sorda" alla strumentazione (faticando, ad esempio, a distinguere una chitarra acustica da un sintetizzatore a parità di intensità). Ciò costringe il sistema a dedurre gli strumenti incrociando l'andamento energetico con il *Cultural Prior*, un limite che in sviluppi futuri verrà superato integrando l'output di un modulo di *tagging* acustico dedicato.

Ulteriori vincoli derivano dalle scelte di dominio e di quantizzazione: il sistema è stato infatti ottimizzato primariamente per la musica elettronica (EDM) e per brani con struttura metrica in 4/4. Sebbene l'estrazione fisica del DSP mantenga validità universale, le regole deduttive imposte ai *Large Language Models* potrebbero faticare a interpretare correttamente ritmiche complesse (come i tempi dispari) o generi musicali fluidi e non allineati alla griglia. Infine, la decisione di quantizzare l'audio in finestre fisse da 16 battiti rappresenta un compromesso obbligato per contenere il carico computazionale e il consumo di *token*. Di conseguenza, l'architettura opera con una risoluzione macroscopica a livello di *clip*, rinunciando a un'analisi di fino sui singoli *frame* temporali e risultando inadatta all'individuazione di micro-eventi acustici transitori.

Capitolo 4

Valutazione Sperimentale

Il presente capitolo descrive il protocollo sperimentale con cui è stata validata l'architettura proposta e ne riporta i risultati. L'obiettivo è verificare se un'architettura modulare e interpretabile, in alternativa a una modellazione puramente *black-box*, produca una struttura accurata e didascalie ancorate al segmento che descrivono. La valutazione si articola in due macro-sezioni interdipendenti. La prima si concentra sull'accuratezza strutturale (RQ1) e misura la precisione del partizionamento temporale e della classificazione delle sezioni. La seconda riguarda l'accuratezza semantica (RQ2) e verifica la coerenza interna delle didascalie generate rispetto al segmento audio che descrivono.

Per garantire una validazione imparziale e scongiurare fenomeni di *cherry-picking*, l'intera batteria di test opera su un campionamento stratificato, concepito per sottoporre l'architettura a livelli di stress acustico crescenti. Le 50 tracce del corpus (Sezione 4.1) sono ripartite in tre fasce: 25 tracce *in-domain* (musica elettronica in 4/4, ambiente nativo del sistema), 15 *middle-ground* (ritmiche in 4/4 ma con timbriche eterogenee, come pop, hip hop e R&B) e 10 *out-of-domain* (rock, metal e blues, senza restrizioni ritmiche, per misurare la tenuta del sistema su pattern irregolari).

Le misurazioni sono confrontate con sistemi di riferimento (Sezione 4.2). Per il partizionamento temporale (*Music Structure Analysis*) la *baseline* primaria è SongFormer [9]. Per l'accuratezza semantica e la generazione testuale a formato esteso (*long-form captioning*) il confronto è con FUTGA [6], l'unica *baseline* aperta che produce segmentazione e didascalie per segmento. Il confronto include anche tre varianti della pipeline (Flash, Pro e Lite) e un test con audio diretto, senza telemetria DSP. Non è stato possibile impiegare modelli più recenti, come FUTGA-MIR o il sistema proposto da Bukey *et al.* [12], perché i rispettivi pesi non sono pubblici. I sistemi sono stati eseguiti una sola volta sulle 50 tracce e i risultati sono

stati salvati (Sezione 4.3). Il repository del progetto contiene il dataset, i risultati e quanto serve per rigenerarli.[1]

Il principale ostacolo metodologico in ambito MIR è l'assenza di un *ground truth* testuale annotato da esperti a livello di segmento strutturale. Per questo la valutazione semantica non confronta le didascalie con un riferimento esterno. Esplora il problema su assi complementari: l'ancoraggio di ogni didascalia al proprio segmento, la capacità di ritrovare il segmento giusto tra segmenti di brani diversi, e la coerenza delle attivazioni ripetute con la classe funzionale.

Il capitolo è organizzato così. La Sezione 4.1 descrive il corpus e il partizionamento, la Sezione 4.2 le *baseline* e la Sezione 4.3 la generazione dei dati di inferenza. Le Sezioni 4.4 e 4.5 riportano la valutazione di RQ1 e di RQ2. La Sezione 4.6 discute i limiti del lavoro e la Sezione 4.7 presenta gli sviluppi futuri della valutazione.

4.1 Dataset e Partizionamento dei Dati

4.1.1 Dataset di Riferimento: SongFormBench-HS

Il corpus di valutazione impiegato non coincide direttamente con la release originaria di HarmonixSet [59], bensì con SongFormBench-HS [9], il *benchmark* standard introdotto dai ricercatori di SongFormer.

L'utilizzo diretto di HarmonixSet avrebbe esposto l'esperimento a problemi di disallineamento temporale, i curatori del *dataset* primario, infatti, forniscono unicamente riferimenti a video YouTube, i cui flussi audio differiscono frequentemente dalle annotazioni cronologiche ufficiali per via di tagli di montaggio, dissolvenze e interventi di post-produzione. Anche filtrando il corpus sui brani ad alta confidenza algoritmica, l'incertezza strutturale non viene eliminata. SongFormBench-HS risolve alla radice questa criticità fornendo file audio nativi già sincronizzati con le annotazioni del *ground truth*. Dal corpus, escludendo la variante SongFormBench-CN per evitare variabili stilistiche extra-occidentali, sono state selezionate 50 tracce di test.

4.1.2 Partizionamento e Stratificazione per Domini

La strategia di partizionamento dei campioni si applica a tutti i task di valutazione, e punta a evitare il *cherry-picking*, imponendo una distribuzione dei dati calibrata per testare l'architettura su livelli di stress crescenti. Le 50 tracce selezionate sono ripartite nei tre domini operativi sintetizzati in Tabella 4.1.

[1] `https://github.com/ApuMbett/tesi_msa`

Split	N (%)	Generi e Metrica	BPM ($\mu \pm \sigma$)
In-Domain	25 (50%)	Dance, EDM, Club Mix (4/4)	125.0 ± 12.6
Middle-Ground	15 (30%)	Pop, Hip-Hop, R&B (4/4)	104.7 ± 23.2
Out-of-Domain	10 (20%)	Rock, Metal, Blues (libera)	121.1 ± 59.0
Totale	50 (100%)	Corpus SongFormBench-HS	118.2 ± 30.8

Tabella 4.1: Caratteristiche e partizionamento del dataset di valutazione estratto da SongFormBench-HS [9] (derivato da HarmonixSet [59]). I valori di BPM indicano media e deviazione standard (range globale $[59, 237]$). Nello split Out-of-Domain la durata media dei brani è di 254 s.

Il sottoinsieme *in-domain* raccoglie musica Dance ed Electronic (tra cui produzioni club mix, electro house ed EDM), contraddistinta da un andamento ritmico regolare, una scansione metrica in 4/4 e un'elevata densità di micro-sezioni funzionali. Questa partizione rappresenta l'ambiente operativo nativo per cui la *pipeline* è stata ottimizzata.

La fascia intermedia, designata come *middle-ground*, è dominata da brani Pop affiancati da produzioni Hip-Hop e R&B. Pur preservando la costanza della griglia metrica in 4/4, introduce una maggiore eterogeneità timbrica e stilistica, accompagnata da andamenti ritmici più distesi, la regolarità strutturale di fondo permane, a fronte di una crescente complessità negli arrangiamenti.

Infine, il sottoinsieme *out-of-domain* comprende generi acusticamente ed espressivamente distanti dalla produzione elettronica, quali Rock, Metal, Grunge, Blues, Alternative e Country. In questo contesto cadono i vincoli di regolarità metrica, mentre aumentano l'escursione del tempo e la dilatazione delle sezioni formali. Ha l'obiettivo di valutare la capacità di generalizzazione del sistema al di fuori dei vincoli di progettazione originari.

4.2 Baselines di Riferimento

4.2.1 Impostazione del Confronto

Al fine di condurre una valutazione rigorosa, l'architettura proposta è stata confrontata con lo stato dell'arte, articolando i modelli di riferimento (*baseline*) in base ai due macro-obiettivi del sistema: l'analisi strutturale e la resa semantica. Per ciascuno dei due si è cercato il sistema più rappresentativo tra quelli di cui è disponibile un'implementazione eseguibile, perché un confronto empirico richiede pesi pubblici e la possibilità di rilanciare il modello sui brani del campione utilizzato.

4.2.2 Baseline per l'Accuratezza Strutturale

Per quanto riguarda l'accuratezza strutturale (*Music Structure Analysis*, MSA), il modello assunto come *baseline* primaria è SongFormer [9], attuale stato dell'arte nel partizionamento temporale. A questo è stato affiancato un confronto con FUTGA [6], sebbene la segmentazione MSA non costituisca l'obiettivo primario di quest'ultimo, l'affinità architetturale rende la comparazione necessaria. Tra i sistemi disponibili, FUTGA è infatti l'unico che produce insieme una partizione temporale e una didascalia per ciascun segmento, la stessa uscita del sistema proposto.

4.2.3 Baseline per l'Accuratezza Semantica e il Music Captioning

Per l'accuratezza semantica e del *music captioning*, il panorama dei modelli disponibili è vasto, ma severamente limitato per quanto riguarda la generazione di descrizioni a formato esteso (*long-form captioning*). I sistemi di *captioning* precedenti, come LP-MusicCaps [5], BLAP [43] e MusicLM, lavorano su clip isolate di circa dieci secondi o sull'intera traccia, non modellando l'evoluzione temporale e non producendo didascalie per segmento.

L'unico sistema pienamente comparabile è FUTGA [6]. È l'unico sistema con pesi aperti che produce congiuntamente segmentazione temporale e *captioning* esteso con localizzazione temporale. Senza FUTGA il confronto si sarebbe ridotto a SongFormer, che restituisce etichette prive di contenuto semantico.

È opportuno precisare il ruolo di FUTGA. Non rappresenta più la frontiera del settore, perché la sua evoluzione FUTGA-MIR [48] lo supera, e non nasce per l'analisi strutturale. È addestrato su brani sintetici ottenuti concatenando da tre a cinque clip e produce circa quattro segmenti per brano, nel *paper* la media del dataset di didascalie generato dal modello è di 4.32 segmenti (Tabella 2 di [6]). FUTGA va quindi inteso come l'unica *baseline* aperta disponibile, non come stato dell'arte assoluto, e il numero di segmenti per brano è trattato nel seguito come una variabile del confronto (Sezione 4.4.8). Va inoltre dichiarato che FUTGA è stato raffinato su HarmonixSet [6], da cui deriva il corpus utilizzato, il confronto contiene dunque un possibile vantaggio a suo favore, mentre la pipeline proposta opera senza alcun addestramento sul compito.

Si può obiettare che il confronto con FUTGA non è alla pari sul piano informativo. FUTGA riceve soltanto l'audio, mentre la pipeline dispone anche della trascrizione del testo e della telemetria DSP, che sono però moduli interni della catena di elaborazione, e, nelle varianti Flash e Pro, della ricerca web (*search grounding*). La differenza è stata dichiarata e, per ridurne il peso, è stata inclusa la variante Lite, priva di *search grounding*.

Restano esclusi i sistemi i cui pesi non sono stati pubblicati. Né FUTGA-MIR [48], pur rappresentando l'attuale vertice prestazionale del settore, né il lavoro di Bukey *et al.* [12] sono impiegabili come *baseline* empiriche per la mancata pubblicazione dei modelli pre-addestrati. Lo stesso vale per Music Flamingo [11] e per le recenti evoluzioni della serie Audio Flamingo. All'avvio del presente lavoro i pesi di Music Flamingo non erano pubblici, sono stati resi disponibili successivamente. Anche con i pesi a disposizione, il confronto non sarebbe stato praticabile poiché i due modelli appartengono a una classe dimensionale fuori scala rispetto alle risorse disponibili, e Music Flamingo non produce nativamente una segmentazione con didascalia per sezione, quindi non è direttamente comparabile sul compito di questa tesi. I riferimenti praticabili restano FUTGA e i modelli generalisti di frontiera alimentati con audio grezzo, impiegati nella verifica di Sezione 4.4.6.

Infine, i modelli generici di localizzazione di eventi audio, come AudioMap e TAC, risolvono compiti di rilevamento di eventi sonori e non la forma musicale, e sono stati quindi esclusi dal confronto.

4.2.4 Sistemi non Confrontati

Restano non confrontati SonicVerse [13] e BLAP [43], modelli di *captioning* globale che non producono didascalie per sezione e che non sono stati investigati come possibili *baseline*. Rimangono come possibile estensione del lavoro.

4.2.5 Esecuzione delle Baseline

Le modalità con cui SongFormer e FUTGA sono stati eseguiti sulle 50 tracce, comprese le modifiche necessarie per renderli eseguibili sull'hardware disponibile, sono descritte nella Sezione 4.3.

4.3 Generazione dei Dati di Inferenza

Ogni sistema è stato eseguito una sola volta sulle 50 tracce di SongFormBench-HS e i risultati sono stati salvati. Le metriche di RQ1 e RQ2 sono calcolate su questi file, senza rilanciare i modelli. FUTGA e la pipeline producono sia la segmentazione con etichette (RQ1) sia le didascalie per segmento (RQ2) mentre SongFormer solo la segmentazione, quindi entra solo in RQ1.

Il repository GitHub del progetto[2] contiene il dataset, tutti i risultati e quanto serve per rigenerarli.

[2] `https://github.com/ApuMbett/tesi_msa`

4.3.1 Esecuzione di SongFormer

SongFormer è stato eseguito su Google Colab con una GPU T4, usando il checkpoint pubblico e lo script ufficiale `infer.sh`, con il post-processing a regole attivo.

Su alcuni brani lunghi la memoria della T4 non bastava. L'attenzione di MuQ costruisce due volte la matrice completa frame per frame, con un'allocazione di circa 5.5 GiB. È stato sostituito il calcolo con `scaled_dot_product_attention` di PyTorch. All'avvio la modifica si confronta con l'attenzione originale su un tensore di prova e si disattiva se i risultati non coincidono.

Inizialmente si riteneva che il problema fosse la precisione. Il confronto fp16/fp32 ha dato risultati uguali su quasi tutte le tracce, ma sei andavano comunque in esaurimento di memoria anche in fp16. La precisione è rimasta quella di default.

Per controllare che la modifica non cambi i risultati, sono state valutate con gli script ufficiali le 44 tracce che giravano anche senza modifica, le metriche aggregate sono identiche a tutte le cifre. Le altre sei sono state ottenute solo con la modifica, e non esiste un riferimento senza. Visto che sulle 44 i risultati coincidono, è improbabile che differiscano, ma non è una prova. Le sei tracce restano nel campione. Gli output sono convertiti in testo (segmenti con etichetta) con `convert_res2msa_txt.py`.

4.3.2 Esecuzione di FUTGA

Ambiente e modello. FUTGA-7B è stato eseguito su Kaggle con due GPU T4, con le versioni di librerie del 2023 compatibili con il codice originale. Il modello è quello del paper [6]: Whisper Large v2 e BEATs come encoder, un Q-Former derivato da SALMONN e Vicuna-7B v1.5 con adattatori LoRA. Il link del checkpoint di BEATs non funzionava più; è stato usato un mirror su Hugging Face con lo stesso hash MD5 del file degli autori.

Parametri. I parametri sono quelli del paper: `num_beams`= 10, `repetition_penalty`= 1.5 [47], `max_length`= 2048, `temperature`= 0.2, `top_p`= 0.7, in FP16. È stato modificato il codice (`model.py`) solo per farlo girare sulle T4: Vicuna è diviso sulle due GPU, `target_modules` è impostato a `q_proj` e `v_proj` per compatibilità con PEFT, e la finestra audio di BEATs è limitata a 30 secondi.

Finestra di 30 secondi. Whisper elabora al massimo 30 s e, nel codice originale, i token di BEATs oltre il frame 1 500 vengono scartati senza avviso. Il codice rilasciato dà a BEATs fino a 240 s, ma l'85% dei token calcolati si perde. Ne segue che FUTGA vede solo i primi 30 secondi del brano, anche se il prompt chiede l'intera durata.

BEATs è bidirezionale, quindi una finestra più ampia potrebbe passare ai token rimasti un po' di contesto globale. Si è comunque preferito limitare a 30 s l'audio inviato a BEATs, per evitare un sovraccarico di memoria sulla GPU T4 dato che con 240 s l'attenzione richiederebbe circa 18.5 GiB. Con 75 s, il massimo possibile, i confini si sono spostati di circa l'1% e ci sono stati arresti per frammentazione della memoria. In questo test l'effetto del contesto aggiuntivo è sembrato trascurabile, ma non si può affermare che sia nullo.

Anche le didascalie usate in RQ2 vengono da questa inferenza e descrivono la stessa finestra, un limite del confronto, ripreso in Sezione 4.5.3.

Esecuzione. Prima del batch è stato confrontato l'output sul brano 43990 di SongDescriber con la didascalia pubblicata dagli autori, per verificare che il modello funzionasse come nel paper. Poi le 50 tracce sono state elaborate con un solo passaggio zero-shot ciascuna, passando l'intera durata come intervallo. Ogni brano viene salvato subito in un file testuale, con ripresa automatica dopo le interruzioni.

Prompt. Il prompt è quello senza assistenza del repository di FUTGA (`cli_inference.py`), riportato nel Listato 4.1. Chiede una descrizione generale (mood, tema, tempo, melodia, strumenti, accordi) e poi l'analisi dei segmenti funzionali con i loro confini. Non è il prompt con cui gli autori hanno costruito il loro dataset, che include genere, BPM e i confini degli annotatori. Quello dà al modello i confini già fatti e non è confrontabile con un'inferenza zero-shot.

Listing 4.1: Prompt non assistito impiegato per l'inferenza zero-shot di FUTGA (`cli_inference.py`).

```
First describe the music in general in terms of mood, theme, tempo,
    melody, instruments and chord progression. Then provide a
   detailed music analysis by describing each functional segment
   and its time boundaries.
```

Tre segmenti per brano. Senza i confini nel prompt, in 47 brani su 50 FUTGA produce esattamente tre segmenti, circa 0–30%, 30–65% e 65–100% della durata, spesso con etichette composte come `Intro/Verse`. In due brani i segmenti sono quattro (una coda al 100%), in uno c'è un blocco duplicato ridotto a tre. La media è 3.04 segmenti per brano, contro gli 11.40 della ground truth (da 6 a 18 per brano). È la causa della forte sotto-segmentazione e dei punteggi bassi sui confini (Sezione 4.4.8). Si ipotizza, senza verifica, che senza una testa di localizzazione il modello ricada sul modello di canzone pop in tre parti che ha appreso dal linguaggio. Il test a 75 s va nella stessa direzione: i confini sono quasi identici (0–29/29–63/63–100% contro 0–28/28–63/63–100%), quindi la granularità dipende dal prompt e non dalla finestra dell'encoder.

Dal testo ai segmenti. FUTGA scrive i confini in percentuale della durata (per esempio `0-29%`). Sono stati convertiti in secondi moltiplicando per la durata del brano, che è un dato del dataset. Le etichette sono mappate sulle classi di HarmonixSet con regole che dipendono dalla posizione: `Intro/Verse` diventa *intro* se è il primo segmento, *outro* se è l'ultimo, altrimenti *chorus*, *verse* o *bridge*, in quest'ordine. Il JSON è poi convertito nel formato testuale di SongFormer.

Revisione manuale. Su 50 brani, 41 erano puliti e 9 sono stati corretti a mano. In sei (*Give It Up*, *Nothin' on You*, *Without You*, *I'll Be Waiting*, *Rock That Body*, *Figure 8*) il modello non aveva rispettato il formato del prompt quindi è stata assegnata la struttura intro, verse, outro tenendo i confini del modello. Negli altri tre le correzioni sono minime: in *Be Alright* il modello aveva scritto descrizioni dettagliate al posto del riassunto; in *Blame It* due segmenti *outro* consecutivi sono stati uniti a valle; in *Falling Anthem* la coda a durata zero è gestita nella conversione. Per sei brani su 50 le etichette di FUTGA non sono quindi quelle del modello. Questo può influire su ACC e IoU, non sui confini.

4.3.3 Esecuzione della Pipeline Proposta e dei Modelli nei Test

La telemetria DSP è stata generata una volta per tutte le 50 tracce, e ogni variante è stata lanciata con un file di configurazione diverso per agenti e modelli. I log delle esecuzioni sono nel repository.

Le varianti cambiano solo il modello linguistico. **Pro** usa `gemini-3.1-pro-preview`. **Flash** usa `gemini-3.8-flash` ed è la configurazione di riferimento («Pipeline») nei confronti con SongFormer e FUTGA, perché è quello che ha ottenuto risultati migliori (Sezione 4.4.5). **Lite** usa `gemini-3.5-flash-lite`, senza search grounding, e gira nel tier gratuito delle API. Tutte le varianti sono state eseguite con i parametri di granularità e di lunghezza di default (granularità media e 20 parole per didascalia).

È stata scartata in fase preliminare una variante con Qwen-72B-Instruct. Dava la stessa didascalia a tutti i token, ometteva intere sezioni del brano e produceva uno schema JSON instabile. Il primo difetto è il *mode collapse* descritto da Zhang et al. [46], e il test CLAP di Sezione 4.5.3 serve proprio a rilevarlo.

Per capire quanto conti l'architettura, è stato eseguito anche lo stesso modello della variante Lite con l'audio diretto. Riceve gli stessi metadati esterni (titolo, artista, durata) ma nessun dato calcolato dalla pipeline quindi né tempo, né tonalità, né griglia dei battiti, né testo trascritto. Deve produrre segmenti con etichetta funzionale e didascalia, con la stessa temperatura usata per il Segmenter (l'agente più simile per funzione, dato che la pipeline ha quattro agenti con temperature diverse).

Tutti i sistemi sono stati eseguiti una volta per traccia, perciò non è disponibile una stima della varianza tra esecuzioni. Il prompt è nel repository del progetto. Le anomalie temporali dell'output e la post-elaborazione che le corregge sono in Sezione 4.4.6.

4.4 Valutazione dell'Accuratezza Strutturale (RQ1)

L'accuratezza strutturale rappresenta il prerequisito fondamentale dell'intero sistema. Prima di potersi interrogare sulla validità e ricchezza semantica del contenuto generato, è necessario certificare con esattezza *quando* tale evento acustico si verifica. Se i confini temporali risultassero imprecisi, ogni successiva valutazione sul contenuto testuale verrebbe compromessa in partenza, poiché opererebbe su finestre acustiche inquinate da transizioni sfasate o da porzioni di segmenti adiacenti.

Gli obiettivi di questa fase di testing sono due. In primo luogo, si intende dimostrare la precisione dei confini temporali estratti, validando le scelte algoritmiche (come l'impiego del parametro di granularità) e scongiurando fenomeni di *over-segmentation* o *under-segmentation*. In secondo luogo, l'analisi verifica la corretta categorizzazione funzionale dei segmenti individuati all'interno della tassonomia standard (*intro*, *verse*, *chorus*, *bridge*, *inst*, *outro*, *silence*) [40].

Per quantificare queste prestazioni, il protocollo si avvale di metriche standard: la F-measure (sulle soglie di tolleranza HR.5F e HR3F) per la localizzazione dei confini e l'Accuracy (ACC) globale per l'etichettatura. A queste si affiancano alcune metriche diagnostiche, descritte nella Sezione 4.4.2.

I test di questa sezione riguardano unicamente la precisione dei confini temporali e l'assegnazione delle etichette standard. La valutazione della qualità e della coerenza semantica delle didascalie viene invece affrontata nella Sezione 4.5.

4.4.1 Setup Sperimentale e Baseline

Il confronto di questa sezione coinvolge SongFormer, FUTGA e la pipeline proposta, valutati su SongFormBench-HS (Sezione 4.1). SongFormer è la *baseline* di riferimento per la MSA. FUTGA non nasce per questo compito, infatti, i suoi confini sono percentuali generate in modo autoregressivo e non sono mai stati validati con le metriche di tolleranza standard, ma solo indirettamente su compiti a valle. Inserirlo nel protocollo serve a misurarne direttamente la risoluzione temporale, non a penalizzare un modello pensato per altro. Le motivazioni della scelta delle due *baseline* sono in Sezione 4.2, le modalità di esecuzione in Sezione 4.3.

Per isolare il contributo del modello linguistico usato dagli agenti, il protocollo confronta inoltre le tre varianti della pipeline descritte in Sezione 4.3.3: **Pro**, **Flash** e **Lite**. Salvo diversa indicazione, la variante Flash è la configurazione di riferimento («Pipeline») nei confronti con SongFormer e FUTGA.

4.4.2 Metriche di Valutazione

Il protocollo di validazione adotta l'infrastruttura di misurazione definita dalla baseline di riferimento [9][3]. Anche le metriche diagnostiche (Sezione 4.4.2) non sono state introdotte in questo lavoro ma sono calcolate dallo script di valutazione di SongFormer, che si appoggia a MSAF [60].

Accuratezza dei Confini Temporali

La precisione della segmentazione viene misurata attraverso la *F-measure over boundary*. Un marcatore temporale predetto è classificato come *true positive* (N_{tp}) se ricade entro una finestra di tolleranza prefissata ($\pm\delta$) rispetto a un confine reale del *ground truth*, come *false positive* (N_{fp}) se privo di corrispondenza, mentre un confine reale non intercettato dall'algoritmo costituisce un *false negative* (N_{fn}). Su questa base, Precision, Recall e F-measure sono definiti come:

$$\mathrm{P} = \frac{N_{tp}}{N_{tp} + N_{fp}}, \qquad \mathrm{R} = \frac{N_{tp}}{N_{tp} + N_{fn}}, \qquad \mathrm{F} = \frac{2 \cdot \mathrm{P} \cdot \mathrm{R}}{\mathrm{P} + \mathrm{R}} \tag{4.1}$$

La F-measure, media armonica tra le due componenti, garantisce un punteggio elevato solo quando il sistema produce simultaneamente poche transizioni spurie e un'elevata copertura dei confini reali.

Il test temporale opera su due livelli di severità. La metrica HR.5F ($\pm$0.5 secondi) certifica la tenuta micro-temporale dell'architettura e non concede alcun margine di errore sui disallineamenti. La soglia HR3F ($\pm$3 secondi) modella un regime tollerante, capace di assorbire le deviazioni intrinseche causate da transizioni acustiche sfumate o dalla soggettività dell'annotatore umano. Nelle analisi per split si aggiunge una soglia intermedia, HR1F ($\pm$1 secondo).

[3] Le metriche principali (HR.5F, HR3F, ACC) sono quelle del task *Music Structure Analysis* di MIREX (`https://music-ir.org/mirex/wiki/2026:Music_Structure_Analysis`), che SongFormer segue.

Accuratezza dell'Etichettatura Strutturale

L'esattezza della classificazione funzionale viene misurata calcolando l'Accuracy (ACC) globale sulle 7 categorie standard. Come previsto dal task MIREX, il calcolo è frame per frame, audio e *ground truth* sono convertiti in sequenze di etichette e l'ACC è la proporzione di frame etichettati correttamente. Per garantire la validità del confronto si usa la griglia di campionamento di SongFormer, a frequenza costante di 8.33 Hz (circa 120 millisecondi per frame). Il sistema proposto etichetta interi segmenti, quindi ogni frame eredita l'etichetta del segmento in cui ricade.

Confronto Statistico tra Sistemi

Poiché i sistemi sono valutati sulle stesse 50 tracce, il confronto tra due sistemi è condotto sulle differenze brano per brano, accoppiando i punteggi dei due sistemi per identificativo della traccia. Si parte dall'ipotesi nulla che non esista una differenza sistematica e si verifica se lo scarto osservato è compatibile con la normale variabilità tra brani eterogenei. Il p-value quantifica la probabilità di osservare una differenza pari o superiore a quella riscontrata sotto l'ipotesi nulla, che viene respinta se $p < 0.05$. Si usano due test sulle differenze tra i punteggi. Il *t-test* accoppiato è il test di riferimento e assume che le differenze siano distribuite in modo approssimativamente normale. Il test di Wilcoxon sui ranghi non fa questa assunzione ed è meno sensibile a pochi brani anomali, come i crolli su singole tracce. Se i due test concordano, la conclusione non dipende dall'assunzione di normalità.

Metriche Diagnostiche di Supporto

Oltre alle metriche principali si riportano tre famiglie di metriche diagnostiche, già calcolate dallo script di SongFormer. Servono perché l'ACC misura insieme la partizione e l'etichetta esatta, quindi non distingue un errore di comprensione della struttura da un disaccordo di nomi con l'annotatore.

Pairwise F-measure (PWF). La PWF [61] è una metrica di *clustering* che ignora i nomi delle etichette e guarda solo se le ricorrenze sono raggruppate in modo coerente. Si considerano le coppie di istanti (t_1, t_2) campionati a intervalli regolari e ci si chiede, per ground truth e predizione, se i due istanti appartengano alla stessa sezione. Una coppia è TP se entrambe concordano, FP se il modello unisce due istanti che la ground truth separa, FN se li separa mentre la ground truth li considera equivalenti. Quindi:

$$P_{\text{pair}} = \frac{TP}{TP + FP}, \qquad R_{\text{pair}} = \frac{TP}{TP + FN}, \qquad \text{PWF} = \frac{2 \cdot P_{\text{pair}} \cdot R_{\text{pair}}}{P_{\text{pair}} + R_{\text{pair}}} \tag{4.2}$$

Ad esempio, se un modello predice *Chorus, Verse, Chorus, Verse* e la ground truth è *Verse, Chorus, Verse, Chorus*, l'ACC è zero, ma il modello ha capito che le sezioni

1 e 3 sono equivalenti, e così le 2 e 4, quindi la PWF è 100%. Una PWF molto sopra l'ACC ($\Delta = \text{PWF} - \text{ACC} > 0$) indica che la struttura ciclica è capita meglio di quanto suggeriscano i nomi delle etichette, cioè che il problema è di tassonomia e non di comprensione.

IoU per classe funzionale. L'*Intersection over Union* (indice di Jaccard) misura la sovrapposizione tra predizione e ground truth per una classe alla volta. Campionando la traccia a intervalli regolari e isolando la classe c, si confrontano le sequenze binarie di presenza:

$$\text{IoU}_c = \frac{|\text{Frames}_{\text{GT}}(c) \cap \text{Frames}_{\text{Pred}}(c)|}{|\text{Frames}_{\text{GT}}(c) \cup \text{Frames}_{\text{Pred}}(c)|} = \frac{TP_c}{TP_c + FP_c + FN_c} \tag{4.3}$$

L'ACC risente dello sbilanciamento tra le classi perché *Verse* e *Chorus* occupano di solito il 70–80% del tempo. L'IoU valuta invece ogni classe su una scala propria in [0,1] e mostra se il modello conosce tutta la forma del brano o solo le sezioni maggioritarie.

Over e under-segmentation (S_o, S_u). Per capire la risoluzione della segmentazione, indipendentemente dai nomi, si usano gli indici di entropia condizionale di Lukashevich [62] S_o misura quanto i segmenti predetti stiano dentro un solo segmento reale senza attraversarne i confini, S_u quanto i segmenti reali siano coperti in modo pulito da quelli predetti. Insieme al numero medio di segmenti per brano, confrontato con quello della ground truth, permettono di distinguere un sistema che frammenta troppo da uno che fonde sezioni diverse in blocchi indistinti.

4.4.3 Confronto Globale con lo Stato dell'Arte

La Tabella 4.2 riporta i risultati medi sulle 50 tracce. Le metriche sono quelle di Sezione 4.4.2, la pipeline è nella variante Flash.

Sistema	ACC	HR3F	HR.5F	PWF
SongFormer	$\mathbf{0.749 \pm 0.196}$	$\mathbf{0.793 \pm 0.136}$	$\mathbf{0.694 \pm 0.167}$	$\mathbf{0.750 \pm 0.160}$
Pipeline (Flash)	0.701 ± 0.181	0.620 ± 0.200	0.379 ± 0.215	0.679 ± 0.148
FUTGA	0.280 ± 0.097	0.304 ± 0.136	0.201 ± 0.077	0.452 ± 0.051

Tabella 4.2: Risultati globali su SongFormBench-HS (50 tracce), riportati come media $\pm$ deviazione standard per brano ($\mu \pm \sigma$).

SongFormer è il migliore su tutte le metriche. La pipeline è a ridosso sull'ACC (0.701 contro 0.749) e sulla PWF (0.679 contro 0.750), più distante sui confini, soprattutto con la tolleranza stretta (HR.5F 0.379 contro 0.694). FUTGA è molto

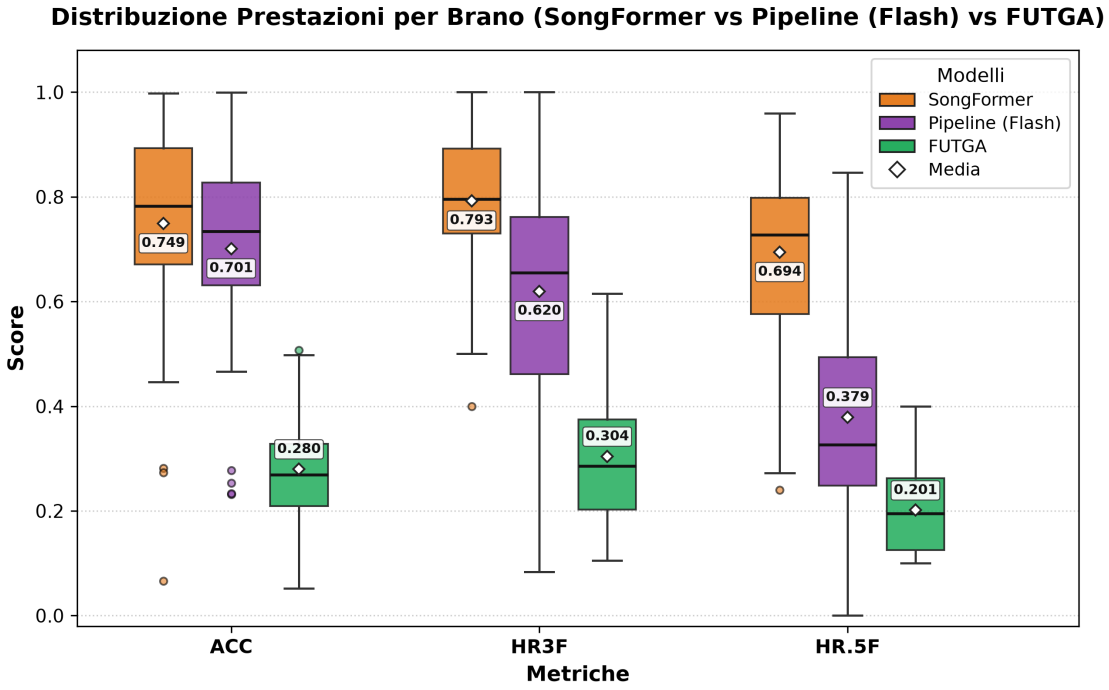


Figura 4.1: Distribuzione per brano di ACC, HR3F e HR.5F (linea: mediana, rombo: media).

indietro su tutte le metriche, confini compresi (HR3F 0.304, HR.5F 0.201). Nei boxplot di Figura 4.1 i corpi centrali dell'ACC di pipeline e SongFormer si sovrappongono. Per entrambi i sistemi la media è trascinata verso il basso da pochi brani con ACC molto bassa.

Nei confronti accoppiati (Sezione 4.4.2) SongFormer risulta superiore su tutte le metriche, anche sull'ACC. Lo scarto di 4.8 punti è contenuto ma significativo ($t(49) = 2.740$, $p = 0.0085$; test di Wilcoxon $p = 0.0109$). Sulla PWF e sui confini (HR3F e HR.5F) la differenza è più ampia, con $p < 0.001$ in entrambi i test. La pipeline supera comunque SongFormer sull'ACC in 17 brani su 50 (34%), con margini fino a +18.0 punti. Il divario più netto resta sui confini, in particolare con la tolleranza stretta.

4.4.4 Risoluzione Temporale e Costo della Griglia a 16 Battiti

La differenza tra la pipeline e SongFormer è concentrata sull'HR.5F (0.379 contro 0.694). Dipende dalla griglia a 16 battiti. La durata di un *token* è

$$\text{Durata (s)} = 16 \times \frac{60}{\text{BPM}} = \frac{960}{\text{BPM}}, \tag{4.4}$$

cioè circa 8 secondi a 120 BPM e circa 16 secondi a 59 BPM. I confini della pipeline si appoggiano ai bordi dei token. SongFormer lavora invece su una griglia di frame continua, a una risoluzione molto più fine di mezzo secondo. Una griglia di diversi secondi non può centrare in modo sistematico una tolleranza di ± 0.5 s. Anche per questo l'HR.5F della pipeline ha una dispersione elevata ($\sigma = 0.215$ per Flash). Una possibile spiegazione è che la quantizzazione premi i brani a tempo rigido e perda sincronia dove ci sono batterie suonate dal vivo e fluttuazioni naturali del BPM, in cui i bordi dei token si discostano dagli attacchi reali.

Le tre varianti della pipeline confermano che il limite non è del modello linguistico, infatti, l'HR.5F è quasi identico (0.379 per Flash, 0.374 per Pro, 0.358 per Lite), mentre cambiano ACC e HR3F. La scarsa precisione sui confini stretti dipende quindi dalla segmentazione a token, non dal modello scelto. Le differenze tra le varianti sono discusse nella Sezione 4.4.5.

4.4.5 Confronto tra le Varianti della Pipeline

La Tabella 4.3 confronta le tre varianti descritte in Sezione 4.3.3.

Variante	Modello	ACC	HR3F	HR.5F
Flash	Gemini 3.8 Flash	$\mathbf{0.701 \pm 0.181}$	$\mathbf{0.620 \pm 0.200}$	$\mathbf{0.379 \pm 0.215}$
Pro	Gemini 3.1 Pro	0.641 ± 0.207	0.588 ± 0.204	0.374 ± 0.211
Lite	Gemini 3.5 Flash Lite	0.597 ± 0.190	0.573 ± 0.198	0.358 ± 0.192

Tabella 4.3: Varianti della pipeline sulle 50 tracce (valori riportati come media $\pm$ deviazione standard, $\mu \pm \sigma$).

Il modello più grande non è il migliore. Flash supera Pro di 6.0 punti di ACC (0.701 contro 0.641), con una mediana di 0.734 contro 0.684 (Lite: 0.610). Sull'HR3F il vantaggio è di 3.2 punti, e la mediana va da 0.604 a 0.655. Flash ha anche la dispersione più contenuta. L'intervallo interquartile, cioè l'ampiezza dell'intervallo che contiene la metà centrale dei brani (dal primo al terzo quartile), per l'ACC è 0.196 per Flash, contro 0.265 per Pro e 0.256 per Lite. Una possibile spiegazione è che il modello più grande, pur ragionando di più, tenda a fondere sezioni adiacenti (Pro produce meno segmenti, si veda sotto), e che questo penalizzi sia l'ACC sia l'HR3F. Un modello più capace quindi non porta necessariamente un vantaggio per questo compito.

Outlier. Un brano è considerato *outlier* secondo la regola di Tukey se il suo punteggio dista dal quartile più vicino più di 1.5 volte l'intervallo interquartile. Per l'ACC di Flash la soglia inferiore è quindi 0.337, e solo Flash ha *outlier* formali sull'ACC: quattro brani (0.231–0.278) sotto questa soglia. Non vuol dire che Pro

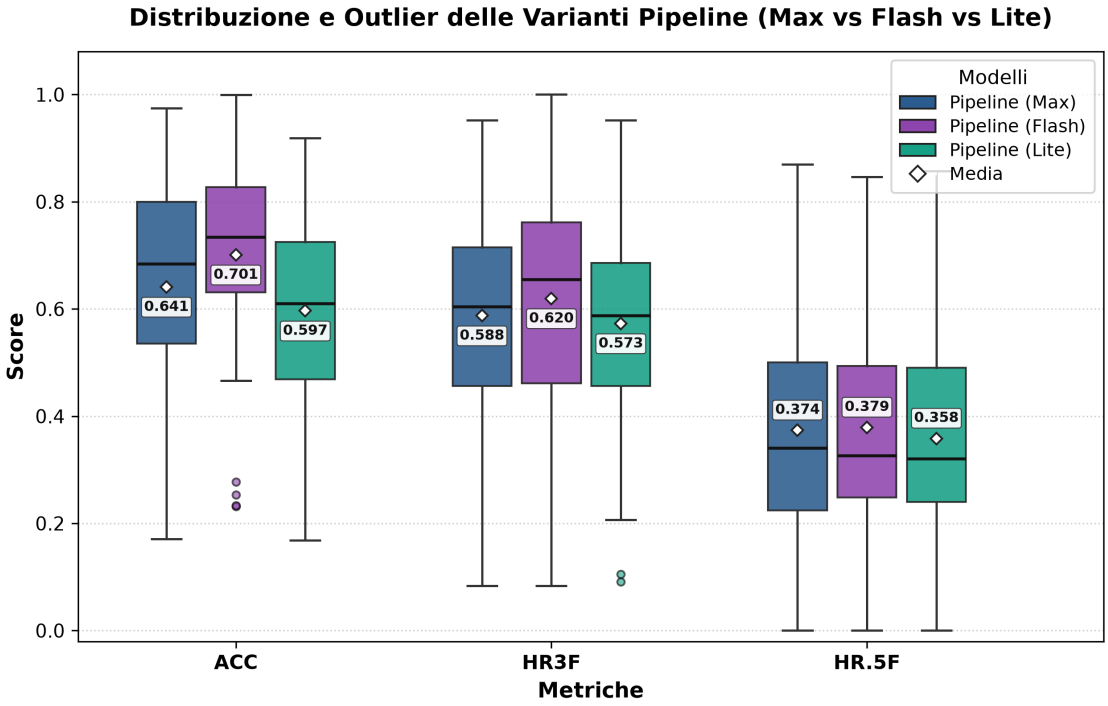


Figura 4.2: Distribuzione per brano delle tre varianti della pipeline.

e Lite siano più stabili. Il corpo centrale di Flash è compatto e concentrato verso l'alto, per cui i casi limite superano formalmente la soglia di Tukey. In Pro e Lite i baffi inferiori sono molto più estesi e i fallimenti restano dentro la dispersione generale. Pro ha 6 brani sotto il 35% di ACC, Lite 7 (tra questi il 16.8% su *Rock That Body*). Lite ha inoltre due *outlier* sull'HR3F (0.091 su *I'll Be Waiting*, 0.105 su *Texas Flood*).

Segmentazione e costi. Il numero medio di segmenti per brano è 11.08 per Flash, 10.50 per Lite e 9.50 per Pro, contro 11.40 della *ground truth*. Pro tende quindi a fondere.

Flash ha costi di inferenza inferiori a Pro, con una qualità maggiore. La variante Lite resta nel *Free Tier* e ha costo nullo. Con il 59.7% di ACC è la configurazione più accessibile, e rende la pipeline utilizzabile anche su cataloghi musicali estesi.

Modello scartato. Un quarto modello, Qwen-72B-Instruct, è stato provato e scartato. Non è stato valutato in modo sistematico, e quanto segue è un'osservazione qualitativa. Produceva le stesse didascalie su tutta la traccia, blocchi da due soli segmenti e token saltati. Era l'unico modello senza ragionamento esteso (non *thinking*) tra quelli provati, ed è l'unico che ha fallito. Non è dimostrato che le due

cose siano collegate, ma l'osservazione è coerente con un compito che richiede di ragionare su molti token consecutivi.

La variante Lite è anche quella usata nel confronto successivo, perché permette di isolare il contributo della pipeline a parità di modello.

4.4.6 Pipeline contro Input Audio Diretto

L'ablazione risponde a una domanda: il risultato dipende dalla scomposizione in DSP e agenti, o dalle capacità di ascolto del modello? Per saperlo si confronta la variante Lite con una configurazione di controllo, **Audio Diretto**.

Il modello è lo stesso (Gemini Flash Lite), con gli stessi metadati (titolo, artista, durata) ma senza telemetria DSP. Riceve l'audio grezzo e produce in un solo passaggio confini ed etichette (Sezione 4.3.3).

Metrica	**Pipeline (Lite)**	**Audio Diretto**	**Δ**
ACC	**0.597**	0.457	+0.139
PWF	**0.598**	0.478	+0.121
HR3F	**0.573**	0.448	+0.125
HR1F	**0.440**	0.339	+0.101
HR.5F	**0.358**	0.265	+0.093

Tabella 4.4: Pipeline (Lite) contro Audio Diretto, con lo stesso modello linguistico.

La pipeline è migliore su tutte le metriche. Poiché il modello è lo stesso, il divario non dipende dai pesi ma da quello che riceve in ingresso. La griglia ritmica, la telemetria DSP e la divisione dei compiti tra gli agenti portano l'ACC da 0.457 a 0.597.

IoU per classe. Il divario si concentra sulle sezioni che richiedono un cambio di funzione (Tabella 4.5). Sul *Bridge* l'Audio Diretto crolla (0.032 contro 0.222). Lo stesso vale, in misura minore, per *Verse*, *Chorus*, *Inst* e *Outro*. Una possibile spiegazione è che, senza la griglia, il modello sottosegmenti e perda le sezioni brevi o di transizione, che sono quelle in cui la funzione cambia (si veda il numero di segmenti più avanti).

L'unica classe in cui l'Audio Diretto è sopra la pipeline è l'*Intro* (0.609 contro 0.550). Non indica maggiore precisione. Una possibile spiegazione è che l'etichetta *intro* venga mantenuta per decine di secondi oltre l'inizio della prima strofa. Un'altra lettura è la deriva temporale: l'inizio del brano è ancora allineato, poi l'errore si accumula. Questa lettura è coerente con quanto riportato in letteratura sui modelli linguistici [10] ma non è stata misurata per posizione nel brano.

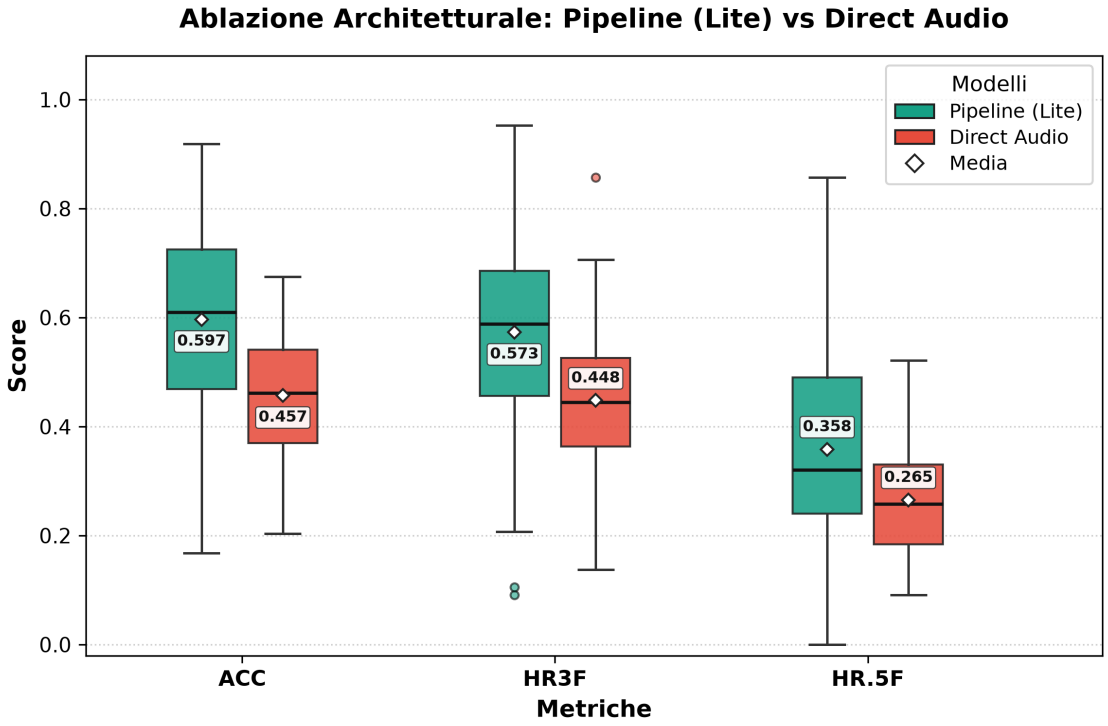


Figura 4.3: Distribuzione per brano di ACC, HR3F e HR.5F: Pipeline (Lite) contro Audio Diretto.

Classe	Pipeline (Lite)	Audio Diretto
Intro	0.550	**0.609**
Verse	**0.504**	0.310
Chorus	**0.438**	0.323
Bridge	**0.222**	0.032
Inst	**0.346**	0.208
Outro	**0.356**	0.226
Silence	**0.018**	0.000

Tabella 4.5: IoU per classe funzionale, Pipeline (Lite) contro Audio Diretto.

Anomalie temporali. In 21 tracce su 50 (42%) l'output dell'Audio Diretto ha anomalie nei tempi come ad esempio intervalli invertiti, notazione che passa da minuti e secondi a decimali, derive cumulative. Gli output sono stati corretti con un *clamp* (conformemente a quanto nella valutazione di SongFormer [9], dove i ricercatori hanno incontrato le medesime anomalie per Gemini 2.5 Pro) e una conversione dal formato min.sec, fino a rendere valutabili tutte le 50 tracce. Il 42% non è pulizia dei dati, ma un risultato: sono errori che l'ancoraggio ai beat della pipeline non permette. Il numero medio di segmenti è 7.28 (7.84 prima del *merge* delle sezioni adiacenti), contro 10.50 della pipeline Lite.

4.4.7 Resilienza al *Domain Shift*

I risultati medi nascondono differenze tra generi. La Tabella 4.6 riporta le metriche per ciascuno dei tre split di Sezione 4.1.

Split	Sistema	ACC	HR3F	HR.5F	PWF
In-domain (25)	SongFormer	**0.7006**	**0.8057**	**0.7015**	**0.7234**
	Pipeline (Flash)	0.6398	0.6692	0.4143	0.6410
	FUTGA	0.2906	0.2999	0.1905	0.4653
Middle-ground (15)	SongFormer	**0.7658**	**0.7929**	**0.7143**	**0.7588**
	Pipeline (Flash)	0.7217	0.6255	0.3784	0.6830
	FUTGA	0.2702	0.3453	0.2261	0.4404
Out-of-domain (10)	SongFormer	**0.8449**	**0.7595**	**0.6456**	**0.8039**
	Pipeline (Flash)	0.8235	0.4869	0.2912	0.7658
	FUTGA	0.2675	0.2530	0.1916	0.4364

Tabella 4.6: Risultati per split (tra parentesi il numero di tracce).

ACC e PWF crescono fuori dominio. Per entrambi i sistemi l'ACC è più alta nell'*out-of-domain* (SongFormer da 0.7006 a 0.8449, pipeline da 0.6398 a 0.8235). Una possibile spiegazione è che i brani rock e metal abbiano sezioni lunghe e omogenee, dove un errore di pochi secondi pesa meno, mentre nella musica elettronica le micro-sezioni sono frequenti e un piccolo sfasamento costa di più. La stessa spiegazione vale per generi con sezioni estese e stabili: una volta inquadrata la sezione, il modello accumula molti frame corretti consecutivi. Va però anche osservato che lo split ha solo 10 tracce.

Il divario sulla PWF si dimezza. La differenza tra SongFormer e la pipeline sulla PWF scende lungo gli split: +0.0824 in-domain, +0.0758 middle-ground, +0.0381 out-of-domain. La PWF della pipeline cresce di 12.5 punti (0.6410 $\rightarrow$ 0.7658), quella di SongFormer di 8.1 (0.7234 $\rightarrow$ 0.8039). FUTGA resta bassa

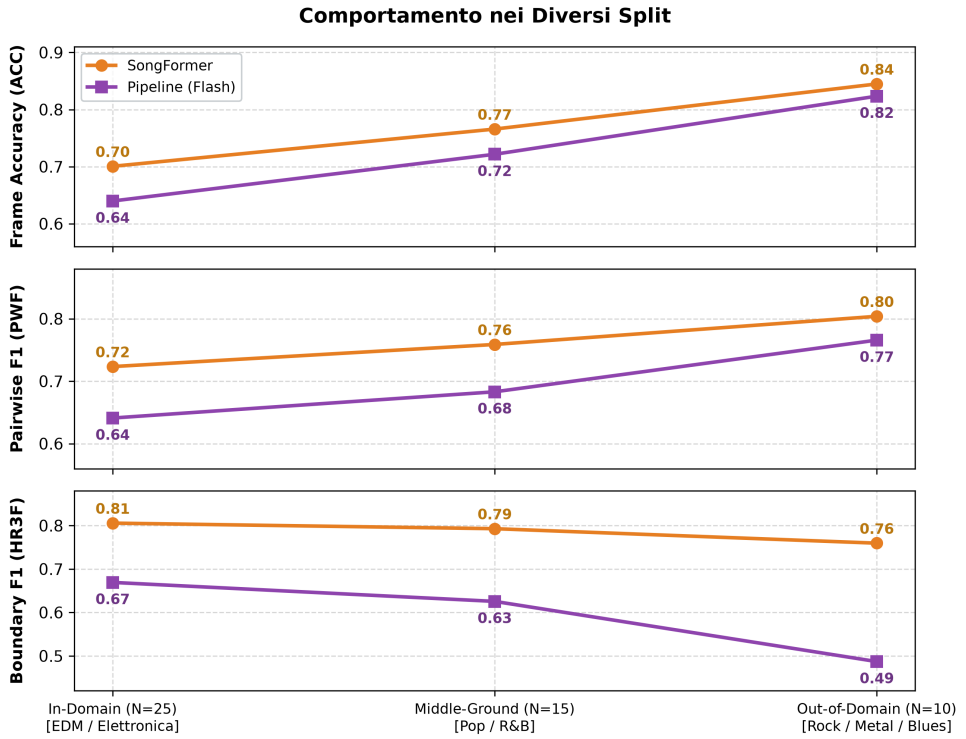


Figura 4.4: Andamento di ACC, PWF e HR3F nei tre split.

(0.4653, 0.4404, 0.4364) e senza andamento. Il picco della PWF della pipeline (0.7658) indica che la ciclicità e la forma del brano sono individuate anche nei generi meno vicini al dominio di sviluppo.

I confini invece cedono. Su SongFormer l'HR3F cala di 4.6 punti (0.8057 → 0.7595). Sulla pipeline cala di 18.2 (0.6692 → 0.4869), e l'HR.5F scende a 0.2912. Il confronto tra PWF e HR3F mostra che dove i confini peggiorano, il raggruppamento delle sezioni migliora. Se la pipeline avesse perso la comprensione della struttura, la PWF sarebbe calata con l'HR3F. L'interpretazione è che la perdita sui confini dipenda dalla griglia a 16 battiti su ritmi poco regolari (tempo rubato, cambi di metro), dato che la griglia assume un tempo stabile. Non è stata verificata con un beat tracker alternativo. In sintesi, l'agente semantico individua la progressione e le ripetizioni (il «cosa»), mentre la discretizzazione a monte perde risoluzione sulla sincronia fine (il «quando»).

Resta da vedere come questo si distribuisce tra le classi funzionali.

4.4.8 Diagnostica per Classe Funzionale

La Tabella 4.7 riporta l'IoU per ciascuna classe funzionale. Sia gli IoU per classe sia l'IoU globale sono calcolati su tutti i frame del corpus, non come media dei valori dei singoli brani. L'IoU globale è il rapporto $\sum TP / \sum(TP + FP + FN)$ su tutte le classi e non coincide con la media semplice dei sette valori, perché le classi più frequenti (*Verse* e *Chorus*) pesano di più.

Classe	**SongFormer**	**Flash**	**Pro**	**FUTGA**
Intro	**0.794**	0.629	0.537	0.216
Verse	**0.691**	0.607	0.550	0.106
Chorus	**0.628**	0.554	0.490	0.179
Bridge	0.393	**0.411**	0.342	0.000
Inst	**0.416**	0.385	0.320	0.000
Outro	0.322	**0.392**	0.333	0.258
Silence	**0.512**	0.056	0.000	0.000
IoU globale	**0.577**	0.519	0.457	0.167

Tabella 4.7: IoU per classe funzionale e IoU globale sulle 50 tracce. I valori sono aggregati su tutti i frame del corpus; l'IoU globale non è la media semplice delle sette classi.

Sull'IoU globale SongFormer è il migliore (0.577), seguito da Flash (0.519), Pro (0.457) e FUTGA (0.167). Il divario tra SongFormer e Flash, pari a 5.8 punti, è più contenuto di quello osservato sui confini.

La pipeline supera SongFormer su *Bridge* (0.411 contro 0.393) e *Outro* (0.392 contro 0.322). Sono sezioni che spesso mantengono l'arrangiamento della strofa e cambiano nel testo o nella funzione. Una possibile spiegazione è che il contributo del testo e del contesto musicale aiuti qui più dell'acustica. Su *Intro*, *Verse* e *Chorus* SongFormer resta avanti, ma la pipeline è relativamente vicina (Verse 0.607 contro 0.691, Chorus 0.554 contro 0.628).

Sulla classe *Silence* la pipeline è molto sotto (0.056 contro 0.512) poiché la griglia a 16 battiti assorbe i silenzi iniziali e finali in *intro* e *outro*, non dipendendo dalla percezione del segnale.

FUTGA ha IoU nullo su *Bridge* e *Inst* poiché tali sezioni non vengono mai individuate per via della fusione di sezioni adiacenti, come analizzato nella Sezione 4.3.2.

Under e over-segmentation. La Tabella 4.8 riporta gli indici di Lukashevich e il numero medio di segmenti per brano.

Sistema	S_u	S_o	Segmenti/brano	Rapporto con GT
Ground truth	–	–	11.40	1.00
SongFormer	**0.776**	**0.791**	14.28	1.25
Pipeline (Flash)	0.731	0.697	11.08	0.97
FUTGA	0.424	0.366	3.04	0.27

Tabella 4.8: Indici di segmentazione e cardinalità.

I due tipi di dato misurano cose diverse. Il numero di segmenti conta quanti blocchi il sistema vede. S_u e S_o misurano quanto i confini cadono nel posto giusto. SongFormer ha indici più alti perché posiziona i confini sui cambi acustici, ma suddivide di più (14.28 segmenti, 1.25 volte la *ground truth*), probabilmente spezzando sezioni su fill ed effetti. La pipeline ha una cardinalità quasi uguale alla *ground truth* (0.97), ma gli indici sono più bassi, perché un confine può cadere qualche secondo fuori posto. FUTGA produce 3.04 segmenti a brano, circa un quarto di quelli reali. L'indice S_u (0.424) è più alto di S_o (0.366). Il suo errore, come già osservato, è la fusione di sezioni adiacenti, non la frammentazione. Con circa un quarto dei segmenti reali la struttura è ridotta a una frazione di quella vera, e questo spiega l'IoU nullo sulle classi secondarie.

4.4.9 Struttura contro Etichetta: Casi Limite

L'ACC è bassa in alcuni brani. Per capire se il sistema sbaglia la struttura o solo il nome si incrocia l'ACC con la PWF, che ignora i nomi (Sezione 4.4.2). Nella Figura 4.5 ogni brano è un punto. Sopra la diagonale la struttura è capita meglio di quanto dica l'etichetta.

Per entrambi i sistemi i due indici sono correlati ($r = 0.83$ per la pipeline, $r = 0.70$ per SongFormer). Dove l'ACC è bassa, la PWF è sopra la diagonale. Un modello che inventasse partizioni casuali avrebbe PWF bassa e correlata con l'ACC in modo debole. Qui non succede. La correlazione più alta della pipeline indica un comportamento internamente coerente, e non una distribuzione casuale delle partizioni.

Le ACC dei due sistemi sono inoltre fortemente correlate brano per brano ($r = 0.79$, correlazione di Pearson): i brani difficili lo sono per entrambi, e gli *outlier* della Tabella 4.9 ne sono il caso più evidente.

I quattro brani sotto la soglia di Tukey dell'ACC della pipeline sono nella Tabella 4.9. Per la pipeline la PWF è sopra l'ACC in tutti e quattro ($\Delta = \text{PWF} - \text{ACC} > 0$, tra +0.12 e +0.51).

Barbra Streisand è il caso estremo. L'ACC è 0.231 per la pipeline e 0.066 per SongFormer, ma la PWF è 0.742 e 0.947. Il Δ è +0.51 per la pipeline e +0.88

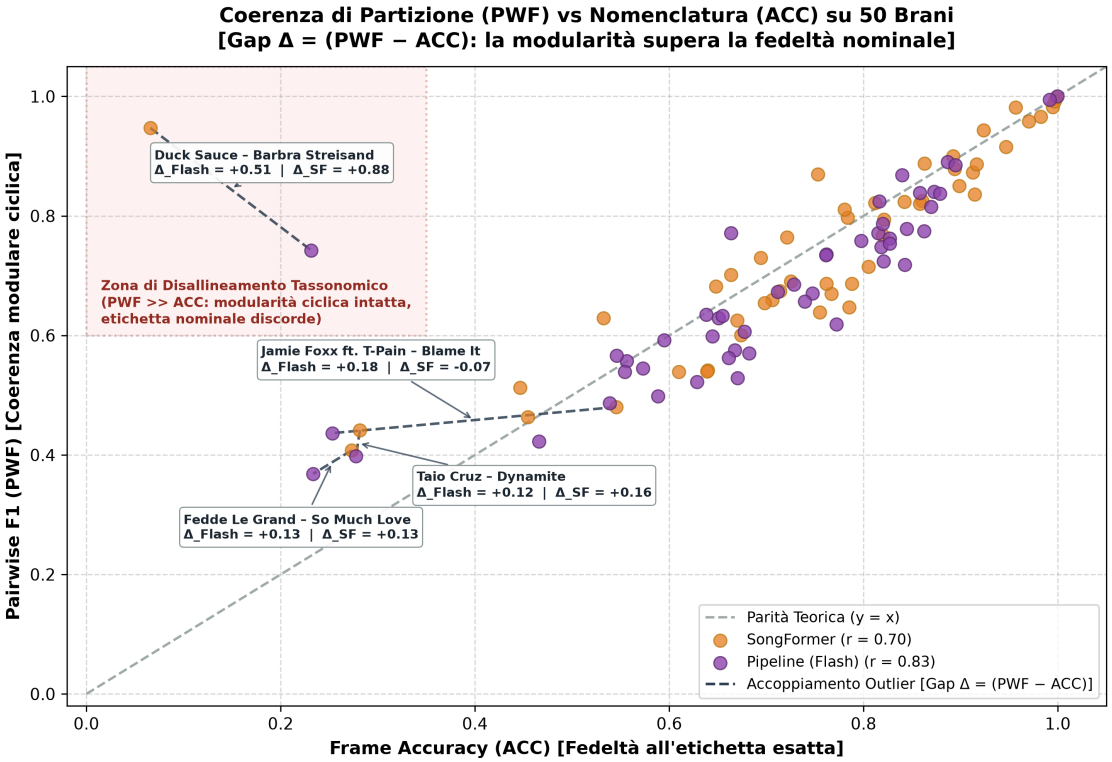


Figura 4.5: ACC contro PWF sulle 50 tracce. La diagonale tratteggiata è $y = x$; i quattro *outlier* sono collegati tra i due sistemi.

	ACC		PWF	
Brano	Flash	SongFormer	Flash	SongFormer
Barbra Streisand (Duck Sauce)	0.231	0.066	0.742	0.947
So Much Love (Fedde Le Grand)	0.233	0.273	0.368	0.408
Blame It (Jamie Foxx)	0.253	0.545	0.436	0.480
Dynamite (Taio Cruz)	0.278	0.282	0.398	0.441

Tabella 4.9: I quattro *outlier* dell'ACC della pipeline.

per SongFormer. Entrambi i sistemi, opposti per architettura, cadono nello stesso punto anomalo e ricostruiscono la ciclicità del brano, perdendo sul nome da dare alle sezioni. Una possibile spiegazione è l'ambiguità tassonomica della *ground truth*: è un brano dance ripetitivo, annotato in modo convenzionale. Nei casi osservati non c'è evidenza di allucinazione, ma di divergenza lessicale dall'annotatore. Per *So Much Love*, *Blame It* e *Dynamite* il quadro è più sfumato. Su *So Much Love* e *Dynamite* i due sistemi falliscono insieme, sono brani club e dance in cui anche l'annotazione è ambigua. Su *Blame It*, invece, il fallimento è specifico della pipeline: SongFormer ottiene un'ACC più che doppia (0.545 contro 0.253), mentre la PWF dei due sistemi è simile (0.436 e 0.480).

4.4.10 Conclusioni sulla Valutazione Strutturale

Sul benchmark di 50 tracce la pipeline si avvicina a SongFormer sull'etichettatura (ACC 0.701 contro 0.749, con uno scarto contenuto ma statisticamente significativo) e sul raggruppamento delle sezioni (PWF 0.679 contro 0.750). Resta indietro sui confini, soprattutto con tolleranza stretta (HR.5F 0.379 contro 0.694), e supera nettamente FUTGA su tutte le metriche. Segmenta con una cardinalità vicina alla *ground truth* (0.97 volte), mentre SongFormer sovrasegmenta (1.25) e FUTGA fonde le sezioni (0.27). Il confronto con l'Audio Diretto, a parità di modello, attribuisce alla pipeline un vantaggio di 13.9 punti di ACC.

Le cause proposte nelle sezioni precedenti hanno un grado di verifica diverso. Il limite sui confini stretti dipende dalla granularità della griglia a 16 battiti, con token di 8–16 secondi. L'evidenza è indiretta: l'HR.5F è quasi identico in tutte le varianti, quindi non dipende dal modello. Anche il vantaggio di Flash su Pro ha una spiegazione indiretta, cioè la tendenza di Pro a fondere le sezioni (9.50 segmenti contro 11.40). Il divario con l'Audio Diretto è l'unico effetto isolato da un'ablazione a parità di modello, e la spiegazione (assenza di griglia e telemetria, sottosegmentazione) è coerente con i 7.28 segmenti per brano. L'ACC bassa con PWF alta è spiegata in parte dall'ambiguità o dalle convenzioni della *ground truth*, con evidenza parziale: la PWF e i quattro *outlier*.

Altre spiegazioni non sono state verificate. L'aumento di ACC e PWF fuori dominio è attribuito a sezioni lunghe e omogenee nei generi rock e metal, ma lo split ha solo 10 tracce. Il calo dell'HR3F fuori dominio è attribuito alla griglia fissa su tempo non regolare, senza prova con un altro *beat tracker*. Il vantaggio su *Bridge* e *Outro* è attribuito al contributo del testo, senza un'ablazione sul solo testo. Il valore quasi nullo su *Silence* è attribuito alla convenzione per cui la griglia assorbe i silenzi in *intro* e *outro*. Il fallimento di Qwen-72B resta un'osservazione qualitativa.

I risultati non misurano la qualità o la correttezza semantica delle didascalie, oggetto di RQ2. Non misurano l'adeguatezza della precisione temporale a compiti

a valle come il DJing o il montaggio automatico, che restano una motivazione del lavoro.

In sintesi, la pipeline recupera gran parte della distanza da SongFormer sull'etichettatura e sulla struttura ciclica, e perde sui confini per un vincolo della sua rappresentazione. Il valore aggiunto è l'output, infatti, ogni segmento arriva con una didascalia e una motivazione.

4.5 Valutazione dell'Accuratezza Semantica

4.5.1 Coerenza Interna e Risoluzione Semantica

La validazione dei confini temporali e della classificazione ontologica discussa nella Sezione 4.4 garantisce il corretto posizionamento dei segmenti e la pertinenza delle rispettive etichette funzionali, ma non dimostra che il contenuto delle didascalie sia acusticamente fondato o strutturalmente coerente lungo l'evoluzione del brano.

I dataset disponibili nell'ambito del *Music Information Retrieval* soffrono di una lacuna strutturale che condiziona la valutazione dei modelli generativi. Dataset diffusi come MusicCaps [63] e SongDescriber [64] mettono a disposizione didascalie testuali riferite unicamente all'intera traccia (SongDescriber) o limitate a finestre temporali rigide di dieci secondi, estratte da video lunghi (MusicCaps). Non esiste un corpus di riferimento annotato da esperti che fornisca descrizioni testuali di *ground truth* calibrate su segmenti strutturali a durata variabile. Per questo motivo i due corpora non sono stati usati. Il primo non contiene segmenti strutturali. Il secondo non scende sotto la granularità del brano intero. Entrambi impediscono di confrontare la didascalia di un singolo segmento con un riferimento umano. Le trascrizioni generate da architetture concorrenti come FUTGA non costituiscono un riferimento valido, rappresentando l'output sintetico della *baseline* di confronto anziché una controparte annotata in modo indipendente da umani.

Di fronte a questo vuoto nei *benchmark*, lo stato dell'arte evita la misurazione diretta della qualità semantica sulle singole sezioni del brano. Architetture come FUTGA ripiegano su stime globali o delegano la validazione a task applicativi a valle. La strategia adottata in questa sezione non tenta di colmare l'assenza di un riferimento testuale segmentale con un'approssimazione debole. Sposta invece l'asse della validazione dal confronto con un corpus esterno alla verifica della coerenza interna del sistema stesso. L'idea di fondo è che, se le descrizioni generate sono realmente fondate sulla fisica del segnale, la loro geometria relazionale, ovvero il modo in cui si assomigliano o si differenziano nel tempo, deve rispecchiare quella dell'audio da cui derivano, indipendentemente dal fatto che il lessico specifico coincida con quello di un annotatore umano.

Il principio si articola in tre verifiche progressive, ciascuna pensata per chiudere una via di fuga lasciata aperta dalla precedente. Nel presente lavoro è stata eseguita la prima, cioè l'ancoraggio di ogni singola descrizione al proprio segmento. Si accerta che le didascalie non siano generiche e intercambiabili tra segmenti distinti, e che non presentino una varianza artificiosa non giustificata da alcuna effettiva variazione del segnale. La verifica si fonda sulla dominanza diagonale della matrice di similarità cross-modale ed è articolata in quattro metriche: il *Mean Reciprocal Rank* (MRR), l'accuratezza Top-1, la *Windowed Accuracy* e il *Semantic Class Agreement*. A queste si aggiunge una prova di recupero su un catalogo di segmenti di brani diversi (Sezione 4.5.5). Le altre due verifiche, sull'isomorfismo topologico tra matrici di auto-similarità e sulla triangolazione tra spazi di rappresentazione, non sono state eseguite e sono discusse tra gli sviluppi futuri (Sezione 4.7).

Ciascuna misura è applicata, a parità di protocollo, anche all'output della *baseline* FUTGA. Il protocollo è applicato alle sole macro-didascalie dei segmenti, che contengono il contenuto semantico effettivo. Un'estensione naturale consisterebbe nell'applicare il medesimo insieme di test anche alle didascalie dei singoli token ma a quel livello di granularità l'assenza di un contesto musicale ampio rende le descrizioni potenzialmente più esposte alla produzione di didascalie generiche intercambiabili tra segmenti distinti, in più i token non sono pensati come unità semantiche ma come unità metriche.

Questo protocollo impone come precondizione il fatto che i confini temporali dei segmenti corrispondano alla topografia del brano. Se i tagli risultassero errati, il calcolo delle similarità opererebbe su porzioni acustiche asimmetriche, impedendo di isolare l'incoerenza semantica da un banale fallimento del partizionamento. Si consideri, ad esempio, un ritornello i cui confini vengano identificati con qualche secondo di anticipo, includendo ancora nella finestra la coda della strofa precedente: la feature acustica media calcolata su quel segmento risulterebbe un impasto di due sezioni musicalmente distinte, alterandone la reale similarità con l'altro ritornello del brano. Un risultato debole non permetterebbe più di stabilire se la causa risieda in una descrizione poco fondata o, più semplicemente, in un errore di segmentazione a monte che ha corrotto la finestra acustica di riferimento. L'accuratezza dei marker temporali costituisce il fondamento del collaudo strutturale (Sezione 4.4), ed è stata valutata per prima.

L'analisi non esaurisce la verifica del contenuto fattuale. Lo strumento di misura ha un limite proprio. Gli autori di FUTGA e di FUTGA-MIR [6, 48] riportano, nella valutazione del *retrieval*, un calo di prestazioni su MusicCaps quando le didascalie sono generate da LLM invece che scritte da umani. La spiegazione è che la varianza linguistica introdotta dagli LLM, molto più ampia di quella dei testi di addestramento del *text encoder* di CLAP, agisce come elemento *out-of-distribution* nello spazio latente contrastivo. I punteggi misurati vanno quindi letti come una stima prudente della qualità del testo.

4.5.2 *Mode Collapse* e *Repetition Penalty*

Anche quando i confini temporali dei segmenti sono accurati, nulla garantisce che il contenuto testuale generato per ciascuno di essi sia sensibile alle effettive variazioni del segnale acustico nel tempo. Lavori recenti mostrano come il *post-training alignment* tramite apprendimento per rinforzo dalle preferenze umane (il processo a cui sono sottoposti pressoché tutti i moderni modelli linguistici) costituisca un fattore strutturale della riduzione di diversità generativa, un fenomeno noto come *mode collapse* [46]. Un modello linguistico privo di un ancoraggio esplicito ai dati fisici del segnale potrebbe dunque presentare confini temporali accurati e, al contempo, produrre per ciascun segmento una didascalia intercambiabile con quella di un segmento adiacente o distante, vanificando l'obiettivo stesso della segmentazione strutturale.

Le conseguenze per la valutazione sono dirette. Se le didascalie di segmenti diversi sono identiche o quasi, il confronto con l'audio non le distingue, e la dominanza diagonale della matrice di similarità (Sezione 4.5.3) si perde. Il caso è stato osservato con Qwen-72B-Instruct, scartato nella fase di generazione (Sezione 4.3): ha prodotto la stessa didascalia su più segmenti, oltre a sezioni omesse e *output* JSON instabili. È un collasso osservato solo in modo qualitativo, che ha motivato l'esclusione del modello dal confronto quantitativo.

Un rischio speculare, di segno opposto, riguarda i meccanismi correttivi usati per contrastare tale tendenza. Tecniche di decodifica come la *repetition penalty* [47], introdotte per scoraggiare la ripetizione lessicale, potrebbero indurre il modello a introdurre variazioni stilistiche superflue anche laddove il segnale acustico rimanga sostanzialmente invariato. FUTGA adotta una penalità di 1.5. Si tratta di un'ipotesi di lavoro, motivata dal meccanismo di funzionamento di tali tecniche ma non attestata in letteratura con la stessa puntualità del fenomeno opposto.

È dunque necessario un test che verifichi, indipendentemente dalla correttezza dei confini già accertata, se il contenuto testuale generato per ciascun segmento sia ancorato a quel preciso istante temporale, o costituisca invece una parafrasi generica riciclata sull'intero brano, o ancora una variazione stilisticamente ingiustificata rispetto a un contenuto acustico di fatto equivalente.

4.5.3 Matrice di Similarità e Metriche

Per verificare questa proprietà si costruisce una matrice di similarità cross-modale $M_{\text{CLAP}} \in \mathbb{R}^{N \times N}$, ottenuta confrontando, tramite similarità del coseno, l'*embedding* audio del segmento i e l'*embedding* testuale della didascalia del segmento j, per ogni coppia (i, j) della medesima traccia:

$$M_{\text{CLAP}}[i, j] = \cos\left(\mathbf{e}_i^{audio}, \mathbf{e}_j^{text}\right) = \frac{\mathbf{e}_i^{audio} \cdot \mathbf{e}_j^{text}}{\|\mathbf{e}_i^{audio}\| \, \|\mathbf{e}_j^{text}\|}.$$

Gli *embedding* sono ottenuti tramite CLAP, il modello contrastivo audio-testo introdotto nella Sezione 2.3.1. Lì si è visto che l'addestramento con la perdita InfoNCE costruisce la stessa matrice $N \times N$ di similarità coseno impiegata qui, e ne massimizza la diagonale. La dominanza diagonale non è quindi un criterio di successo introdotto ad hoc in questa sede, ma il principio geometrico su cui il modello è stato ottimizzato, riletto in chiave diagnostica anziché come obiettivo di addestramento.

Si adotta la variante *feature fusion* di LAION-CLAP (`laion/clap-htsat-fused`) per i segmenti di tutti i sistemi. FUTGA-MIR usa per questo task il CLAP standard [48]. La scelta è diversa perché il CLAP standard elabora una finestra fissa di 10 secondi, e sceglie a caso un ritaglio di 10 secondi se l'audio è più lungo. I segmenti dei due sistemi sono in media più lunghi di 10 secondi: 21.6 secondi per la pipeline e 79.9 per FUTGA. Un solo ritaglio ne coprirebbe quindi meno della metà nel primo caso e circa il 13% nel secondo. La variante *fusion* gestisce nativamente durate arbitrarie, combinando un campionamento globale dell'intero audio con tre ritagli locali di 10 secondi, fusi tramite un meccanismo di *attention*. I tre ritagli sono scelti a caso a ogni passaggio, quindi è stato fissato un *seed* per la riproducibilità. Nel paper di LAION-CLAP [45] la *fusion* migliora il recupero proprio su clip più lunghe di 10 secondi. La deviazione dal protocollo di FUTGA-MIR è quindi dovuta alla durata dei segmenti del corpus. Un confronto sistematico con *encoder* audio-testo alternativi resta uno sviluppo futuro. Il *text encoder* (RoBERTa) è lo stesso nelle due varianti del modello, quindi il passaggio alla *fusion* non modifica lo spazio testuale. Nessun segmento è escluso per brevità: l'audio più corto della finestra è ripetuto e completato con *padding* dal modello.

Il vocabolario di CLAP è inoltre più piatto di quello delle didascalie generate da un LLM, e questo comprime i valori assoluti di similarità in un intervallo stretto. Per questo la valutazione è relativa e non assoluta, cioè si confronta il rango delle didascalie della stessa traccia e non un punteggio di similarità. Il rango tra le N didascalie resta un segnale valido, molto meno sensibile al problema.

Se il sistema produce descrizioni correttamente ancorate, i valori più elevati della matrice si concentrano lungo la diagonale principale ($i = j$): l'audio del segmento

i risulta più simile alla propria didascalia che a quella di qualsiasi altro segmento della stessa traccia.

Imporre tuttavia una dominanza diagonale rigida costituirebbe un criterio di successo mal calibrato per il dominio musicale. La musica, specialmente nei generi a struttura ripetitiva come l'EDM, presenta sezioni distinte ma acusticamente equivalenti. Se i segmenti 2 e 5 corrispondono a due *drop* pressoché identici, è ragionevole che anche le celle fuori diagonale (2,5) e (5,2) registrino valori elevati, poiché l'audio del primo *drop* risulterà comunque simile alla didascalia scritta per il secondo. L'emersione di queste attivazioni fuori diagonale non costituisce quindi un segnale di fallimento, ma la naturale controparte testuale della ripetitività intrinseca del segnale acustico.

Il termine *dominanza diagonale*, qui e nel seguito, è impiegato in senso descrittivo e non nell'accezione algebrica stretta, secondo cui il valore diagonale dovrebbe superare la somma di tutti i valori fuori diagonale sulla medesima riga. È una condizione pensata per contesti diversi (ad esempio la garanzia di invertibilità di una matrice), e risulterebbe troppo rigida per una matrice di similarità coseno, dove pochi valori extradiagonali moderatamente elevati la violerebbero per pura aritmetica, indipendentemente dalla qualità reale dell'ancoraggio.

Per questo motivo la dominanza diagonale non è valutata con un unico criterio rigido, ma tramite metriche complementari, ciascuna pensata per assorbire una specifica fonte di ambiguità legittima. Lo scopo è accertare che ciascuna didascalia sia ancorata in modo univoco al proprio segmento, tollerando le ambiguità legittime descritte di seguito, senza pretendere di certificare la fedeltà quantitativa dell'intera topologia ricorsiva del brano. In primo luogo, anziché un criterio Top-1 secco per cui la cella (i, i) deve essere l'unico massimo di riga, si adotta come metrica principale il *Mean Reciprocal Rank* (MRR) calcolato sulla diagonale:

$$MRR = \frac{1}{N} \sum_{i=1}^{N} \frac{1}{\text{rank}_i},$$

dove rank_i è la posizione, nella classifica per similarità decrescente delle N didascalie rispetto all'audio del segmento i, occupata dalla didascalia corretta i. Se l'audio del primo *drop* colloca al primo posto la didascalia del secondo *drop* per l'affinità acustica appena descritta e solo al secondo posto la propria, il sistema non riceve un punteggio nullo, come accadrebbe con un criterio Top-1 secco, ma un punteggio parziale (0.5). L'accuratezza Top-1 in senso stretto, ossia la frazione di segmenti per cui la cella (i, i) è l'effettivo massimo di riga, è comunque calcolata e riportata in parallelo, non come criterio di successo ma come misura interpretativa di supporto.

In secondo luogo, si introduce una tolleranza posizionale tramite la *Windowed Accuracy*: il match è considerato corretto non solo quando il picco di similarità ricade

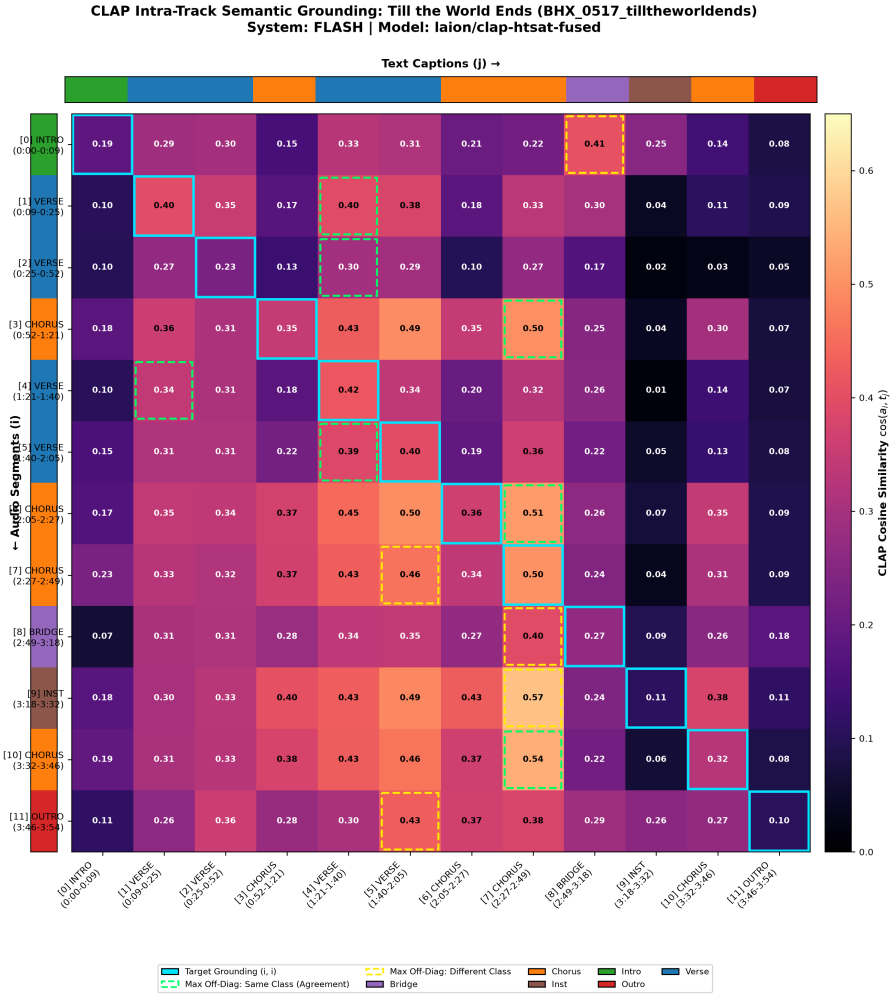


Figura 4.6: Matrice di similarità cross-modale M_{CLAP} per il brano *Till the World Ends* (pipeline Flash, 12 segmenti). Le righe sono i segmenti audio, le colonne le didascalie. Il riquadro ciano indica la cella diagonale, quello verde il massimo extradiagonale della riga quando i due segmenti hanno la stessa classe funzionale, quello giallo quando le classi sono diverse. La diagonale non è sempre il massimo di riga. In 7 righe su 12 le attivazioni extradiagonali più alte coinvolgono segmenti della stessa classe (strofe con strofe, ritornelli con ritornelli).

esattamente sulla cella (i, i), ma anche quando ricade su un segmento immediatamente adiacente ($i - 1$ o $i + 1$). Questa tolleranza assorbe un'ambiguità di natura diversa da quella gestita dall'MRR: non la somiglianza acustica tra segmenti distanti e ripetuti, ma il fatto che, anche quando il *timestamp* di un confine è correttamente individuato, il contenuto acustico del segmento può presentare uno sconfinamento fisico verso il segmento adiacente (una nota di coda che si protrae oltre il taglio nominale, una dissolvenza incrociata tra due sezioni). Per questo la tolleranza è riportata sempre accanto al criterio Top-1 rigido e non in sua sostituzione. Un eventuale offset sistematico tra confini e didascalie, come nel caso di un sistema che descriva costantemente il segmento precedente anziché quello corretto, resta infatti visibile nella metrica rigida anche nei casi in cui la *Windowed Accuracy* lo maschererebbe.

La terza metrica, il *Semantic Class Agreement*, riguarda la legittimità delle attivazioni extradiagonali e ha una sezione propria (Sezione 4.5.6).

Le metriche dipendono dal numero di segmenti del brano. Con tre segmenti il valore atteso per puro caso è molto più alto che con undici. La pipeline Flash produce in media circa 11 segmenti per brano, FUTGA ne produce sempre 3. Un confronto sui valori grezzi favorirebbe il sistema con meno segmenti. Per questo i risultati sono espressi come guadagno rispetto al livello di caso, calcolato separatamente per ciascun sistema.

Il protocollo è applicato alle 50 tracce del *benchmark* (Sezione 4.1). Per ciascuna traccia si calcola la matrice M_{CLAP} e, a partire da essa, le metriche descritte. L'aggregazione finale avviene a livello di traccia (*macro-averaging*): ciascuna delle 50 tracce contribuisce con un unico valore per metrica, indipendentemente dal numero di segmenti, evitando che le tracce più lunghe pesino più delle altre. Lo stesso protocollo è applicato, sul medesimo campione, alle didascalie generate da FUTGA, per un confronto diretto e appaiato. Il confronto con il livello di caso e quello tra i sistemi usano il test di Wilcoxon appaiato, come in RQ1 (Sezione 4.4.2).

Il superamento di questo test mostra che ciascuna didascalia j è ancorata, a meno delle legittime ambiguità introdotte dalla ripetitività musicale, all'intervallo temporale j. Non mostra che il sistema abbia compreso la macro-struttura ricorsiva del brano. Ci si aspetterebbe che le celle (2,5) e (5,2) risultino elevate in proporzione alla somiglianza acustica reale tra i segmenti 2 e 5, e non altrove. Lo spazio latente di CLAP, essendo uno spazio di compromesso addestrato per una comprensione contrastiva generalista, non ha la risoluzione per certificare questa proporzionalità. È in grado di segnalare l'esistenza di un'affinità fuori diagonale, non di garantire che il grado di tale affinità rispecchi quello della somiglianza acustica. Le attivazioni extradiagonali possono però essere verificate in modo più semplice, controllando se coinvolgono segmenti della stessa classe funzionale (Sezione 4.5.6).

4.5.4 Coerenza Intra-Brano

La Tabella 4.10 riporta il guadagno medio rispetto al livello di caso sulle 50 tracce.

Tabella 4.10: Coerenza audio-testo intra-brano: guadagno rispetto al livello di caso (50 tracce). Il p-value si riferisce al confronto appaiato tra pipeline e FUTGA.

Metrica	Pipeline	FUTGA	p
MRR	+0.085	+0.022	0.0003
Top-1	+0.075	+0.033	0.012
Windowed Accuracy (± 1)	+0.083	+0.089	0.85

La pipeline supera il livello di caso su tutte e tre le metriche, con $p < 0.05$. Rispetto a FUTGA è migliore su MRR e Top-1. Sulla *Windowed Accuracy* non c'è differenza (0.85). Una possibile spiegazione è che, con soli tre segmenti, una finestra di ± 1 copra quasi tutto il brano, quindi FUTGA recupera il vantaggio che non ha sulle metriche più esigenti.

Il segnale è statisticamente solido ma di entità modesta. La *Top-1 Accuracy* intra-brano della pipeline è del 16.6%. In 3 tracce su 50 la didascalia corretta non è mai la migliore corrispondenza per il proprio segmento (*Top-1* nulla). Il livello di caso differisce molto tra i sistemi, perché dipende dal numero di segmenti: per la pipeline è 0.274 (MRR), 0.091 (Top-1) e 0.256 (*Windowed Accuracy*), per FUTGA 0.611, 0.333 e 0.778. I valori grezzi di FUTGA sarebbero quindi superiori a quelli della pipeline, ma solo perché il suo compito è più facile. Il guadagno non dipende dal numero di segmenti: la correlazione di Spearman tra numero di segmenti e difficoltà non è significativa su nessuna metrica. I dati indicano un ancoraggio reale ma debole del testo all'audio, non un'associazione forte.

4.5.5 Recupero *Many-to-Many* tra Brani

La coerenza intra-brano confronta segmenti dello stesso brano, che condividono timbro e genere. Una verifica più severa consiste nel recuperare il segmento corretto in un insieme di segmenti di brani diversi. Il test è ispirato al task di *Audio Clip Retrieval* (*many-to-many retrieval*) di FUTGA [6], ma non lo replica. Nella formulazione originale la valutazione avviene a risoluzione di canzone: le similarità CLAP tra segmenti testuali e audio sono aggregate con una media pesata per IoU in un solo punteggio per coppia query-traccia. L'informazione sul singolo segmento è quindi compressa prima del *ranking*. L'estensione a risoluzione di segmento, invece, valuta se dato un testo si recupera il segmento giusto, non soltanto il brano giusto. La versione *song-level* con pesi IoU non è stata eseguita (Sezione 4.7). Con sole 50 tracce un recupero per brano sarebbe troppo facile, perché genere e strumentazione basterebbero a distinguerle. Il test a livello di segmento chiede invece se una singola

didascalia sia abbastanza specifica da ritrovare il proprio frammento, in un catalogo che comprende anche segmenti di altri brani.

Nell'estensione, l'unità di retrieval diviene il singolo segmento audio. Il catalogo è composto da $M = \sum_{d=1}^{N} J_d$ segmenti, dove J_d è il numero di segmenti della traccia d, e ogni segmento è un candidato indipendente nel *ranking*. Per ciascun segmento-query i della traccia q si calcola la similarità del coseno $\cos(\mathbf{T}_i, \mathbf{A}_j)$ tra il suo *embedding* CLAP e quello di ciascuno degli M segmenti audio del catalogo. L'aggregazione pesata per IoU non è applicabile: il confronto è diretto, uno a uno. Usare l'IoU come peso introdurrebbe anzi un *bias* posizionale, perché due segmenti nella stessa posizione relativa di tracce distinte avrebbero IoU elevata indipendentemente dal contenuto.

Il match corretto è identificato dall'identità di indice ($j = i$ con $d = q$), perché ogni didascalia ha già il proprio segmento audio esatto, con lo stesso indice. Il criterio è quindi esatto e non richiede alcuna soglia di IoU. Per ciascuna query i candidati sono ordinati per similarità decrescente e si individua il rango $r_{q,i}$ occupato dal match corretto. La *Recall@K* è calcolata sulla popolazione dei segmenti-query:

$$\text{Recall@K} = \frac{1}{\sum_{q=1}^{N} I_q} \sum_{q=1}^{N} \sum_{i=1}^{I_q} \mathbb{I}(r_{q,i} \leq K) \times 100,$$

dove I_q è il numero di segmenti della traccia q. Il denominatore è quindi il numero totale di segmenti-query e non il numero di canzoni. La prova è eseguita nelle due direzioni: Audio→Testo (dato il segmento audio, si recupera la didascalia) e Testo→Audio (dato il testo, si recupera il segmento). Dal punto di vista applicativo, questo task risponde alla domanda operativa di chi cerca nel catalogo un frammento con una certa caratteristica: il sistema deve individuare il segmento giusto, non soltanto il brano giusto.

Il catalogo comprende circa 550 segmenti: 554 candidati per la pipeline e 150 per FUTGA. La differenza dipende dal numero di segmenti prodotti da ciascun sistema.

Tabella 4.11: Recupero *many-to-many* a livello di segmento. Il fattore indica il rapporto con il livello di caso.

Sistema	Direzione	Recall@10	Fattore sul caso	p
Pipeline	Audio→Testo	7.58%	4.2×	$1.6 \cdot 10^{-14}$
Pipeline	Testo→Audio	9.21%	5.1×	$7.7 \cdot 10^{-21}$
FUTGA	Audio→Testo	9.33%	1.4×	0.13
FUTGA	Testo→Audio	11.33%	1.7×	0.02

Il valore grezzo di FUTGA è più alto, ma non è confrontabile. Il suo catalogo è di 150 candidati contro 554: con meno candidati, anche una scelta casuale colloca il

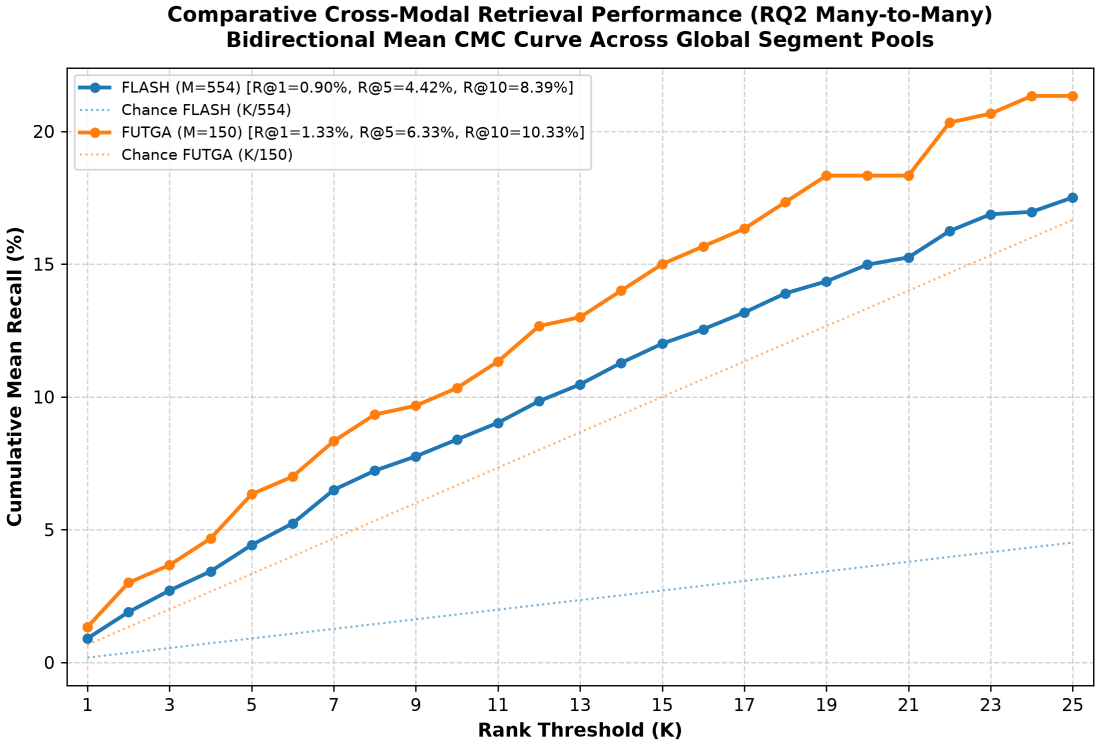


Figura 4.7: Recall cumulativa in funzione del rango K (media delle due direzioni, fino a $K = 25$) per pipeline e FUTGA. Le linee tratteggiate indicano il livello di caso di ciascun sistema ($K/554$ e $K/150$). I cataloghi hanno dimensioni diverse, quindi le curve vanno confrontate con la propria linea del caso e non tra loro.

segmento corretto tra i primi dieci più spesso. Il fattore sul livello di caso corregge questo effetto. La pipeline è oltre quattro volte sopra il caso in entrambe le direzioni, con p molto piccoli. FUTGA è sopra il caso di 1.4 volte in Audio→Testo, senza significatività, e di 1.7 volte in Testo→Audio ($p = 0.02$). La significatività del p in tabella è calcolata con un test binomiale sulla Recall@10 rispetto al livello di caso. Un test sui ranghi (Kolmogorov-Smirnov) dà lo stesso esito: valori molto piccoli per la pipeline, non significativo per FUTGA in Audio→Testo ($p = 0.07$) e marginale in Testo→Audio ($p = 0.026$) Il catalogo di FUTGA è più piccolo, quindi anche la potenza statistica è minore: non si può escludere che con più segmenti il segnale emerga. Con i dati raccolti, l'ipotesi che FUTGA superi il caso in Audio→Testo non è supportata.

La *Recall@1* della pipeline è intorno all'1% (0.72% in Audio→Testo, 1.08% in Testo→Audio, media 0.90%) e di poco superiore per FUTGA (1.33%). Il testo prodotto non permette quindi di identificare con precisione il segmento tra centinaia di candidati. Il risultato conferma la lettura della sezione precedente: il legame

tra testo e audio esiste ma è debole. Una possibile spiegazione è che segmenti omologhi di brani diversi (due strofe, due ritornelli) condividano caratteristiche acustiche e semantiche simili e aumentino così i distrattori plausibili. Questa ipotesi non è stata verificata.

4.5.6 *Semantic Class Agreement*

Il *Semantic Class Agreement* (SCA) verifica se le attivazioni extradiagonali elevate corrispondano a segmenti della medesima classe funzionale. Distingue così l'eco strutturale legittimo dal falso positivo casuale.

La sua applicazione richiede di stabilire quali celle extradiagonali siano abbastanza elevate da richiedere una verifica. Per ciascuna riga i della matrice si individua il valore massimo fuori diagonale, $\max_{j \neq i} M_{\text{CLAP}}[i, j]$, e lo si considera un'attivazione extradiagonale significativa se supera una soglia relativa al valore diagonale della medesima riga, inizialmente fissata all'80% di $M_{\text{CLAP}}[i, i]$. Solo per le attivazioni significative si verifica se il segmento j corrispondente condivida la classe funzionale del segmento i, già accertata in sede di validazione strutturale (Sezione 4.4). Ad esempio, un'attivazione significativa nella cella (2,5) è considerata concorde, e dunque interpretata come ripetizione strutturale legittima, se e solo se entrambi i segmenti hanno la medesima etichetta (es. *chorus*), mentre è conteggiata come falso positivo in caso di discordanza. La metrica finale è la percentuale di attivazioni significative risultate concordi sul totale delle attivazioni significative rilevate nel campione.

La soglia dell'80% era indicativa e va calibrata empiricamente. Sono state valutate quattro soglie: la soglia fissa all'80%, una soglia calibrata sulla media degli elementi extradiagonali del corpus e due soglie calibrate sul 90° e sul 95° percentile della distribuzione extradiagonale. I percentili, come la media, sono calcolati sull'intero corpus (stesso sistema, 50 tracce). La soglia fissa e quella sulla media si sono rivelate poco selettive. Il massimo tra circa dieci valori supera quasi sempre la loro media per costruzione, e il vocabolario piatto di CLAP avvicina tra loro tutte le similarità. Nei primi risultati con la pipeline Flash le attivazioni significative scattavano su circa il 96% delle righe con la soglia fissa e sul 95% con quella sulla media. Con una condizione che scatta quasi sempre, non si distingue una confusione realmente forte da una banale. I percentili isolano invece le attivazioni anomale, e per questo sono la soglia di riferimento. Le altre due sono riportate per completezza.

Il valore osservato è confrontato con una base di caso: la probabilità che due segmenti condividano l'etichetta per pura composizione delle etichette della traccia, senza alcun segnale di CLAP. Il confronto è appaiato per brano, con test di Wilcoxon, sul sistema Flash.

Tabella 4.12: *Semantic Class Agreement* della pipeline Flash. La differenza è rispetto alla base di caso. Per P90 e P95 il confronto appaiato riguarda le 48 e le 42 tracce con almeno un'attivazione significativa. Tutti i confronti hanno $p < 0.0001$.

Soglia	Osservato	Base di caso	Differenza
Fissa 80%	0.284	0.164	+0.120
Media calibrata	0.295	0.169	+0.126
P90	0.289	0.148	+0.141
P95	0.365	0.152	+0.213

L'accordo osservato supera la base di caso in tutte le soglie. Il margine cresce con la severità della soglia, da +0.120 a +0.213. Questo andamento è coerente con ripetizioni strutturali reali: quando l'attivazione extradiagonale è molto forte, il segmento coinvolto ha la stessa classe più spesso di quanto accada per caso. Le confusioni della matrice sono quindi in parte ripetizioni della stessa sezione e non errori casuali. Resta comunque basso il valore assoluto: con la soglia fissa, circa il 28% delle attivazioni significative è concorde.

Per FUTGA il confronto non è calcolabile. Il sistema produce una struttura fissa di tre segmenti con etichette sempre diverse, quindi non esistono coppie con la stessa classe. L'accordo osservato e la base di caso sono entrambi nulli a ogni soglia. Inoltre FUTGA elabora solo i primi 30 secondi di audio (Sezione 4.3.2), per cui la struttura ripetitiva dell'intero brano non è comunque accessibile.

4.5.7 Conclusioni sulla Valutazione Semantica

I tre esperimenti convergono su una lettura unica. Il testo generato dalla pipeline è associato al segmento corretto in misura superiore al caso, in modo statisticamente significativo, sia nel confronto interno al brano sia nel recupero tra brani. Rispetto a FUTGA, la pipeline è migliore su MRR e Top-1, equivalente sulla *Windowed Accuracy* e l'unica a mostrare un segnale chiaro nel recupero tra segmenti. Le attivazioni extradiagonali forti coinvolgono segmenti della stessa classe più spesso di quanto accada per caso, con un margine che cresce con la soglia.

L'entità del segnale resta però modesta. La *Top-1 Accuracy* intra-brano è del 16.6% e la *Recall@1* è intorno all'1%. I dati sostengono un ancoraggio del testo all'audio, ma non un ancoraggio forte. Non sostengono l'affermazione che le didascalie siano accurate nel contenuto.

Il confronto con FUTGA ha alcuni vincoli. La diversa cardinalità dei segmenti rende i valori grezzi non confrontabili, e per questo si usa il guadagno sul livello di caso. L'SCA non è calcolabile per FUTGA. Lo strumento di misura, CLAP, è inoltre fuori distribuzione per il testo di un LLM, quindi i valori sono una stima

prudente. La verifica dipende infine dalla correttezza dei confini, già valutata nella sezione precedente.

In sintesi, RQ2 riceve una risposta positiva ma limitata: le didascalie sono coerenti con l'audio più di quanto sia casuale, senza un grado di precisione elevato. Restano fuori da questa valutazione le dimensioni non eseguite, discusse insieme agli altri limiti del lavoro (Sezione 4.6).

4.6 Limiti e Discussione

Questa sezione raccoglie i limiti della valutazione. Alcuni riguardano i moduli del sistema, altri il protocollo e i dati, altri la dipendenza da modelli proprietari. Sono presentati come scelte fatte entro i vincoli di tempo e di risorse del lavoro, con le conseguenze che hanno per l'interpretazione dei risultati.

4.6.1 Limiti dei Moduli DSP

Il *beat tracker* impiegato (BeatNet) non è stato ottimizzato né confrontato con alternative. Il calo di HR.5F e di HR3F rispetto a SongFormer non va quindi attribuito al *tracker* senza un test dedicato. La Sezione 4.4.4 indica che il limite sui confini stretti è legato anche alla griglia a 16 battiti, ma questa è una spiegazione indiretta.

La catena di trascrizione (separazione delle voci, rilevamento dell'attività vocale con RMS, WhisperX) non è stata valutata. Non è stato calcolato alcun *word error rate*, quindi la qualità del testo trascritto che raggiunge gli agenti non è quantificata. Non sono stati valutati singolarmente nemmeno la stima del BPM, la stima della tonalità e l'ancoraggio dei *cue point* alla griglia (Cue-DETR). Il sistema è inoltre ottimizzato per la musica elettronica in 4/4, mentre il corpus di valutazione è in larga parte fuori da questo dominio (Sezione 4.4.7).

Per l'*Acoustic Profiler* e il *Cultural Researcher* non sono stati misurati il loro contributo alla deduzione del timbro né la densità informativa dell'output. Non sono state valutate le allucinazioni dei modelli linguistici, che dipendono dal modello usato più che dall'architettura. Un'eventuale allucinazione a monte, per esempio sul genere, si propagherebbe alle didascalie senza essere intercettata dai test eseguiti.

4.6.2 Limiti di Protocollo e di Dati

Il corpus è piccolo e sbilanciato: 50 tracce ripartite in 25, 15 e 10 tra i tre domini. Lo split fuori dominio ha solo 10 tracce, quindi i risultati per dominio hanno una potenza statistica ridotta e le spiegazioni proposte per le differenze tra domini non sono verificate (Sezione 4.4.10). Non è stato misurato l'effetto dell'assenza di metadati, cioè di titolo e artista, sulle prestazioni del *Cultural Researcher*.

Ogni sistema è stato eseguito una sola volta per traccia. Non c'è quindi una stima della varianza tra esecuzioni né della stocasticità dei modelli linguistici. Ripetere le esecuzioni permetterebbe di separare l'effetto del modello dal caso.

Il confronto ha una sola *baseline* aperta. FUTGA non è stato addestrato per l'analisi strutturale, produce poche sezioni per brano ed è stato raffinato su HarmonixSet, da cui deriva il corpus (Sezione 4.2). In sei brani il modello non ha rispettato il formato di output e si è assegnata la struttura standard (intro, verse, outro) con i confini prodotti dal modello (Sezione 4.3.2). Inoltre FUTGA elabora solo i primi 30 secondi di audio, quindi nel confronto semantico le sue didascalie descrivono solo quella finestra e la Semantic Class Agreement non è calcolabile. Pesa anche la scelta di lasciare FUTGA invariato, bug incluso, come nel *paper*.

Per RQ2 lo strumento di misura è CLAP, fuori distribuzione per testi generati da un LLM, quindi i valori sono una stima prudente della qualità del testo. La verifica non dimostra che le didascalie siano corrette nel contenuto, ma che sono più ancorate al proprio segmento di quanto accada per caso. Dipende inoltre dalla correttezza dei confini, valutata in RQ1.

Per mancanza di tempo non sono stati eseguiti: l'analisi con matrici di auto-similarità e test di Mantel, il test di equivalenza (TOST) sulla ACC, il confronto con la *baseline* MSAF, la prova con metadati anonimizzati e l'esecuzione di Gemini 2.5 Pro sulle stesse 50 tracce.

4.6.3 Dipendenza da Modelli Linguistici Proprietari

La pipeline usa modelli Gemini a pagamento, con costi di utilizzo delle API, tranne la variante Lite che gira nel *tier* gratuito. I modelli proprietari possono cambiare o essere ritirati, e questo limita la riproducibilità esatta dei risultati nel tempo.

4.7 Sviluppi Futuri della Valutazione

La batteria di test descritta nel capitolo non esaurisce le verifiche possibili. Per i vincoli di tempo sono state portate a termine la valutazione strutturale (RQ1) e quella della coerenza semantica intra-brano e del recupero tra segmenti (RQ2). Le estensioni seguenti completerebbero il quadro.

Per la semantica, una prima verifica riguarda la coerenza gerarchica. Confrontare con *Sentence-BERT* la macro-didascalia con la concatenazione delle descrizioni dei suoi *token* giustificherebbe la scelta di valutare i soli macro-segmenti, che nel presente lavoro è motivata solo in modo architetturale (Sezione 4.5.1). Una seconda riguarda l'isomorfismo topologico: confrontare con un test di Mantel le matrici di auto-similarità audio e testuali, e triangolarle con la matrice cross-modale di CLAP, mostrerebbe se la geometria delle ripetizioni del testo rispecchia quella del segnale.

Altre estensioni misurerebbero il contenuto delle didascalie. La densità informativa potrebbe essere valutata sullo split *long-form* di MMAU-Pro, confrontando l'interrogazione di un modello valutatore con audio grezzo e con il JSON del sistema, con uno studio di ablazione sulla perdita di informazione tra JSON e macro-didascalia. La resa descrittiva potrebbe essere valutata con metriche NLP su MusicCaps e SongDescriber, con la coerenza lessicale, con la *Reverse Feature Extraction* su genere, strumenti e *mood*, e con un test soggettivo (*Mean Opinion Score*) affiancato da un modello come giudice.

Il recupero potrebbe infine essere esteso al *Whole-track Retrieval*, con l'encoder CLAP esteso di FUTGA-MIR, e al recupero a livello di canzone con pesi IoU, come in FUTGA (Sezione 4.5.5). Resta da svolgere anche un'analisi dedicata di latenza, colli di bottiglia e costi per variante. La Sezione 4.4.5 ne dà solo un'indicazione qualitativa.

Capitolo 5

Conclusioni

Il presente lavoro è partito da una difficoltà della comprensione musicale automatica. I modelli specializzati nell'analisi della struttura individuano i confini con precisione, ma restituiscono solo un'etichetta funzionale per ogni sezione. I modelli generativi audio-linguaggio producono descrizioni articolate, ma operano su rappresentazioni latenti e non permettono di controllare su quali elementi del segnale si fondino. Per tenere insieme segmentazione e descrizione è stata sviluppata una *pipeline* modulare. Un motore DSP discretizza il brano in *token* da sedici battiti e ne calcola la telemetria. Quattro agenti linguistici la elaborano in sequenza fino a produrre sezioni strutturali, ciascuna con un'etichetta funzionale, una didascalia e una motivazione esplicita. Il sistema è stato valutato su 50 tracce di SongFormBench-HS, ripartite in tre domini di difficoltà crescente, e confrontato con SongFormer e FUTGA (Capitolo 4).

Alla prima domanda di ricerca, sull'accuratezza strutturale, la valutazione risponde in modo articolato. Senza alcun addestramento sul compito, la *pipeline* raggiunge un'accuratezza di etichettatura vicina a quella di SongFormer (ACC 0.701 contro 0.749), con uno scarto contenuto, di 4.8 punti, ma statisticamente significativo, e molto superiore a quella di FUTGA (0.280). Sulla collocazione dei confini il divario è molto più ampio. SongFormer è nettamente migliore, in particolare con la tolleranza stretta (HR.5F 0.379 contro 0.694). Il confronto tra le varianti mostra che questo limite non dipende dal modello linguistico, perché l'HR.5F resta quasi identico con Flash, Pro e Lite. Sembra legato alla discretizzazione a monte, con *token* che durano alcuni secondi. Lo stesso confronto indica che un modello più grande non è necessariamente migliore per questo compito. Il test con audio diretto, a parità di modello, attribuisce poi alla *pipeline* un vantaggio di circa 14 punti di ACC e mostra che senza l'ancoraggio ai battiti compaiono frequenti anomalie temporali. Per queste ragioni, il contributo dell'architettura appare più rilevante della scala del modello.

Alla seconda domanda, sull'ancoraggio semantico, la risposta è positiva ma limitata. Le didascalie generate sono associate al proprio segmento più di quanto avverrebbe per caso, in modo statisticamente significativo, sia nel confronto interno al brano sia nel recupero tra segmenti di brani diversi. Il guadagno rispetto al caso è superiore a quello di FUTGA sulle metriche più esigenti, e le attivazioni extradiagonali forti coinvolgono segmenti della stessa classe funzionale più spesso di quanto accada per caso. L'entità del segnale resta però modesta, e i dati non permettono di affermare che le didascalie siano corrette nel contenuto. L'ancoraggio è quindi reale ma debole. In assenza di un riferimento testuale annotato da esperti a livello di segmento, la verifica è stata condotta sulla coerenza interna del sistema, non su un confronto con descrizioni umane.

Nel complesso, il sistema proposto non intende sostituire i modelli specializzati sul compito in cui eccellono. Cede in precisione temporale, ma restituisce in più, per ogni segmento, una descrizione e una motivazione riconducibile a misure fisiche esplicite. Rende inoltre possibile individuare l'origine di un errore, isolando il parametro che lo ha generato, cosa che un modello alimentato con l'audio grezzo non consente. I limiti del lavoro sono stati discussi nelle Sezioni 3.4 e 4.6. Riguardano soprattutto un corpus di dimensioni ridotte, una sola esecuzione per traccia, un'unica *baseline* aperta per il confronto semantico, uno strumento di misura fuori distribuzione per testi generati da modelli linguistici e la dipendenza da modelli proprietari.

Le direzioni di sviluppo si dividono in due gruppi. Sul versante del sistema, i limiti già descritti nel Capitolo 3 suggeriscono di integrare un modulo dedicato al riconoscimento di timbro e strumentazione, oggi dedotti solo indirettamente, e di sperimentare beat tracker alternativi o una griglia più fine per ridurre il divario sui confini stretti. Sul versante della valutazione, le verifiche non eseguite sono raccolte nella Sezione 4.7. Nel lungo periodo, la rappresentazione per *token* e le descrizioni associate a ciascun segmento potrebbero fornire a un agente decisionale le informazioni necessarie per compiti come la costruzione automatica di un mix musicale. Tale prospettiva, che ha motivato alcune scelte progettuali del sistema, non è stata sviluppata né valutata in questo lavoro.

Bibliografia

[1] Meinard Müller. *Fundamentals of Music Processing: Audio, Analysis, Algorithms, Applications*. Cham: Springer International Publishing, 2015. DOI: 10.1007/978-3-319-21945-5.

[2] Jonathan Foote. «Automatic audio segmentation using a measure of audio novelty». In: *IEEE International Conference on Multi-Media and Expo*. Vol. 1. 2000. DOI: 10.1109/ICME.2000.869637.

[3] Jouni Paulus, Meinard Müller e Anssi Klapuri. «State of the Art Report: Audio-Based Music Structure Analysis.» In: 2010.

[4] Ilaria Manco et al. «MusCaps: Generating Captions for Music Audio». In: 2021. DOI: 10.1109/IJCNN52387.2021.9533461.

[5] SeungHeon Doh et al. «LP-MusicCaps: LLM-BASED PSEUDO MUSIC CAPTIONING» (2023).

[6] Junda Wu et al. *Futga: Towards Fine-grained Music Understanding through Temporally-enhanced Generative Augmentation*. 2024. DOI: 10.48550/arXiv.2407.20445. arXiv: 2407.20445[cs.SD].

[7] Benjamin Elizalde et al. *CLAP: Learning Audio Concepts From Natural Language Supervision*. _eprint: 2206.04769. 2022. URL: https://arxiv.org/abs/2206.04769.

[8] Òscar Celma, Perfecto Herrera e Xavier Serra. «Bridging the Music Semantic Gap». In: *Workshop on Semantic Web Applications*. 2006. URL: https://ceur-ws.org/Vol-187/20.pdf.

[9] Chunbo Hao et al. *SongFormer: Scaling Music Structure Analysis with Heterogeneous Supervision*. 2026. DOI: 10.48550/arXiv.2510.02797. arXiv: 2510.02797[eess.AS].

[10] Mingchen Shao et al. *Listening with Time: Precise Temporal Awareness for Long-Form Audio Understanding*. 2026. URL: https://arxiv.org/abs/2604.22245.

[11] Sreyan Ghosh et al. *Music Flamingo: Scaling Music Understanding in Audio Language Models*. 2025. DOI: 10.48550/arXiv.2511.10289. arXiv: 2511.10289[eess.AS].

[12] Irmak Bukey et al. *Rethinking Music Captioning with Music Metadata LLMs*. 2026. DOI: 10.48550/arXiv.2602.03023. arXiv: 2602.03023[cs.SD].

[13] Anuradha Chopra, Abhinaba Roy e Dorien Herremans. *SonicVerse: Multi-Task Learning for Music Feature-Informed Captioning*. 2025. DOI: 10.48550/arXiv.2506.15154. arXiv: 2506.15154[cs.SD].

[14] Max Bain et al. «WhisperX: Time-Accurate Speech Transcription of Long-Form Audio». In: *INTERSPEECH 2023*. INTERSPEECH 2023. ISCA, 2023. DOI: 10.21437/Interspeech.2023-78.

[15] Sebastian Böck et al. *madmom: a new Python Audio and Music Signal Processing Library*. 2016. DOI: 10.48550/arXiv.1605.07008. arXiv: 1605.07008[cs.SD].

[16] Mickaël Zehren, Marco Alunno e Paolo Bientinesi. «Automatic Detection of Cue Points for the Emulation of DJ Mixing». *Computer Music Journal* 46.3 (2022). DOI: 10.1162/comj_a_00652.

[17] Sebastian Böck, Florian Krebs e Gerhard Widmer. «Joint Beat and Downbeat Tracking with Recurrent Neural Networks». In: *International Society for Music Information Retrieval Conference*. 2016. URL: https://api.semanticscholar.org/CorpusID:15831944.

[18] Mojtaba Heydari, Frank Cwitkowitz e Zhiyao Duan. *BeatNet: CRNN and Particle Filtering for Online Joint Beat Downbeat and Meter Tracking*. 2021. DOI: 10.48550/arXiv.2108.03576. arXiv: 2108.03576[eess.AS].

[19] Yun-Ning Hung et al. *Modeling Beats and Downbeats with a Time-Frequency Transformer*. 2022. URL: https://arxiv.org/abs/2205.14701.

[20] Jingwei Zhao, Gus Xia e Ye Wang. *Beat Transformer: Demixed Beat and Downbeat Tracking with Dilated Self-Attention*. 2022. URL: https://arxiv.org/abs/2209.07140.

[21] Francesco Foscarin, Jan Schlüter e Gerhard Widmer. *Beat this! Accurate beat tracking without DBN postprocessing*. 2024. URL: https://arxiv.org/abs/2407.21658.

[22] Peter Knees et al. «Two Data Sets for Tempo Estimation and Key Detection in Electronic Dance Music Annotated from User Corrections». In: *Proceedings of the 16th International Society for Music Information Retrieval Conference (ISMIR)*. 2015. DOI: 10.5281/zenodo.1414995.

[23] Hendrik Schreiber, Frank Zalkow e Meinard Müller. «Modeling and Estimating Local Tempo: a Case Study on Chopin's Mazurkas». In: 2020. DOI: 10.5281/zenodo.4245546.

[24] Michelle L. Daniels. *Tempo Estimation and Causal Beat Tracking Using Ensemble Learning*. Published: Music Information Retrieval Evaluation eXchange (MIREX), extended abstract. 2014. URL: https://www.music-ir.org/mirex/abstracts/2014/MD2.pdf.

[25] Giulia Argüello, Luca A. Lanzendörfer e Roger Wattenhofer. *Cue Point Estimation using Object Detection*. 2024. DOI: 10.48550/arXiv.2407.06823. arXiv: 2407.06823[cs.AI].

[26] J.P. Bello et al. «A tutorial on onset detection in music signals». *IEEE Transactions on Speech and Audio Processing* 13.5 (2005). DOI: 10.1109/TSA.2005.851998.

[27] Geoffroy Peeters. «A large set of audio features for sound description (similarity and classification) in the CUIDADO project» (2004).

[28] Alexandre Défossez. *Hybrid Spectrogram and Waveform Source Separation*. 2022. DOI: 10.48550/arXiv.2111.03600. arXiv: 2111.03600[eess.AS].

[29] Simon Rouard, Francisco Massa e Alexandre Défossez. «Hybrid Transformers for Music Source Separation». In: *ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Rhodes Island, Greece: IEEE, 2023. DOI: 10.1109/ICASSP49357.2023.10096956.

[30] Wei-Tsung Lu et al. *Music Source Separation with Band-Split RoPE Transformer*. 2023. URL: https://arxiv.org/abs/2309.02612.

[31] Derry FitzGerald. «Harmonic/Percussive Separation Using Median Filtering» (2010).

[32] Takuya Fujishima. «Realtime Chord Recognition of Musical Sound: a System Using Common Lisp Music». In: *Proceedings of the International Computer Music Conference (ICMC)*. International Computer Music Association, 1999. URL: http://hdl.handle.net/2027/spo.bbp2372.1999.446.

[33] Judith C. Brown. «Calculation of a constant Q spectral transform». *Acoustical Society of America Journal* 89.1 (1991). DOI: 10.1121/1.400476.

[34] Carol L. Krumhansl. *Cognitive Foundations of Musical Pitch*. Oxford Psychology Series 17. New York: Oxford University Press, 1990. URL: https://global.oup.com/academic/product/cognitive-foundations-of-musical-pitch-9780195148367.

[35] Carol L. Krumhansl e Edward J. Kessler. «Tracing the dynamic changes in perceived tonal organization in a spatial representation of musical keys». *Psychological Review* 89 (1982). URL: https://pubmed.ncbi.nlm.nih.gov/7134332/.

[36] Alexei Baevski et al. *wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations*. 2020. URL: https://arxiv.org/abs/2006.11477.

[37] Jaza Syed et al. *Exploiting Music Source Separation for Automatic Lyrics Transcription with Whisper*. 2025. DOI: 10.48550/arXiv.2506.15514. arXiv: 2506.15514[cs.SD].

[38] Francesco Bonzi et al. «Exploiting Music Source Separation For Singing Voice Detection». In: *2023 IEEE 33rd International Workshop on Machine Learning for Signal Processing (MLSP)*. 2023 IEEE 33rd International Workshop on Machine Learning for Signal Processing (MLSP). Rome, Italy: IEEE, 2023. DOI: 10.1109/MLSP55844.2023.10285863.

[39] Mateusz Barański et al. «Investigation of Whisper ASR Hallucinations Induced by Non-Speech Audio». In: *ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2025. DOI: 10.1109/icassp49660.2025.10890105.

[40] Ju-Chiang Wang, Yun-Ning Hung e Jordan B. L. Smith. *To catch a chorus, verse, intro, or anything else: Analyzing a song with structural functions*. 2022. DOI: 10.48550/arXiv.2205.14700. arXiv: 2205.14700[eess.AS].

[41] Taejun Kim e Juhan Nam. *All-In-One Metrical And Functional Structure Analysis With Neighborhood Attentions on Demixed Audio*. 2023. URL: https://arxiv.org/abs/2307.16425.

[42] Sreyan Ghosh et al. *Audio Flamingo Next: Next-Generation Open Audio-Language Models for Speech, Sound, and Music*. 2026. URL: https://arxiv.org/abs/2604.10905.

[43] Luca A Lanzendörfer et al. «BLAP: Bootstrapping Language-Audio Pretraining for Music Captioning» (2024). URL: https://openreview.net/forum?id=23LTPLTB88.

[44] Alec Radford et al. *Learning Transferable Visual Models From Natural Language Supervision*. _eprint: 2103.00020. 2021. URL: https://arxiv.org/abs/2103.00020.

[45] Yusong Wu et al. «Large-Scale Contrastive Language-Audio Pretraining with Feature Fusion and Keyword-to-Caption Augmentation». In: *ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Rhodes Island, Greece: IEEE, 2023. DOI: 10.1109/ICASSP49357.2023.10095969.

[46] Jiayi Zhang et al. «Verbalized Sampling: How to Mitigate Mode Collapse and Unlock LLM Diversity». *arXiv preprint arXiv:2510.01171* (2025).

[47] Nitish Shirish Keskar et al. «CTRL: A Conditional Transformer Language Model for Controllable Generation». *arXiv preprint arXiv:1909.05858* (2019).

[48] Junda Wu et al. «FUTGA-MIR: Enhancing Fine-grained and Temporally-aware Music Understanding with Music Information Retrieval». In: *ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Hyderabad, India: IEEE, 2025. DOI: 10.1109/ICASSP49660.2025.10888485.

[49] Yanfeng Shi et al. *Towards Fine-grained Temporal Perception: Post-Training Large Audio-Language Models with Audio-Side Time Prompt*. 2026. DOI: 10.48550/arXiv.2604.13715. arXiv: 2604.13715[cs.SD].

[50] Sonal Kumar et al. «MMAU-Pro: A Challenging and Comprehensive Benchmark for Holistic Evaluation of Audio General Intelligence». *arXiv preprint arXiv:2508.13992* (2025).

[51] Weijie Wu et al. *MMAC: A Massive Multi-dimensional Benchmark for Audio Captioning*. 2026. URL: https://arxiv.org/abs/2607.27109.

[52] Leonardo Haw-Yang Foo et al. *All That Glitters Is Not Audio: Rethinking Text Priors and Audio Reliance in Audio-Language Evaluation*. 2026. URL: https://arxiv.org/abs/2604.24401.

[53] Teemu Mäki-Patola. «MUSICAL EFFECTS OF LATENCY».

[54] Bob McMurray. «The myth of categorical perception». *The Journal of the Acoustical Society of America* 152.6 (2022). DOI: 10.1121/10.0016614.

[55] Alvin M. Liberman et al. «The discrimination of speech sounds within and across phoneme boundaries.» *Journal of Experimental Psychology* 54.5 (1957). DOI: 10.1037/h0044417.

[56] Hans Strasburger. «Invariance of the psychometric function for character recognition across the visual field». *Perception & Psychophysics* 63.8 (2001). DOI: 10.3758/BF03194548.

[57] Hai Huyen Dam et al. «Optimized Sigmoid Functions for Speech Presence Probability and Gain Function in Speech Enhancement». *Circuits, Systems, and Signal Processing* 43.5 (2024). DOI: 10.1007/s00034-023-02549-2.

[58] Department of Computer Science, Babcock University, Ilishan Remo (Ogun State), Nigeria. et al. «Voice Activity Detection Using Weighted K-Means Thresholding Algorithm». *International Journal of Innovative Technology and Exploring Engineering* 14.4 (2025). DOI: 10.35940/ijitee.D1051.14040325.

[59] Oriol Nieto et al. «THE HARMONIX SET: BEATS, DOWNBEATS, AND FUNCTIONAL SEGMENT ANNOTATIONS OF WESTERN POPULAR MUSIC».

[60] Oriol Nieto e Juan Pablo Bello. «MSAF: MUSIC STRUCTURE ANALYSIS FRAMEWORK». In: 2015. URL: https://api.semanticscholar.org/CorpusID:204780258.

[61] Mark Levy e Mark Sandler. «Structural Segmentation of Musical Audio by Constrained Clustering». *IEEE Transactions on Audio, Speech, and Language Processing* 16 (2008). DOI: 10.1109/TASL.2007.910781.

[62] Hanna Lukashevich. *Towards quantitative measures of evaluating song segmentation*. 2008. URL: https://publica.fraunhofer.de/handle/publica/360587.

[63] Andrea Agostinelli et al. *MusicLM: Generating Music From Text*. _eprint: 2301.11325. 2023. URL: https://arxiv.org/abs/2301.11325.

[64] Ilaria Manco et al. «The Song Describer Dataset: a Corpus of Audio Captions for Music-and-Language Evaluation». In: *Machine Learning for Audio Workshop at NeurIPS 2023*. 2023.

Ringraziamenti